

# PV-FashionViT：基于 Transformer 的位置可变 FashionMNIST 图像分类

人工智能工程实践

## 小组成员

| 序号 | 姓名  | 学号         |
|----|-----|------------|
| 1  | 李怿凡 | 3240103379 |
| 2  | 李建树 | 3230101228 |
| 3  | 龙官震 | 3250105720 |
| 4  | 朱云麟 | 3250102363 |

2026 年 7 月

## 摘要

标准 FashionMNIST 的服饰主体大多位于图像中央，常规测试准确率因而难以反映模型面对位置变化时的稳定性。本项目将原始  $28 \times 28$  灰度图像放入  $56 \times 56$  画布，并施加可控平移和最大  $45^\circ$  的双向旋转。构造后的数据集支持中心、小幅平移、大幅平移、 $7 \times 7$  位置网格、随机旋转和固定角度扫描等评估协议；随机擦除只作为增强模型的训练设置使用。在统一的 CPU 训练预算下，项目比较了 MLP、CNN、带可学习绝对位置编码的 Tiny ViT，以及依次加入复合增强、Mean Pooling 和卷积 stem 的三种 ViT 变体。

五个随机种子下的结果显示，中心准确率不能替代位置鲁棒性评价。CNN 的 Center Accuracy 均值达到 90.93%，但 Grid Accuracy 仅为 13.09%；ViT-AbsPos 的 Grid Accuracy 为 20.68%，仍有明显的中心偏置。加入平移、旋转与随机擦除后，ViT-Aug 和 ViT-MeanPool 的网格表现分别提升至 63.77% 和 65.17%。HybridConv-ViT 的 Grid Accuracy 达到 81.05%，在 Center、Large Shift、Rotation 和 Shift+Rotation 下也保持在约 81%。三种子消融显示，平移和旋转增强分别改善位置与角度鲁棒性，Random Erasing 在当前设置下影响较小；移除位置编码可以减轻中心依赖，但效果仍不及位移增强。总体上，训练期覆盖目标扰动带来的提升最大，卷积 stem 进一步改善了稳定性，而相似服饰类别和极端边缘输入仍较难识别。

**关键词：**位置可变性；FashionMNIST；Vision Transformer；鲁棒性评估；数据增强；可视化分析

# 目录

|          |                              |           |
|----------|------------------------------|-----------|
| <b>1</b> | <b>项目背景与问题定义</b>             | <b>1</b>  |
| 1.1      | 项目目标 . . . . .               | 1         |
| 1.2      | 探索路线 . . . . .               | 1         |
| 1.3      | 主要完成内容 . . . . .             | 2         |
| <b>2</b> | <b>PV-FashionMNIST 数据集构造</b> | <b>2</b>  |
| 2.1      | 从中心分类到位置可变分类 . . . . .       | 2         |
| 2.2      | 数据划分与随机性控制 . . . . .         | 3         |
| 2.3      | 平移协议 . . . . .               | 3         |
| 2.4      | 旋转与复合增强 . . . . .            | 4         |
| 2.5      | 数据构造可视化 . . . . .            | 4         |
| <b>3</b> | <b>模型设计与改进思路</b>             | <b>7</b>  |
| 3.1      | MLP 基线 . . . . .             | 8         |
| 3.2      | CNN 基线 . . . . .             | 8         |
| 3.3      | Tiny ViT 与绝对位置 . . . . .     | 8         |
| 3.4      | 扩大训练分布 . . . . .             | 9         |
| 3.5      | Mean Pooling . . . . .       | 9         |
| 3.6      | HybridConv-ViT . . . . .     | 9         |
| <b>4</b> | <b>工程实现与训练设置</b>             | <b>10</b> |
| 4.1      | 配置驱动的运行流程 . . . . .          | 10        |
| 4.2      | 训练目标与优化 . . . . .            | 10        |
| 4.3      | 训练设置 . . . . .               | 11        |
| 4.4      | 统一 CPU 前向基准 . . . . .        | 12        |
| 4.5      | 检查点与日志 . . . . .             | 12        |
| 4.6      | 评估协议与指标 . . . . .            | 12        |
| 4.7      | 可复现运行顺序 . . . . .            | 13        |
| <b>5</b> | <b>实验设计与探索过程</b>             | <b>14</b> |
| 5.1      | 六组主实验 . . . . .              | 14        |
| 5.2      | 三层对照逻辑 . . . . .             | 14        |
| 5.3      | 逐项增强消融 . . . . .             | 15        |

|          |                             |           |
|----------|-----------------------------|-----------|
| 5.4      | 位置编码消融 . . . . .            | 15        |
| 5.5      | 评价安排 . . . . .              | 16        |
| <b>6</b> | <b>实验结果与量化分析</b>            | <b>16</b> |
| 6.1      | 中心高分不等于位置鲁棒 . . . . .       | 16        |
| 6.2      | 从增强到 Hybrid 的逐步变化 . . . . . | 18        |
| 6.3      | 三种子逐项增广揭示的取舍 . . . . .      | 19        |
| 6.4      | 位置编码不是位移鲁棒性的充分条件 . . . . .  | 20        |
| 6.5      | 模型规模与 CPU 前向开销 . . . . .    | 21        |
| 6.6      | 固定角度扫描的量化结果 . . . . .       | 21        |
| 6.7      | 类别层面的困难并未消失 . . . . .       | 22        |
| <b>7</b> | <b>可视化与误差分析</b>             | <b>23</b> |
| 7.1      | 训练过程 . . . . .              | 23        |
| 7.2      | 位置响应 . . . . .              | 24        |
| 7.3      | 无裁剪内层与可能裁剪外圈 . . . . .      | 24        |
| 7.4      | 等半径裁剪对照 . . . . .           | 25        |
| 7.5      | 角度响应 . . . . .              | 26        |
| 7.6      | 逐类热力图与混淆结构 . . . . .        | 27        |
| 7.7      | Attention Rollout . . . . . | 29        |
| <b>8</b> | <b>总结、局限与后续工作</b>           | <b>31</b> |
| 8.1      | 对研究问题的回答 . . . . .          | 31        |
| 8.2      | 现有局限 . . . . .              | 31        |
| 8.3      | 后续可开展实验 . . . . .           | 32        |
| <b>9</b> | <b>成员贡献</b>                 | <b>32</b> |
| 9.1      | 项目仓库 . . . . .              | 32        |

# 1 项目背景与问题定义

在真实图像中，目标通常不会始终位于画面中心。衣物照片会受到构图习惯、拍摄角度和遮挡影响，同一件衣物可能出现在角落，也可能只保留部分轮廓。如果训练数据长期保持居中，模型就可能把“中心区域出现前景”当作一种稳定线索。此时，原始测试集上的高准确率既包含类别识别能力，也包含训练分布与测试分布高度一致带来的便利；仅凭这一数字，很难判断模型是否真正学到了可以随目标移动的视觉特征。

FashionMNIST 包含十类  $28 \times 28$  灰度服饰图像 [1]，规模适中、类别清晰，适合在有限算力下反复开展控制实验。它的主体位置相对固定，恰好为研究位置偏置提供了一个简洁起点。另一方面，Shirt、T-shirt/top、Pullover 和 Coat 等类别外形接近，当图像在边缘发生截断时，完整轮廓消失，模型会更依赖局部纹理，这使数据集同时具备可控性和一定的分析价值。

Transformer 通过自注意力在序列元素之间建立全局联系 [2]，Vision Transformer 则把图像划分为 patch 序列进行建模 [3]。全局交互并不自动带来位置不变性：patch 仍与位置编码结合，训练数据的空间分布也会影响模型。为此，本文在同一套位置与角度协议下比较 MLP、CNN、普通 ViT 和三种改进的 ViT。

## 1.1 项目目标

本文把中心分类任务扩展为可测量的位置鲁棒性问题，主要回答三个问题：

1. 当训练图像保持居中而测试目标发生平移或旋转时，分类性能会下降到什么程度？中心准确率能否代表真实的鲁棒性？
2. MLP、CNN 和带可学习绝对位置编码的 Tiny ViT 会呈现怎样不同的空间响应？ViT 的全局交互是否足以抵消中心训练分布带来的偏置？
3. 扩大训练期的位置和角度覆盖、改变 token 聚合方式、加入卷积 stem，能否让准确率在位置网格和角度区间上更加平坦？

## 1.2 探索路线

探索围绕两类变量展开：先用 MLP、CNN 和 ViT-AbsPos 比较不同空间归纳偏置，再沿 ViT 路线依次改变训练扰动、token 聚合与局部卷积先验。评估端同时采用随机平移、随机旋转、49 点位置网格和七个固定角度，避免用单个中心准确率概括全部表现。各模型原理和具体对照关系分别在第 3 节和第 5 节说明，图1只给出总体路线。




图 1: 位置可变分类实验的总体设计

### 1.3 主要完成内容

- 实现可复现的 PV-FashionMNIST，统一记录  $dx$ 、 $dy$ 、angle 和 scale，并使随机参数随 epoch 更新；
- 实现 MLP、CNN、Tiny ViT 和 HybridConv-ViT，通过 YAML 继承管理 CPU 与 GPU 配置，并组织六组正式实验；
- 建立 Center、Small Shift、Large Shift、Grid、Rotation 和 Shift+Rotation 评估协议，并补充等位移半径裁剪对照，输出 Robust Drop、Rotation Drop、逐类准确率和混淆矩阵；
- 对增强阶段与位置编码开展三个随机种子的控制变量消融，报告均值与样本标准差；
- 生成数据示例、训练曲线、位置网格、角度响应、错误样本和 Attention Rollout 图；
- 保存检查点、运行配置、逐轮日志和逐样本预测，便于复现实验。

## 2 PV-FashionMNIST 数据集构造

### 2.1 从中心分类到位置可变分类

原始 FashionMNIST 样本是单通道  $28 \times 28$  图像。PV-FashionMNIST 不改变类别标签，而是先对前景进行可选旋转，再把它粘贴到  $56 \times 56$  的全零画布。以居中位置为原点， $dx > 0$  表示向右移动， $dy > 0$  表示向下移动。模型输入因此统一为  $[1, 56, 56]$ ，输出仍是十类 logits。

这个构造把类别内容与空间位置分开：对同一个原始样本，只需改变  $(dx, dy)$  或 angle，就能得到一组内容相同而扰动强度不同的测试输入。与直接使用随机增强相比，可记录的元数据使后续按坐标和角度聚合准确率成为可能。每次取样返回

$$(\text{image}, \text{label}, \text{meta}), \quad \text{meta} = \{dx, dy, \text{angle}, \text{scale}\}.$$

## 2.2 数据划分与随机性控制

FashionMNIST 官方训练集包含 60,000 张图像，项目按配置中的随机种子划分为 54,000 张训练样本和 6,000 张验证样本；官方 10,000 张测试图像只用于最终评估。同一随机种子下，六组模型使用相同划分；随机种子 42 用于代表性可视化，第 6 节主结果则汇总五个固定随机种子。这样既能保持同一随机种子下的模型对照公平，也能观察数据划分、模型初始化和增强采样共同带来的波动。

训练期随机参数由随机种子、训练轮次和样本索引共同生成。这样做有两个目的：同一配置重新运行时可以复现；训练样本又不会在所有轮次中停留在同一位置和角度。训练循环在每轮开始时更新数据集状态，而验证集和测试集固定使用第 0 轮的数据集状态。随机性不依赖 DataLoader 的 worker 调度，因此切换单进程或多进程加载不会改变某个样本的增强参数。

## 2.3 平移协议

项目把位置变化划分为四种强度：

- **Center**：固定使用  $(dx, dy) = (0, 0)$ ，对应原始中心分布；
- **Small Shift**： $dx, dy$  分别在  $[-8, 8]$  内按整数均匀采样，主体仍大多完整可见；
- **Large Shift**： $dx, dy$  分别在  $[-18, 18]$  内按整数均匀采样，包含明显边缘位置；
- **Grid Shift**： $dx, dy \in \{-18, -12, -6, 0, 6, 12, 18\}$ ，共形成 49 个固定位置，每个位置都评估完整测试集。

28 像素前景在 56 像素画布中无裁剪移动的上限为 14 像素。因此当  $|dx|$  或  $|dy| > 14$  时，部分前景会越过画布边界。项目没有把越界区域缩回画面，而是按真实粘贴结果裁剪。这使 Large Shift 同时包含位置分布变化和可见信息减少。它提高了极端条件的难度，也意味着后续不能把所有性能下降都简单归因于“缺少平移不变性”。

除原始  $7 \times 7$  内外圈拆分外，项目进一步构造等半径裁剪对照。在所有整数坐标  $(dx, dy) \in [-18, 18]^2$  中，按  $r^2 = dx^2 + dy^2$  分组，只保留同一  $r^2$  下同时含  $|dx|, |dy| \leq 14$  和至少一轴超过 14 的半径。最终得到 7 个精确匹配半径、104 个坐标。该设计使两组位置到中心的欧氏距离完全相同，再比较几何上完整与可能裁剪位置；由于可用方向集合仍不完全一致，结果解释为距离匹配关联，不表述为严格因果效应。

## 2.4 旋转与复合增强

在平移实验初步建立后，数据协议进一步加入旋转。Rotation 模式把前景保持在中心，在  $[-45^\circ, 45^\circ]$  连续采样角度；Shift+Rotation 则同时在  $[-18, 18]$  内采样平移，并在相同角度范围内旋转。旋转首先作用于原始  $28 \times 28$  前景，采用双线性插值和零填充，之后再粘贴到大画布。该顺序避免围绕整张  $56 \times 56$  画布旋转而产生与目标无关的大范围位移。

这一实现对应一个直接的图像坐标运算。若原像素坐标为  $(u, v)$ ，角度为  $\alpha$ ，则旋转和平移可合并为

$$\begin{bmatrix} u' \\ v' \\ 1 \end{bmatrix} = \begin{bmatrix} \cos \alpha & -\sin \alpha & dx \\ \sin \alpha & \cos \alpha & dy \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} u \\ v \\ 1 \end{bmatrix}.$$

程序采用逆向坐标映射和双线性插值。旋转会同时改变轮廓方向和局部像素，越界裁剪还会减少可见信息，这两点都可能影响分类结果。

增强模型的训练数据采用 Shift+Rotation，并以 0.25 的概率执行随机擦除：擦除区域为边长 4-10 像素的正方形，像素填充为 0。缩放参数仍作为数据集接口保留，但本轮正式实验不额外混入缩放，以便把主要变化集中在平移和旋转。除了连续随机角度，测试阶段还固定评估

$$\{-45^\circ, -30^\circ, -15^\circ, 0^\circ, 15^\circ, 30^\circ, 45^\circ\},$$

从而分别观察不同角度下的准确率。

## 2.5 数据构造可视化

图2依次展示原始图像、居中画布、随机平移、纯旋转和 Shift+Rotation。前景类别保持不变，只改变空间位置和朝向。






图 2: 原始 FashionMNIST 与 PV-FashionMNIST 的五种输入形式

图3把同一个样本放到九个典型坐标。中心位置保留完整轮廓，四个角落则出现不同方向的截断，这也是后续网格热力图出现边缘退化的重要数据原因。




图 3: 同一测试样本在九个典型  $(dx, dy)$  位置下的外观（极端位置可能减少了可见区域）

图4固定位置，只改变输入角度。 $\pm 45^\circ$  下仍能辨认主体，但轮廓方向和插值后的

局部像素已经与中心训练样本明显不同。位置九宫格与角度序列分别隔离了两类扰动，为后续空间和角度分析提供参照。




图 4: 同一测试样本在七个固定旋转角度下的输入变化，旋转范围由  $-45^\circ$  延伸至  $45^\circ$

图5按照配置文件对平移和角度各进行 12,000 次蒙特卡洛采样。左图叠加整数均匀平移、49 个固定网格点、Small Shift 边界和无裁剪边界；右图叠加连续随机角度直方图与七个固定测试角度。该图展示配置定义的采样范围。




图 5: 配置定义的平移与旋转采样分布，以及确定性的网格和固定角度评估探针

### 3 模型设计与改进思路

六组模型都接收  $[B, 1, 56, 56]$  输入并输出十类 logits。模型规模控制在 CPU 可以完成多组实验的范围内，重点不是把网络做大，而是看清训练分布、空间结构和 token 聚合方式分别带来什么变化。表1把各模型的层数、宽度和参数量放在一起，后文再解释这些结构为什么可能影响位置适应能力。

表 1: 模型规模与主要结构差异

| 模型                 | 主体结构                                                                    | 位置 / 聚合              | 参数量       |
|--------------------|-------------------------------------------------------------------------|----------------------|-----------|
| MLP                | Flatten, 隐藏层 256, ReLU                                                  | 无显式空间聚合              | 805,642   |
| CNN                | Conv $1 \rightarrow 32 \rightarrow 64$ , 两次池化, FC 128                   | 卷积后展平                | 1,625,866 |
| ViT-AbsPos/ViT-Aug | $7 \times 7$ patch, 64 tokens, $d = 64$ , 2 个 Encoder, 4 heads, FFN 128 | Learnable Pos / CLS  | 75,146    |
| ViT-MeanPool       | 与上行相同                                                                   | Learnable Pos / Mean | 75,018    |
| HybridConv-ViT     | Conv $1 \rightarrow 32 \rightarrow 64$ stem, 随后同规格 Transformer          | Learnable Pos / Mean | 291,402   |

所有模型的 dropout 均为 0.1，分类头输出 10 个 logits。三种 Tiny ViT 共享同一套 Transformer 主体： $56/7 = 8$ ，所以每张图形成  $8 \times 8 = 64$  个视觉 token；每层前馈网络把 64 维特征扩展到 128 维后再压回。这样设置一方面让自注意力仍能覆盖完整画布，另一方面把模型控制在约 7.5 万参数，适合本项目的多组 CPU 对照。Hybrid 只在 token 化之前增加两层  $3 \times 3$  卷积，因此它仍然是小模型，而不是通过大幅增加 Transformer 深度来换取结果。

图6把六组实验的关系压缩为两条线索：E1–E3 使用相同中心训练分布比较三类基础架构；E3–E6 则沿 ViT 路线依次扩大训练分布、改变聚合方式并加入卷积 stem。后者是一条逐步改进链，而不是六个互不相关的模型。




图 6: 六组模型的对照关系与 ViT 改进路径

### 3.1 MLP 基线

MLP 将  $56 \times 56$  输入展平成 3,136 维向量, 经过 256 维隐藏层、ReLU、Dropout 和十类线性分类头。展平后, 每个输入权重都与固定像素坐标对应, 同一轮廓平移后会激活不同的连接。因此, MLP 作为缺少二维局部结构和权值共享的基线, 用于观察中心训练分布造成的位置依赖。

### 3.2 CNN 基线

CNN 使用两组 “ $3 \times 3$  Conv-ReLU-MaxPool”, 通道数由 1 增至 32、再增至 64, 之后连接 128 维全连接层和分类头。卷积的局部连接与权值共享使同一纹理移动后仍能产生相似响应, 两次池化则提供小范围的位置容忍度。由于后端全连接层仍接收固定位置的特征图, 且极端平移会造成裁剪, 该模型并不具备严格的平移不变性。CNN 因此作为具有局部空间先验的基线, 与 ViT 的全局 token 建模进行比较。

### 3.3 Tiny ViT 与绝对位置

Tiny ViT 使用步长和核大小均为 7 的卷积完成 patch embedding, 将  $56 \times 56$  图像划分为  $8 \times 8 = 64$  个 token, 每个 token 维度为 64。序列经过 2 层 Transformer Encoder, 每层包含 4 头自注意力和扩展比例为 2 的前馈网络。ViT-AbsPos 在序列前加入一个可学习 CLS token, 并为所有 token 叠加可学习绝对位置编码, 最后使用 CLS 输出进行分类。

在每个注意力头中, token 矩阵  $Z$  先投影为  $Q = ZW_Q$ 、 $K = ZW_K$  和  $V = ZW_V$ , 再计算

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V.$$

$QK^T$  给出 64 个 patch 两两之间的相关程度, softmax 将其变为信息汇聚权重, 因而角落 token 可以直接利用远处 token 的信息。但该运算本身不知道二维顺序, 项目必

须叠加位置编码；这也解释了全局交互为何不自动带来位置不变性。

自注意力允许任意 patch 交换信息，但 token 在进入 Encoder 前已经与固定网格坐标绑定。可学习绝对位置编码能够帮助模型区分“上方”和“下方”，同时也可能在中心训练数据上形成强位置先验。因此，ViT-AbsPos 的实验目的不是证明绝对位置编码一定有害，而是观察它在训练位置单一时会呈现怎样的空间响应。

三个 Tiny ViT 变体共享同一模型实现，训练模式与聚合方式由 YAML 配置切换。项目还实现了二维 Sin-Cos 位置编码，并在第 6 节以三个随机种子的补充消融与 Learnable 和 No Positional Encoding 进行比较。Sin-Cos 仍表达绝对坐标，不直接保证平移或旋转不变性。

### 3.4 扩大训练分布

ViT-Aug 保持 ViT-AbsPos 的模型结构不变，把训练数据从中心分布改为平移与旋转复合分布，并加入概率为 0.25 的随机擦除。模型参数量仍为 75,146，E3 与 E4 的主要差异来自训练分布；由于三种增强同时启用，这组主实验不单独估计平移、旋转或擦除的贡献，第 6 节另给出逐项消融。

旋转范围最终设置为  $[-45^\circ, 45^\circ]$ 。这一范围明显强于最初的轻微角度扰动，能够覆盖肉眼可见的朝向变化；同时没有扩展到倒置服饰，以免任务语义发生不必要改变。

### 3.5 Mean Pooling

ViT-MeanPool 删除 CLS token，对 64 个 patch token 的 Encoder 输出求平均，再送入分类头。其余 ViT 结构、位置编码和训练增强与 ViT-Aug 保持一致，因此 E4 与 E5 是六组实验中相对清晰的一组结构对照。

CLS token 是固定的全局信息汇聚点，分类结果取决于注意力层如何把各位置证据传递给它；Mean Pooling 则让每个 patch token 直接参与最终表示，更接近对整张画布上的证据平均投票。该设计不保证一定提升准确率，但可以检验聚合方式是否影响位置分布变化下的稳定性。

### 3.6 HybridConv-ViT

HybridConv-ViT 在 patch embedding 前增加两个带 padding 的  $3 \times 3$  卷积层，通道数依次为 32 和 64，再将卷积特征投影成 Transformer token。后续 Encoder、可学习位置编码和 Mean Pooling 与前一阶段保持同一思路。

卷积 stem 先提取局部边缘和纹理，再把特征图投影为 token；Transformer 负责远距离关系，Mean Pooling 完成全局聚合。这种组合适合依赖鞋底、袖口和衣身轮廓的 FashionMNIST 图像。Hybrid 的参数量为 291,402，仍小于 MLP 和 CNN。E6

相对 E5 只增加卷积 stem，可用于估计它在当前增强和 pooling 设置下的贡献；E6 相对 E3 则是完整方案比较，同时包含增强、pooling 和 stem 的变化。

## 4 工程实现与训练设置

### 4.1 配置驱动的运行流程

项目以 `src/main.py` 作为统一入口。一次正式运行依次完成配置继承、随机种子设置、数据集构建、模型初始化、训练与验证、检查点保存以及多协议测试。公共参数写在 `configs/base.yaml`，模型配置只覆盖 `run_name`、训练模式和结构差异，减少多份 YAML 之间的隐性偏差。

每次实验写入独立目录 `outputs/<run_name>/`，其中包含 `checkpoints/`、`logs/`、`tables/` 和 `figures/`。正式流程被拆成三个阶段：首先训练六种配置在五个随机种子下的 30 个模型并完成基础评估；随后加载各自的 `best.pt`，执行耗时较长的位置网格和固定角度扫描；最后由 `analyze_results.py` 生成随机种子 42 的细节图，再由 `analyze_multiseed_results.py` 汇总五个随机种子的表格与统计图。图7概括了这一过程。三个阶段可以独立重跑，因此修改报告图片不需要重新训练模型。




图 7: 训练、评估与结果汇总流程

### 4.2 训练目标与优化

模型输出十类 logits，训练采用 label smoothing 系数  $\varepsilon = 0.1$  的交叉熵。设类别数为  $C = 10$ ，平滑目标和 batch 损失为

$$q_{i,k} = (1 - \varepsilon)\mathbf{1}[k = y_i] + \frac{\varepsilon}{C}, \quad \mathcal{L} = -\frac{1}{B} \sum_{i=1}^B \sum_{k=1}^C q_{i,k} \log p_{i,k}.$$

其中  $p_{i,k}$  为 softmax 概率。PyTorch 自动微分计算梯度，AdamW 以初始学习率  $3 \times 10^{-4}$  和 weight decay 0.05 更新参数，CosineAnnealing 在训练过程中降低学习率，梯

度范数裁剪上限为 1.0。训练时启用 Dropout；验证和测试使用 `eval()` 并关闭梯度记录。

4.3 训练设置

表2列出正式实验实际使用的训练参数。六种模型沿用同一套优化设置，结构比较时不会因为学习率或 batch size 不同而混入额外变量。

表 2: 正式实验的训练与选优参数

| 参数         | 设置                       | 说明                                          |
|------------|--------------------------|---------------------------------------------|
| 运行设备       | CPU，8 个计算线程              | DataLoader 使用 0 个额外 worker，避免 Windows 多进程开销 |
| 随机种子       | 42、2026、3407、12345、98765 | 每个随机种子都重新完成数据划分、模型初始化、增强采样和随机协议测试           |
| Batch size | 训练 64，评估 256             | 验证与测试不更新梯度，可以使用更大 batch                     |
| 训练轮数       | 最多 12 epochs             | 达到早停条件时可以提前结束                               |
| 优化器        | AdamW                    | 初始学习率 $3 \times 10^{-4}$ ，weight decay 0.05 |
| 学习率调度      | CosineAnnealing          | 在最多 12 个 epoch 内逐步降低学习率                     |
| 损失函数       | Cross Entropy            | label smoothing 0.1                         |
| 梯度裁剪       | 范数上限 1.0                 | 抑制偶发的过大更新                                   |
| 早停         | 最少 5 epochs，patience 3   | 验证准确率改进不超过 0.0005 时计为一轮未提升                  |
| 选优协议       | Center 验证集               | 保存验证准确率最高的 <code>best.pt</code>             |

在随机种子 42 的代表性运行中，ViT-Aug 于第 7 轮达到最佳验证准确率，并在第 10 轮触发早停；其余五种配置运行到第 12 轮。训练图据此显示各次运行实际完成的轮数。

所有模型均按 Center 验证准确率选择检查点，以保持选优标准一致。该设置与原始 FashionMNIST 分类任务对应，但没有直接针对 Grid 或 Shift+Rotation 表现选优。



## 4.4 统一 CPU 前向基准

除训练日志中的单轮耗时外，项目还用 `src/benchmark_cpu.py` 对五种不同推理结构执行统一前向基准。ViT-AbsPos 与 ViT-Aug 共用同一 Tiny ViT (CLS)，数据增强只改变训练输入，因此不重复计时。所有模型均切换到 `eval()` 并关闭梯度记录，接收同一形状的随机输入；固定 8 个 PyTorch 线程和 batch size 64，先预热 5 个 batch，再重复测量 30 个 batch。表3中的延迟不含数据读取、图像变换、反向传播和优化器更新，因此回答的是“同一台 CPU 上模型前向有多快”，而不是完整训练一轮需要多久。绝对数值依赖运行机器，参数量则与硬件无关。

**表 3:** 统一 CPU 前向基准。使用 8 个 PyTorch 线程、batch size 64，预热后重复 30 次；延迟不含数据加载。

| Model          | Parameters | Latency (ms/batch) | Throughput (img/s) |
|----------------|------------|--------------------|--------------------|
| MLP            | 805,642    | 0.37               | 173,570.3          |
| CNN            | 1,625,866  | 16.78              | 3,814.1            |
| Tiny ViT (CLS) | 75,146     | 4.02               | 15,933.5           |
| ViT-MeanPool   | 75,018     | 3.75               | 17,067.6           |
| HybridConv-ViT | 291,402    | 28.15              | 2,273.2            |

## 4.5 检查点与日志

每轮训练保存 `last.pt`，验证准确率刷新时保存 `best.pt`。检查点包含模型权重、优化器、学习率调度器、当前轮次、最佳验证准确率和完整配置。最终测试重新加载 `best.pt`。

日志逐轮记录训练损失、训练准确率、验证损失、验证准确率、学习率和单轮耗时。正式重新训练开始时，当前运行的旧日志会被清空，避免多次运行的数据拼接成错误曲线；smoke test 使用独立的 `_smoke` 目录，也不会写入正式汇总表。

## 4.6 评估协议与指标

基础评估在完整官方测试集上分别构造 Center、Small Shift、Large Shift、Rotation 和 Shift+Rotation 数据。Rotation 表示居中前景在  $[-45^\circ, 45^\circ]$  连续随机旋转；Shift+Rotation 同时随机采样位置和角度。固定位置网格则对 49 个坐标各评估一次完整测试集，固定角度扫描对七个角度分别评估完整测试集。表4进一步区分几种旋转指标的含义。



**表 4:** 旋转相关指标的采样协议与含义，连续随机指标和固定角度汇总来自不同测试构造

| 指标                      | 角度与位置协议                                       | 回答的问题           |
|-------------------------|-----------------------------------------------|-----------------|
| Rotation Accuracy       | 居中位置；每个测试样本在 $[-45^\circ, 45^\circ]$ 连续采样一次角度 | 随机旋转分布上的总体准确率   |
| Fixed-angle Mean        | 七个固定角度分别跑完整测试集，再作宏平均                          | 各方向等权时的平均水平     |
| Fixed-angle Worst       | 七个固定角度准确率的最小值                                 | 已扫描极端方向中的最弱表现   |
| Shift+Rotation Accuracy | 位置与角度同时连续随机采样                                 | 两类扰动共同出现时的总体准确率 |

除 Accuracy 外，项目定义

$$\text{Robust Drop} = \text{Center Accuracy} - \text{Large Shift Accuracy}, \quad (1)$$

$$\text{Rotation Drop} = \text{Center Accuracy} - \text{Rotation Accuracy}. \quad (2)$$

二者均以百分点表示。正值越大，说明模型从中心分布转移到扰动分布时损失越明显；小幅负值并不表示扰动提高了模型能力，而通常说明增强模型在不同条件下的性能接近，随机测试采样和训练分布差异造成了数个百分点波动。

Grid Accuracy 是 49 个位置准确率的宏平均，同时报告网格最小值和最大值以分析空间平坦性。逐类准确率和混淆矩阵基于 Large Shift 预测统计，逐样本结果记录  $dx$ 、 $dy$  和  $angle$ ，用于错误样本与可视化分析。

## 4.7 可复现运行顺序

在 Windows PowerShell 中，正式流程只保留多随机种子训练和评估。随机种子 42 本身已包含在五个种子中，训练曲线、位置热力图、逐类结果和 Attention 对比直接从该次运行生成，无需再训练一套内容重复的单种子模型。

```
conda activate pv-vit
python src/visualize_data.py
.\scripts\run_multiseed_experiments.ps1
.\scripts\eval_multiseed_grid.ps1
python src/visualize_attention_comparison.py
.\scripts\run_augmentation_ablation.ps1
.\scripts\run_position_encoding_ablation.ps1
.\scripts\run_matched_clipping.ps1
```

`eval_multiseed_grid.ps1` 为 30 个检查点完成固定位置和固定角度评估，再用随机种子 42 生成细节图，并汇总五个随机种子的主表和统计图。表格数据来自每次运行的 `evaluation.json`、网格 CSV 和角度 CSV。

后三个脚本分别运行三个随机种子的逐项增强消融、固定 Center+CLS 条件下的位置编码消融，以及按相同欧氏位移半径分组的边缘裁剪分析。脚本会跳过已有 `evaluation.json` 的训练结果；从头复跑前两个消融时可添加 `-Force`。

## 5 实验设计与探索过程

### 5.1 六组主实验

表5按建立基线、扩大训练分布、改变聚合方式和加入局部先验的顺序组织实验。E1–E3 建立中心训练基线；E4 检查扩大训练分布的效果；E5 改变 token 聚合方式；E6 组合局部卷积特征与 Transformer。同一随机种子下，所有模型使用相同的数据划分、优化器和评估协议。

表 5: 主实验矩阵及各实验回答的问题

| 编号 | 模型             | 训练分布           | 关键设置                 | 主要问题             |
|----|----------------|----------------|----------------------|------------------|
| E1 | MLP            | Center         | 展平输入                 | 缺少空间结构时位置退化有多明显？ |
| E2 | CNN            | Center         | 局部卷积与池化              | 权值共享能否自然抵抗大幅平移？  |
| E3 | ViT-AbsPos     | Center         | Learnable Pos + CLS  | 全局交互是否仍会学习中心偏置？  |
| E4 | ViT-Aug        | Shift+Rotation | CLS + Random Erasing | 目标扰动增强组合能改善多少？   |
| E5 | ViT-MeanPool   | Shift+Rotation | Mean Pooling         | 聚合方式是否改善稳定性？     |
| E6 | HybridConv-ViT | Shift+Rotation | Conv Stem + Mean     | 局部归纳偏置能否继续提升？    |

### 5.2 三层对照逻辑

六组实验可以合并为三层对照。第一层是 E1–E3：训练分布固定为 Center，只比较 MLP、CNN 与 ViT 的空间建模方式，用来判断中心测试是否掩盖位置失效。第二层是 E3–E4：ViT 结构保持不变，训练输入扩展为平移、旋转和擦除，观察分布覆盖带来的整体变化。第三层是 E4–E6：在相同增强方向上比较 CLS、Mean Pooling 以及卷积 stem 与 Transformer 的组合，考察聚合方式和局部视觉先验。按题目中的 A/B 记法，中心训练模型的 Center 与扰动测试分别对应 B/B 和 B/A，增强模型的 Center 与扰动测试则对应 A/B 和 A/A；项目用动态取样切换分布，不需要复制四套数据文件。

表 6: 按题目 A/B 记法重排的 ViT 四设置结果 (五个随机种子的均值  $\pm$  标准差)

|                      | 测试 B: Center                                             | 测试 A: Large Shift                                        |
|----------------------|----------------------------------------------------------|----------------------------------------------------------|
| 训练 B: Center         | B/B<br>ViT-AbsPos<br><b>86.38% <math>\pm</math> 0.20</b> | B/A<br>ViT-AbsPos<br><b>20.03% <math>\pm</math> 1.36</b> |
| 训练 A: Shift+Rotation | A/B<br>ViT-Aug<br><b>62.81% <math>\pm</math> 2.12</b>    | A/A<br>ViT-Aug<br><b>64.60% <math>\pm</math> 2.37</b>    |

说明: A 表示目标位置发生变化。训练 A 对应 Shift+Rotation 与 Random Erasing 组合, 测试 A 只使用 Large Shift; 因此 B/A 与 A/A 的差异同时包含多种训练增强的影响。

表6把结构相同的 ViT-AbsPos 与 ViT-Aug 排成题目建议的四种设置。B/B 与 B/A 的落差说明中心训练的高分不能迁移到位置变化测试; A/B 与 A/A 的接近则说明扰动训练削弱了对测试位置的依赖。训练 A 同时包含旋转和随机擦除, 各组件的贡献由后续消融实验进一步比较。

本轮选择 7 像素 patch, 使  $56 \times 56$  输入恰好形成  $8 \times 8$  个 token, 并把计算量控制在 CPU 可接受范围。由于没有训练其他 patch 配置, 本文只说明这一取值, 不讨论 patch 大小的优劣。

### 5.3 逐项增强消融

为进一步拆分 E3-E4, 补充 Center、仅平移、平移 + 旋转、平移 + 旋转 + Random Erasing 四个阶段。四者使用相同的 Tiny ViT、CLS pooling、优化器、数据划分和最多 12 epochs 的预算, 只逐步扩大训练输入分布。

四个阶段都在随机种子 42、2026、3407 下独立训练, 表格报告三次运行的均值与样本标准差。随机种子数量少于六组主实验, 因此总体模型比较仍以五种子结果为准。

### 5.4 位置编码消融

为了直接回答位置编码本身的影响, 项目另设 Learnable Absolute、固定二维 Sin-Cos 和 No Positional Encoding 三组。三者固定 Center 训练、CLS pooling、7 像素 patch、64 维 embedding、2 层 Encoder、优化器与最多 12 epochs, 只切换位置编码, 并同样使用随机种子 42、2026、3407。这样可以避免原可选 vit\_sincos.yaml 同时改变训练增强与 Mean Pooling 所带来的混杂。

No Pos 并不等于模型没有任何结构信息: 卷积式 patch embedding 仍提取每个局部块, CLS token 也仍通过自注意力聚合所有 token; 真正被移除的是把 token 映

射到固定画布坐标的显式向量。因此该对照主要检查绝对坐标信息是否提高中心拟合、以及它是否加剧位置迁移下降。

这些实验不是完整的全因子设计。E6 建立在增强和 Mean Pooling 之上，因此卷积 stem 的比较仅对应当前增强与 pooling 设置。固定位置和固定角度扫描用于观察边缘位置和极端角度的表现。

## 5.5 评价安排

随机协议用于概括总体变化，49 点位置网格和固定角度扫描用于定位空间与方向上的薄弱区域，等半径裁剪对照进一步控制离中心距离，逐类结果、错误样本和 Attention Rollout 用于分析类别差异。六组主实验汇总五个随机种子，两条控制变量实验汇总三个随机种子；Attention Rollout 仅作定性分析。

# 6 实验结果与量化分析

本节汇总六组模型在五个随机种子下的结果。每个随机种子都重新进行数据划分、模型初始化和训练增强；固定位置和固定角度扫描使用统一坐标与角度。主表报告均值和样本标准差，柱形图以中位数和上下四分位数展示五次运行的分布。小幅差异同时结合跨种子方向判断。

## 6.1 中心高分不等于位置鲁棒

**表 7:** 不同模型的位置鲁棒性结果（五个随机种子汇总）。Accuracy 均值采用百分比，Drop 均值采用百分点； $\pm$  Std 行均以百分点表示跨种子标准差。

| Model          | Stat      | Center Acc | Small Shift Acc | Large Shift Acc | Rotation Acc | Shift+Rotation Acc | Grid Acc | Robust Drop (pp) | Rotation Drop (pp) |
|----------------|-----------|------------|-----------------|-----------------|--------------|--------------------|----------|------------------|--------------------|
| MLP            | Mean      | 87.63%     | 25.06%          | 14.22%          | 44.14%       | 13.31%             | 13.58%   | 73.41            | 43.48              |
|                | $\pm$ Std | 0.14       | 0.57            | 0.26            | 0.79         | 0.08               | 0.18     | 0.18             | 0.87               |
| CNN            | Mean      | 90.93%     | 29.49%          | 13.80%          | 50.47%       | 12.33%             | 13.09%   | 77.13            | 40.46              |
|                | $\pm$ Std | 0.12       | 0.77            | 0.50            | 0.80         | 0.20               | 0.48     | 0.46             | 0.73               |
| ViT-AbsPos     | Mean      | 86.38%     | 30.35%          | 20.03%          | 46.18%       | 17.40%             | 20.68%   | 66.35            | 40.20              |
|                | $\pm$ Std | 0.20       | 1.50            | 1.36            | 1.71         | 0.94               | 1.23     | 1.33             | 1.77               |
| ViT-Aug        | Mean      | 62.81%     | 64.49%          | 64.60%          | 64.86%       | 65.04%             | 63.77%   | -1.80            | -2.06              |
|                | $\pm$ Std | 2.12       | 2.37            | 2.37            | 2.51         | 2.83               | 2.20     | 1.25             | 1.11               |
| ViT-MeanPool   | Mean      | 63.51%     | 66.02%          | 66.29%          | 66.20%       | 66.83%             | 65.17%   | -2.78            | -2.69              |
|                | $\pm$ Std | 0.70       | 0.89            | 0.99            | 1.29         | 1.05               | 0.83     | 0.99             | 1.02               |
| HybridConv-ViT | Mean      | 81.42%     | 81.83%          | 81.33%          | 81.86%       | 80.90%             | 81.05%   | 0.09             | -0.44              |
|                | $\pm$ Std | 0.48       | 0.74            | 0.72            | 0.90         | 0.81               | 0.73     | 0.62             | 0.52               |

先看最直观的一组结果：只在中心样本上训练时，MLP、CNN 和 ViT-AbsPos 的 Center Accuracy 都超过 86%，CNN 更达到 90.93%。但把衣物移到大范围随机位置后，三者分别只剩 14.22%、13.80% 和 20.03%。CNN 在熟悉的中心位置分得最好，在 Large Shift 下却下降最多。这个反差正好回答了项目最初的问题：标准

FashionMNIST 上的高分，并不能直接代表模型已经学会识别“出现在任何位置”的衣物。

ViT-AbsPos 的中心准确率比 CNN 低 4.55 个百分点，但 Large Shift 和 Grid Accuracy 分别高出 6.23 和 7.59 个百分点，说明全局 token 交互带来了一定帮助。不过，它的 Robust Drop 仍有 66.35 个百分点；对当前小型 ViT 而言，训练数据的位置覆盖仍是决定性因素。

加入平移、旋转和擦除后，ViT-Aug 的中心准确率降到 62.81%，Large Shift、Rotation 和 Shift+Rotation 则稳定在约 65%，表现更为均匀。ViT-MeanPool 把这些指标小幅提高到约 64%–67%；五个随机种子中有四个呈现同向变化，说明 Mean Pooling 有小幅收益，但不是整体提升的主要来源。

综合表现最好的是 HybridConv-ViT。它的 Center 和 Large Shift Accuracy 分别为 81.42% 和 81.33%，Rotation、Shift+Rotation 和 Grid Accuracy 则为 81.86%、80.90% 和 81.05%。它没有追上 CNN 的中心最高分，但不同协议之间的落差明显缩小，并在位置和角度变化下维持约 81% 的准确率。




图 8：五个随机种子汇总后的多协议结果，柱高与空心圆表示中位数，误差线范围为第一至第三四分位数

## 6.2 从增强到 Hybrid 的逐步变化

表 8: 模型消融实验结果（五个随机种子的中位数）

| Model          | Augmentation   | Pooling | Conv Stem | Grid Acc | Robust Drop (pp) |
|----------------|----------------|---------|-----------|----------|------------------|
| MLP            | center         | cls     | No        | 13.59%   | 73.32            |
| CNN            | center         | cls     | No        | 13.16%   | 76.97            |
| ViT-AbsPos     | center         | cls     | No        | 20.56%   | 65.91            |
| ViT-Aug        | shift_rotation | cls     | No        | 64.70%   | -1.59            |
| ViT-MeanPool   | shift_rotation | mean    | No        | 65.37%   | -2.89            |
| HybridConv-ViT | shift_rotation | mean    | Yes       | 80.96%   | -0.01            |

表8按增强、pooling 和卷积 stem 整理六组配置。

E3 到 E4 的 Grid Accuracy 中位数从 20.56% 提升到 64.70%，增加 44.14 个百分点。两者的 ViT 主体相同，主要区别是 E4 使用平移、旋转和擦除增强，说明训练分布覆盖是这一步提升的主要因素。由于三种增强一起加入，这 44.14 个百分点对应整套增强方案。

E4 到 E5 只把 CLS 聚合换成 Mean Pooling，Grid Accuracy 中位数从 64.70% 提升到 65.37%。增幅不大，但五个随机种子中有四个方向一致，因此属于稳定性有限的小幅改进。

E5 到 E6 加入卷积 stem 后，Grid Accuracy 中位数增加 15.59 个百分点，七角度平均中位数增加 16.38 个百分点，Center、Large Shift、Rotation 和 Shift+Rotation 也同步提高。Hybrid 只有 291,402 个参数，仍小于 MLP 和 CNN；结果表明局部卷积特征与 Transformer 的跨位置建模在该任务上形成了有效组合。




图 9: 五个随机种子下六组模型的 49 点 Grid Accuracy，柱高与空心圆表示中位数，误差线范围为第一至第三四分位数

图10把三个关键比较放回同一随机种子内观察。E6 相对 E5、E4 相对 E3 的差值在五个随机种子下都为正；只有 E5 相对 E4 在随机种子 12345 下出现反向。由此看，增强和卷积 stem 带来的变化较稳定，聚合方式属于次要改进。




图 10: 同一随机种子下关键模型对的 Grid Accuracy 差值

### 6.3 三种子逐项增广揭示的取舍

表 9: 数据增强逐项消融（随机种子 42, 2026, 3407）。单元格为均值  $\pm$  样本标准差，单位为百分比或百分点。

| Training distribution      | Center Acc       | Large Shift Acc  | Rotation Acc     | Shift+Rotation Acc | Robust Drop (pp) |
|----------------------------|------------------|------------------|------------------|--------------------|------------------|
| Center                     | 86.63 $\pm$ 0.16 | 20.86 $\pm$ 1.83 | 45.55 $\pm$ 1.27 | 17.74 $\pm$ 0.72   | 65.77 $\pm$ 1.69 |
| Shift only                 | 73.34 $\pm$ 0.17 | 74.14 $\pm$ 0.21 | 41.57 $\pm$ 0.30 | 42.50 $\pm$ 0.66   | -0.80 $\pm$ 0.14 |
| Shift + Rotation           | 63.02 $\pm$ 1.76 | 65.67 $\pm$ 0.61 | 65.81 $\pm$ 1.59 | 66.76 $\pm$ 0.93   | -2.65 $\pm$ 1.16 |
| Shift + Rotation + Erasing | 63.31 $\pm$ 1.03 | 65.98 $\pm$ 0.34 | 66.17 $\pm$ 1.10 | 66.53 $\pm$ 0.39   | -2.67 $\pm$ 0.69 |

表9给出三个随机种子的四阶段控制变量结果。Center 到仅平移是位置鲁棒性的主要跃升：Large Shift Accuracy 从 20.86% 提升到 74.14%，Robust Drop 从 65.77 个百分点缩小到 -0.80 个百分点；代价是 Center Accuracy 从 86.63% 降到 73.34%。仅平移的 Rotation Accuracy 仍为 41.57%，甚至略低于 Center 阶段，而 Shift+Rotation Accuracy 只有 42.50%。这说明覆盖各个位置足以消除主要平移落差，却不会自动学会旋转不变性。

继续加入旋转后，Rotation 与 Shift+Rotation Accuracy 分别增加 24.24 和 24.26 个百分点，四项指标收敛到约 63%–67%；同时 Center 与 Large Shift 分别下降 10.32 和 8.47 个百分点。当前容量与训练预算下，扩大训练分布带来了更均匀但更低的单协议峰值。最后加入 Random Erasing 后，四项指标相对上一阶段的变化均小于对应的跨种子标准差，说明擦除在当前设置下影响较小。






图 11: 三个随机种子的四阶段增广消融；柱高为准确率均值，误差线为样本标准差

## 6.4 位置编码不是位移鲁棒性的充分条件

表 10: 位置编码控制变量实验（随机种子 42, 2026, 3407）。三组均使用 Center 训练、CLS pooling 与相同 Tiny ViT；单元格为均值  $\pm$  样本标准差。

| Positional encoding    | Center Acc       | Large Shift Acc  | Rotation Acc     | Shift+Rotation Acc | Robust Drop (pp) |
|------------------------|------------------|------------------|------------------|--------------------|------------------|
| Learnable absolute     | 86.63 $\pm$ 0.16 | 20.86 $\pm$ 1.83 | 45.55 $\pm$ 1.27 | 17.74 $\pm$ 0.72   | 65.77 $\pm$ 1.69 |
| Fixed 2-D Sin-Cos      | 85.59 $\pm$ 0.45 | 18.39 $\pm$ 0.47 | 50.68 $\pm$ 1.05 | 16.49 $\pm$ 0.44   | 67.19 $\pm$ 0.91 |
| No positional encoding | 84.03 $\pm$ 0.27 | 39.42 $\pm$ 1.81 | 42.66 $\pm$ 0.24 | 28.21 $\pm$ 0.47   | 44.61 $\pm$ 2.05 |

三组位置编码实验保持 Center 训练、CLS pooling 与 Tiny ViT 其余设置完全一致，因此表10中的差异不再混入增强或聚合方式变化。这个对照回答的是当前小型 ViT 中显式画布坐标的作用，而不是为所有 Transformer 结构给出普遍排序。

Learnable Absolute 与固定二维 Sin-Cos 的 Center Accuracy 分别为 86.63% 和 85.59%，Large Shift Accuracy 只有 20.86% 和 18.39%，Robust Drop 均超过 65 个百分点。Sin-Cos 的 Rotation Accuracy 高出 5.13 个百分点，但 Shift+Rotation 反而低 1.25 个百分点，因此不能把这项局部变化解释为整体鲁棒性提升。对当前 Center-trained Tiny ViT 而言，把可学习向量换成固定函数并没有解决位置迁移。

No Positional Encoding 呈现更明确的取舍：Center Accuracy 相对 Learnable 下降 2.60 个百分点，Large Shift 与 Shift+Rotation 却分别提高 18.56 和 10.47 个百分点，Robust Drop 从 65.77 缩小到 44.61 个百分点。移除显式坐标确实减弱了固定位置依赖，但 39.42% 的 Large Shift Accuracy 仍远低于仅平移增强的 74.14%；patch 边界、裁剪和从未见过位移输入等因素仍然存在。因此，位置编码选择会改变取舍，却不是训练分布覆盖的替代品。






图 12: 三个随机种子的受控位置编码消融；柱高为准确率均值，误差线为样本标准差

## 6.5 模型规模与 CPU 前向开销

表3的本次运行环境为 Intel Core Ultra X9 388H 与 PyTorch 2.12.1+cpu。Tiny ViT (CLS) 只有 75,146 个参数，平均每批前向约 4.02 ms；Mean Pooling 版本的参数量和延迟处于同一量级。MLP 虽有 805,642 个参数，却因为主要由密集矩阵乘法组成而达到最低延迟；CNN 参数最多，为 1,625,866 个。HybridConv-ViT 只有 291,402 个参数，仍少于 MLP 和 CNN，但平均每批约 28.15 ms，是五种结构中最慢的一种。这说明参数量不能直接替代 CPU 延迟：卷积特征图大小、token 运算和算子实现同样重要。

MLP 的前向最快，但在 Large Shift 下准确率较低；Hybrid 的吞吐量约为每秒 2,273 张图像，在离线测试规模下可用，并取得约 81% 的多协议准确率。Hybrid 因而是准确率与鲁棒性优先的 CPU 方案，其推理速度并非最优。

## 6.6 固定角度扫描的量化结果

随机 Rotation Accuracy 对  $[-45^\circ, 45^\circ]$  连续采样后的结果取平均，适合概括整体水平，却可能掩盖端点失效。五个随机种子下七个固定角度的宏平均分别为：MLP 39.93%、CNN 45.84%、ViT-AbsPos 41.75%、ViT-Aug 62.75%、ViT-MeanPool 64.02%、HybridConv-ViT 80.24%。

三个中心训练基线都在  $0^\circ$  附近表现最好，绝对角度越大，准确率下降越快。ViT-Aug 和 ViT-MeanPool 把七角度平均提升到 60% 以上；HybridConv-ViT 达到 80.24%，最差角度的跨种子均值也有 73.89%。这张图比单个 Rotation Accuracy 更直观地说明：模型不只是平均准确率提高，在  $\pm 45^\circ$  端点也没有完全失效。正负角度仍有轻微不对称，可能与服装轮廓、插值或有限采样有关，本项目暂不作进一步解释。

图13补充展示七角度平均值和最差角度的跨种子中位数，并与第7节的逐角度扇形图形成互补。前者强调整体稳定性，后者用于检查单次代表性运行的平均值是否掩盖极端角度下降。




图 13: 五个随机种子下的固定角度鲁棒性，柱高与空心圆表示中位数，误差线范围为第一至第三四分位数

## 6.7 类别层面的困难并未消失

表 11: 随机种子 42 的代表性运行在 Large Shift 条件下的类别准确率

| class       | MLP    | CNN    | ViT-AbsPos | ViT-Aug | ViT-MeanPool | HybridConv-ViT |
|-------------|--------|--------|------------|---------|--------------|----------------|
| T-shirt/top | 7.90%  | 12.70% | 21.20%     | 58.30%  | 62.60%       | 72.10%         |
| Trouser     | 6.90%  | 14.70% | 18.00%     | 83.60%  | 90.00%       | 94.10%         |
| Pullover    | 1.70%  | 9.60%  | 1.40%      | 40.20%  | 59.20%       | 67.90%         |
| Dress       | 4.50%  | 4.80%  | 7.90%      | 68.50%  | 67.70%       | 80.20%         |
| Coat        | 1.50%  | 2.00%  | 2.40%      | 50.80%  | 49.70%       | 80.20%         |
| Sandal      | 49.00% | 47.40% | 65.20%     | 87.60%  | 86.20%       | 92.00%         |
| Shirt       | 16.60% | 6.10%  | 11.90%     | 21.70%  | 14.50%       | 49.20%         |
| Sneaker     | 10.30% | 7.50%  | 13.20%     | 80.90%  | 80.90%       | 91.10%         |
| Bag         | 37.00% | 24.40% | 42.90%     | 69.40%  | 82.30%       | 94.70%         |
| Ankle boot  | 3.90%  | 7.30%  | 28.30%     | 77.90%  | 85.20%       | 94.70%         |

表11和后续错误分析使用随机种子 42 的运行展示类别结构；表7则报告五个随机种子的总体统计。

Large Shift 下，HybridConv-ViT 在 Trouser、Sandal、Sneaker、Bag 和 Ankle boot 上分别达到 94.10%、92.00%、91.10%、94.70% 和 94.70%，这些类别通常具有较

明确的整体轮廓或局部特征。Shirt 只有 49.20%，是 Hybrid 最困难的类别；Pullover 为 67.90%，T-shirt/top 为 72.10%。

增强并没有以相同幅度改善所有类别。以衬衫类为例，ViT-Aug 的准确率为 21.70%，ViT-MeanPool 反而只有 14.50%，说明聚合策略的总体收益不能直接推广到每个类别。相似上装之间需要依赖领口、袖长和衣身等完整形状，而边缘截断恰好会破坏这些结构。类别结果因此补充了平均指标：位置鲁棒性不仅是模型是否跟随目标移动，也取决于移动后还剩下多少可区分类别的信息。

## 7 可视化与误差分析

第 6 节给出五个随机种子的总体结果，本节采用随机种子 42 的代表性运行观察训练过程、位置与角度响应、类别错误和注意力分布，用于定位总体指标背后的具体失效区域。

### 7.1 训练过程

图14显示，中心训练的 MLP、CNN 和 ViT-AbsPos 很快达到较高验证准确率，验证损失也较低。ViT-Aug 和 ViT-MeanPool 的中心验证准确率明显较低，这是因为训练样本同时经历大范围平移和旋转，模型需要把有限容量分配给更广的输入分布，而验证集仍保持居中。

在随机种子 42 的运行中，HybridConv-ViT 的中心验证曲线高于另外两个增强 ViT，且损失持续下降。ViT-Aug 在第 7 轮达到最佳验证准确率，并于第 10 轮触发早停，因此曲线记录到第 10 轮。训练曲线用于观察优化过程，最终测试结果以五个随机种子的统计为准。




图 14: 随机种子 42 的代表性运行中六组模型的验证准确率与验证损失

训练曲线还提示一个重要取舍：如果只根据中心验证准确率判断，增强模型似乎不如中心基线；但位置网格显示相反结论。训练阶段和最终评价目标不完全一致，

是后续可以继续改进的工程环节。

## 7.2 位置响应

图15展示各模型随位置变化的准确率。MLP、CNN 和 ViT-AbsPos 都在 (0,0) 附近形成显著高值区，向四周移动后迅速变浅。中心测试只覆盖这些分布的最高区域，因此会高估模型面对任意位置时的表现；均值、极值和下降幅度见第 6 节。

随机种子 42 下，ViT-Aug 和 ViT-MeanPool 的热力图不再出现突出的中心岛，说明训练期随机位置覆盖改变了模型的空间响应。HybridConv-ViT 的 49 点结果进一步收紧，最差位置与最好位置只相差 4.50 个百分点。该局部形态与图9的跨种子总体排序一致；与单个 Grid Accuracy 相比，热力图还能说明代表性运行的改进不是由少数容易坐标拉高平均值。





图 15: 随机种子 42 的  $7 \times 7$  位置网格准确率，横轴和纵轴分别为  $dx$ 、 $dy$ ，每个单元均来自完整测试集

## 7.3 无裁剪内层与可能裁剪外圈

为了进一步检查边缘下降，表12和图16把同一份  $7 \times 7$  网格拆成两组。内层  $5 \times 5$  使用  $\{-12, -6, 0, 6, 12\}$ ，28 像素前景在 56 像素画布中保持完整；外圈 24 个点至少有一个坐标为  $\pm 18$ ，因而会在对应方向损失 4 像素。这个拆分不需要重新训练或重新选择样本，每个坐标仍评估完整测试集。

**表 12:** 随机种子 42 的无裁剪内层与可能裁剪外圈对照。内层为  $|dx|, |dy| \leq 12$  的 25 个点，外圈为至少一个坐标等于  $\pm 18$  的 24 个点。

| Model          | Inner $5 \times 5$ Acc | Outer Ring Acc | Inner-Outer (pp) |
|----------------|------------------------|----------------|------------------|
| MLP            | 16.97%                 | 10.13%         | 6.84             |
| CNN            | 16.47%                 | 10.12%         | 6.35             |
| ViT-AbsPos     | 26.76%                 | 17.32%         | 9.44             |
| ViT-Aug        | 63.12%                 | 61.42%         | 1.70             |
| ViT-MeanPool   | 66.72%                 | 65.67%         | 1.05             |
| HybridConv-ViT | 81.57%                 | 80.39%         | 1.18             |



**图 16:** 随机种子 42 的无裁剪内层  $5 \times 5$  与可能裁剪外圈 Accuracy 对比，柱顶数字为准确率，gap 为两组百分点差

三个中心训练基线的内外圈差距为 6.35–9.44 个百分点，其中 ViT-AbsPos 最大；ViT-Aug、ViT-MeanPool 和 HybridConv-ViT 的差距只有 1.05–1.70 个百分点。换言之，增强模型不仅热力图更平坦，在前景部分越界的外圈也没有出现额外的大幅崩溃。不过，外圈同时比内层离中心更远，因此这项拆分只能量化“边缘位置加上裁剪”的联合惩罚，不能把差值全部解释为可见信息损失的纯因果效应。


## 7.4 等半径裁剪对照

为排除“外圈离中心更远”这一明显混杂，项目在全部整数位移中按  $r^2 = dx^2 + dy^2$  分组，只保留同一精确半径下同时存在无裁剪和可能裁剪坐标的分组。最终得到 7 个半径、104 个坐标；每个坐标均评估完整测试集，先在半径内分别宏平均两类坐

标, 再对 7 个半径作宏平均。该分析复用 seed 42 的 Center-trained ViT 与 Augmented ViT 检查点。

**表 13:** seed 42 的等半径裁剪对照。每个半径内分别宏平均无裁剪与可能裁剪坐标, 再对七个完全匹配半径作宏平均; Gap 为无裁剪减可能裁剪。

| Model              | Radii | No-clip Acc | Possible-clip Acc | Gap (pp) |
|--------------------|-------|-------------|-------------------|----------|
| Center-trained ViT | 7     | 16.27%      | 17.54%            | -1.27    |
| Augmented ViT      | 7     | 65.88%      | 65.77%            | 0.11     |



**图 17:** seed 42 的等半径裁剪对照; 纵轴为每个精确位移半径内无裁剪与可能裁剪坐标的准确率差

表13显示, Center-trained ViT 的无裁剪与可能裁剪宏平均分别为 16.27% 和 17.54%, Gap 为  $-1.27$  个百分点; 在模型已经严重失效的极端半径上, 坐标方向差异会影响比较结果。Augmented ViT 的两组准确率为 65.88% 和 65.77%, Gap 仅 0.11 个百分点, 七个半径的差值也大多接近零。距离匹配后没有观察到一致的额外裁剪惩罚。由于同一半径内两类坐标的方向集合并不完全相同, 该结果只用于说明距离匹配后的差异。

## 7.5 角度响应

图18把随机种子 42 在  $-45^\circ$  到  $45^\circ$  下的结果排成扇形, 每个模型占一层环带, 单元格数字为该固定角度下的 Accuracy。下方柱状图单独给出七个角度的平均值, 避免把平均统计塞入扇形后降低可读性; 跨种子的角度总体水平则以图13为准。

三个中心训练基线在  $0^\circ$  形成深色尖峰, 越靠近  $\pm 45^\circ$  越浅; 其中 CNN 的平均值明显受到中心高点拉动。ViT-Aug 和 ViT-MeanPool 的颜色沿角度方向更均匀,

Hybrid 则在所有扇区保持较深颜色。扇形图因此同时呈现了三个信息：中心峰值有多高、极端角度下降多快，以及平均准确率是否由少数角度支撑。正负角度的局部不对称只是观察现象，当前实验无法区分类别朝向、插值误差和随机波动的影响。




图 18: 随机种子 42 的固定角度扇形热力图与七角度平均准确率，扇形由左至右对应  $-45^\circ$  到  $45^\circ$

## 7.6 逐类热力图与混淆结构

图19显示 Large Shift 下十个类别并没有同步改善。鞋类、包和裤子在增强模型中形成较稳定的高值区，上装类别仍较困难。尤其是 Shirt 一行在所有模型中都明显偏浅，说明整体 Grid Accuracy 的提高没有消除细粒度类别混淆。






图 19: 随机种子 42 的代表性运行在 Large Shift 条件下的逐类准确率

图20中的混淆矩阵进一步给出错误方向。数量最多的非对角项是 Shirt 被预测为 Coat (252 次)，其次是 Pullover 被预测为 Coat (167 次)、T-shirt/top 被预测为 Shirt (164 次) 以及 Shirt 被预测为 T-shirt/top (115 次)。这些错误集中在轮廓相近的上装类别，符合逐类准确率的观察。鞋类也存在外形接近的混淆，例如 Sneaker 与 Ankle boot，但数量明显少于上装内部错误。




图 20: 随机种子 42 的 HybridConv-ViT 在 Large Shift 下的类别混淆与错误样本

错误样本大致可以分为两类。一类主体仍较完整，但类别本身相近，例如 Coat 被预测为 Dress、Pullover 或 Shirt；另一类处在  $|dx|$  或  $|dy|$  较大的位置，只剩局部鞋面、裤腿或衣身，模型只能根据残留纹理判断。图中也存在 Sandal 与 Sneaker、Sneaker 与 Ankle boot 的互相混淆。这说明部分失败源于类别边界，部分失败来自可见信息减少，不能全部归结为 Transformer 结构。



## 7.7 Attention Rollout



图 21: 随机种子 42 中五个边缘位置样本的 Attention Rollout 对照 (一), 左至右为输入、ViT-AbsPos 和 HybridConv-ViT




图 22: 随机种子 42 中五个边缘位置样本的 Attention Rollout 对照 (二)

Attention 对照使用随机种子 42。图21和图22每行依次给出输入、ViT-AbsPos rollout 和 Hybrid rollout。Hybrid 的高响应通常更集中于当前前景，例如角落中的鞋

面、衣身或裤腿；ViT-AbsPos 的响应有时扩散到前景外的空白区域，或者只覆盖局部边缘。

rollout 展示注意力权重的传播结果，不直接等同于特征贡献。图中差异作为定性观察，并与网格准确率和错误样本结合分析。

## 8 总结、局限与后续工作

### 8.1 对研究问题的回答

**第一，位置变化会不会明显影响分类？**会，而且影响远大于中心测试给人的印象。中心训练的 MLP、CNN 和 ViT-AbsPos 在 Center 上都有 86% 以上准确率，CNN 达到 90.93%；换成 Large Shift 后，三者只剩 14.22%、13.80% 和 20.03%。这说明原任务中的高准确率很大一部分建立在“衣物总在画布中央”这一稳定条件上。一旦位置变化并伴随边缘裁剪，模型原有的分类能力不能直接迁移过去。

**第二，使用绝对位置编码的 Tiny ViT 能否自然适应位移？**不能。ViT-AbsPos 在 Large Shift 和位置网格上比中心训练的 MLP、CNN 略好，但 Grid Accuracy 仍只有约 21%，Robust Drop 达到 66.35 个百分点。受控三种子实验中，固定二维 Sin-Cos 与可学习绝对位置编码的位移表现相近；完全移除位置编码虽然把 Large Shift Accuracy 从 20.86% 提高到 39.42%，也同时降低中心准确率，而且仍明显不如平移增强。自注意力和位置编码选择都会影响取舍，却不能替代合适的训练分布。

**第三，数据增强、Mean Pooling 和卷积 stem 是否有效？**三者的作用大小不同。加入平移、旋转和随机擦除后，ViT 的 Grid Accuracy 从约 21% 提升到约 65%，这是最主要的变化；三种子逐项消融进一步表明，平移负责消除主要位置落差，旋转负责补上角度鲁棒性，而 Random Erasing 在当前设置下基本中性。Mean Pooling 又带来约 1 个百分点的小幅改善；加入卷积 stem 后，HybridConv-ViT 的 Center、Large Shift、Rotation、Shift+Rotation 和 Grid Accuracy 都达到约 81%。它没有取得最高的中心准确率，但位置改变、角度改变或二者同时出现时，成绩几乎不再下降。

在当前实验中，HybridConv-ViT 的综合表现最好：它在五个随机种子下均保持较高的位置和角度准确率，对中心位置的依赖明显弱于三个中心训练基线。其主要困难仍是 Shirt 等相似上装，以及极端位置下被裁剪的输入。

### 8.2 现有局限

1. **补充消融使用三个随机种子。**其重复次数少于六组主实验，因此很小的均值差异不宜解释为稳定排序。
2. **边缘裁剪仍构成混杂因素。**等半径对照控制了位移距离，但两组坐标的方向构成和实际可见前景比例仍有差异。

3. **消融范围有限**。位置编码实验只覆盖 Center 训练的小型 ViT；E6 也没有单独分离卷积 stem 与 Mean Pooling 的影响。
4. **早停依据偏向中心**。验证集使用 Center 协议，可能优先选择中心准确率较好的检查点，而不是网格或复合扰动最稳定的检查点。
5. **训练预算有限**。CPU 配置采用 7 像素 patch、64 维 embedding、2 层 Encoder 和最多 12 个 epoch，足够完成课程项目的比较，但没有探索更大 ViT 或更长训练的上限。
6. **分析指标仍不完整**。Attention Rollout 只提供定性观察；效率实验也未覆盖峰值内存、训练吞吐量和 FLOPs。

### 8.3 后续可开展实验

后续可以把两个补充消融扩展到五个随机种子，并在相同增强下分别比较 CLS 与 Mean Pooling，以及有无卷积 stem。数据方面还可进一步控制移动方向与可见像素比例，以区分位置变化和信息缺失；模型选择则可同时参考 Center 与扰动验证准确率。

## 9 成员贡献

贡献比例按小组协商结果分配，共计 100%。

表 14: 成员贡献记录

| 姓名  | 学号         | 主要分工                 | 贡献比例 |
|-----|------------|----------------------|------|
| 李怿凡 | 3240103379 | 实验流程搭建；算法优化、可视化与报告撰写 | 27%  |
| 李建树 | 3230101228 | 项目框架搭建、基础算法编写        | 26%  |
| 龙官震 | 3250105720 | 实验多种子流程优化更新          | 26%  |
| 朱云麟 | 3250102363 | 优化报告                 | 21%  |

### 9.1 项目仓库

项目代码、配置文件、运行脚本与报告源文件统一保存在以下仓库：

**GitHub Repository**

[github.com/GuChL9/PV-FashionViT](https://github.com/GuChL9/PV-FashionViT)

## 参考文献

- [1] Han Xiao, Kashif Rasul, and Roland Vollgraf. Fashion-MNIST: a Novel Image Dataset for Benchmarking Machine Learning Algorithms. *arXiv preprint arXiv:1708.07747*, 2017.
- [2] Ashish Vaswani et al. Attention Is All You Need. In *Advances in Neural Information Processing Systems*, 2017.
- [3] Alexey Dosovitskiy et al. An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale. In *International Conference on Learning Representations*, 2021.