

PV-FashionViT：基于 Transformer 的位置可变 FashionMNIST 图像分类

[待填写：课程名称]

[待填写：学院/专业]

姓名	学号	GitHub 用户名	主要贡献
[待填写：成员 1]	[待填写：学号]	[待填写：用户名]	[待填写：贡献]
[待填写：成员 2]	[待填写：学号]	[待填写：用户名]	[待填写：贡献]
[待填写：成员 3]	[待填写：学号]	[待填写：用户名]	[待填写：贡献]
[待填写：成员 4]	[待填写：学号]	[待填写：用户名]	[待填写：贡献]

[待填写：提交日期]

摘要

标准 FashionMNIST 的服饰主体大多位于图像中央，常规测试准确率因而难以反映模型面对位置变化时的稳定性。本项目将原始 28×28 灰度图像放入 56×56 画布，并施加可控平移、最大 45° 的双向旋转和随机擦除。由此构造的 PV-FashionMNIST 支持中心、小幅平移、大幅平移、 7×7 位置网格、随机旋转和固定角度扫描等评估协议。在统一的 CPU 训练预算下，项目比较了 MLP、CNN、带可学习绝对位置编码的 Tiny ViT，以及依次加入复合增强、Mean Pooling 和卷积 stem 的三种 ViT 变体。

实验显示，中心准确率不能替代位置鲁棒性评价。CNN 的 Center Accuracy 达到 90.79%，但 Grid Accuracy 仅为 13.36%；ViT-AbsPos 的 Grid Accuracy 为 22.14%，虽高于另外两种中心训练基线，仍存在明显的中心高值区。扩大训练位置与角度分布后，ViT-Aug 和 ViT-MeanPool 的网格表现分别提升至 62.29% 和 66.20%。加入卷积 stem 的 HybridConv-ViT 取得 80.99% 的 Grid Accuracy，49 个位置的准确率落在 78.15%–82.65% 之间；其七个固定角度的平均准确率为 80.53%。位置热力图、角度扇形图、逐类准确率、混淆矩阵和错误样本进一步说明：训练分布覆盖是缓解中心偏置的首要因素，局部卷积特征有助于提升小图像任务中的整体稳定性，但边缘裁剪和相似服饰类别仍构成主要困难。项目最终形成了一套从数据构造、模型训练、鲁棒性评估到可视化分析的可复现工程流程。

关键词：位置可变性；FashionMNIST；Vision Transformer；鲁棒性评估；数据增强；可视化分析

目录

1	项目背景与问题定义	1
1.1	项目目标	1
1.2	探索路线	1
1.3	主要完成内容	2
2	PV-FashionMNIST 数据集构造	2
2.1	从中心分类到位置可变分类	2
2.2	数据划分与随机性控制	3
2.3	平移协议	3
2.4	旋转与复合增强	3
2.5	数据构造可视化	4
3	模型设计与改进思路	5
3.1	MLP：没有空间结构的参照	6
3.2	CNN：局部连接与权值共享基线	7
3.3	Tiny ViT：全局交互与绝对位置依赖	7
3.4	第一步改进：扩大训练分布	8
3.5	第二步改进：从 CLS 到 Mean Pooling	9
3.6	第三步改进：HybridConv-ViT	9
4	工程实现与训练闭环	10
4.1	配置驱动的运行流程	10
4.2	训练设置	10
4.3	Checkpoint 与日志	11
4.4	评估协议与指标	11
4.5	可复现运行顺序	11
5	实验设计与探索过程	12
5.1	六组主实验	12
5.2	阶段一：中心基线是否可靠	12
5.3	阶段二：先处理数据分布	12
5.4	阶段三：聚合方式是否重要	13
5.5	阶段四：加入局部视觉先验	13

5.6	评价证据链	13
6	实验结果与量化分析	14
6.1	主结果：中心高分不等于位置鲁棒	14
6.2	从增强到 Hybrid 的逐步变化	15
6.3	固定角度扫描的量化结果	16
6.4	类别层面的困难并未消失	17
6.5	对研究问题的阶段性回答	18
7	可视化与误差分析	18
7.1	训练曲线：增强任务更难，但中心验证并非最终目标	18
7.2	位置网格：从中心峰值到平坦响应	19
7.3	角度扇形图：观察方向、幅度与平均水平	20
7.4	逐类热力图与混淆结构	20
7.5	Attention Rollout：只作行为观察	22
8	总结、局限与后续工作	25
8.1	主要结论	25
8.2	项目价值	25
8.3	当前局限	26
8.4	后续实验优先级	26
9	成员贡献	27

1 项目背景与问题定义

在真实图像中，目标通常不会始终位于画面中心。衣物照片会受到构图习惯、拍摄角度和遮挡影响，同一件衣物可能出现在角落，也可能只保留部分轮廓。如果训练数据长期保持居中，模型就可能把“中心区域出现前景”当作一种稳定线索。此时，原始测试集上的高准确率既包含类别识别能力，也包含训练分布与测试分布高度一致带来的便利；仅凭这一数字，很难判断模型是否真正学到了可以随目标移动的视觉特征。

FashionMNIST 包含十类 28×28 灰度服饰图像 [1]，规模适中、类别清晰，适合在有限算力下反复开展控制实验。它的主体位置相对固定，恰好为研究位置偏置提供了一个简洁起点。另一方面，Shirt、T-shirt/top、Pullover 和 Coat 等类别外形接近，当图像在边缘发生截断时，完整轮廓消失，模型会更依赖局部纹理，这使数据集同时具备可控性和一定的分析价值。

Transformer 通过自注意力在序列元素之间建立全局联系 [2]，Vision Transformer 则把图像划分为 patch 序列进行建模 [3]。全局交互并不自动等价于位置不变性：patch 仍会与位置编码结合，训练数据也会决定模型看到哪些空间分布。因此，本项目不把“ViT 是否优于 CNN”设为预定结论，而是让 MLP、CNN、普通 ViT 和逐步改进的 ViT 在同一套位置与角度协议下接受检验。

1.1 项目目标

项目的目标不是再实现一个普通的 FashionMNIST 分类器，而是把中心分类任务改写为可测量的位置鲁棒性问题。围绕这一主线，需要回答三个问题：

1. 当训练图像保持居中而测试目标发生平移或旋转时，分类性能会下降到什么程度？中心准确率能否代表真实的鲁棒性？
2. MLP、CNN 和带可学习绝对位置编码的 Tiny ViT 会呈现怎样不同的空间响应？ViT 的全局交互是否足以抵消中心训练分布带来的偏置？
3. 扩大训练期的位置和角度覆盖、改变 token 聚合方式、加入卷积 stem，能否让准确率在位置网格和角度区间上更加平坦？

1.2 探索路线

实验没有从最终模型直接开始，而是按问题逐层推进。第一阶段使用中心训练的 MLP、CNN 和 ViT-AbsPos 建立参照，观察不同空间归纳偏置在分布外位置上的表现。第二阶段保持 ViT 主体结构不变，只把训练数据改为随机平移、 $\pm 45^\circ$ 旋转和随机擦除，以判断数据覆盖本身能解决多少问题。第三阶段将 CLS token 改为 Mean Pooling，考察聚合方式是否影响不同位置证据的整合。最后，在 Mean Pooling ViT

前加入轻量卷积 stem，观察局部边缘和纹理提取能否进一步改善小尺寸图像上的稳定性。

在最初的平移协议之外，项目后续补充了旋转维度。随机旋转和“平移 + 旋转”用于衡量连续扰动下的总体表现， -45° 至 45° 的七点固定角度扫描则用于观察退化曲线是否对称、极端角度是否形成新的失效区域。这样，报告中的结论不再只依赖单个准确率，而由位置网格、角度扇形图、逐类指标和错误样本共同支撑。




图 1: 项目探索主线。数据扰动、模型对照和可视化证据围绕“位置可变性”逐层展开。

1.3 主要完成内容

- 实现可复现的 PV-FashionMNIST，统一记录 dx 、 dy 、angle 和 scale，并使随机参数随 epoch 更新；
- 实现 MLP、CNN、Tiny ViT 和 HybridConv-ViT，通过 YAML 继承管理 CPU 与 GPU 配置，并组织六组正式实验；
- 建立 Center、Small Shift、Large Shift、Grid、Rotation 和 Shift+Rotation 评估协议，输出 Robust Drop、Rotation Drop、逐类准确率和混淆矩阵；
- 将数据构造、训练曲线、位置网格、角度响应、错误样本和 attention rollout 整理为可自动重建的报告资产；
- 保存 best/last checkpoint、完整配置、逐轮日志和逐样本预测，使训练、测试与报告汇总可以分阶段复现。

2 PV-FashionMNIST 数据集构造

2.1 从中心分类到位置可变分类

原始 FashionMNIST 样本是单通道 28×28 图像。PV-FashionMNIST 不改变类别标签，而是先对前景进行可选旋转，再把它粘贴到 56×56 的全零画布。以居中位置为原点， $dx > 0$ 表示向右移动， $dy > 0$ 表示向下移动。模型输入因此统一为 $[1, 56, 56]$ ，输出仍是十类 logits。

这个构造把类别内容与空间位置分开：对同一个原始样本，只需改变 (dx, dy) 或 angle，就能得到一组内容相同而扰动强度不同的测试输入。与直接使用随机增强相

比，可记录的元数据使后续按坐标和角度聚合准确率成为可能。每次取样返回

$$(\text{image}, \text{label}, \text{meta}), \quad \text{meta} = \{dx, dy, \text{angle}, \text{scale}\}.$$

2.2 数据划分与随机性控制

FashionMNIST 官方训练集包含 60,000 张图像，项目按固定随机种子 42 划分为 54,000 张训练样本和 6,000 张验证样本；官方 10,000 张测试图像只用于最终评估。划分索引固定，避免模型之间因验证样本不同而产生额外差异。

训练期随机参数由 seed、epoch 和样本索引共同生成。这样做有两个目的：同一配置重新运行时可以复现；训练样本又不会在所有 epoch 中停留在同一位置和角度。训练循环在每个 epoch 开始时更新数据集状态，而验证集和测试集固定在 epoch 0。随机性不依赖 DataLoader 的 worker 调度，因此切换单进程或多进程加载不会改变某个样本的增强参数。

2.3 平移协议

项目把位置变化划分为四种强度：

- **Center**: 固定使用 $(dx, dy) = (0, 0)$ ，对应原始中心分布；
- **Small Shift**: dx, dy 分别在 $[-8, 8]$ 内均匀采样，主体仍大多完整可见；
- **Large Shift**: dx, dy 分别在 $[-18, 18]$ 内均匀采样，包含明显边缘位置；
- **Grid Shift**: $dx, dy \in \{-18, -12, -6, 0, 6, 12, 18\}$ ，共形成 49 个固定位置，每个位置都评估完整测试集。

28 像素前景在 56 像素画布中无裁剪移动的上限为 14 像素。因此当 $|dx|$ 或 $|dy| > 14$ 时，部分前景会越过画布边界。项目没有把越界区域缩回画面，而是按真实粘贴结果裁剪。这使 Large Shift 同时包含位置分布变化和可见信息减少。它提高了极端条件的难度，也意味着后续不能把所有性能下降都简单归因于“缺少平移不变性”。

2.4 旋转与复合增强

在平移实验初步建立后，数据协议进一步加入旋转。Rotation 模式把前景保持在中心，在 $[-45^\circ, 45^\circ]$ 连续采样角度；Shift+Rotation 则同时在 $[-18, 18]$ 内采样平移，并在相同角度范围内旋转。旋转首先作用于原始 28×28 前景，采用双线性插值和零填充，之后再粘贴到大画布。该顺序避免围绕整张 56×56 画布旋转而产生与目标无关的大范围位移。

增强模型的训练数据采用 Shift+Rotation，并以 0.25 的概率在画布上执行随机擦除。缩放参数仍作为数据集接口保留，但本轮正式实验不额外混入缩放，以便把主要变化集中在平移和旋转。除了连续随机角度，测试阶段还固定评估

$$\{-45^\circ, -30^\circ, -15^\circ, 0^\circ, 15^\circ, 30^\circ, 45^\circ\},$$

从而得到可解释的角度响应，而不是只保留一次随机平均。

2.5 数据构造可视化

图2从同一批类别出发，依次展示原始图像、居中画布、随机平移、纯旋转和 Shift+Rotation。它直观呈现了项目真正改变的变量：前景类别保持不变，空间位置和朝向发生变化。




图 2: 原始 FashionMNIST 与 PV-FashionMNIST 的五种输入形式。每一列保持同一类别，行间只改变画布、位置和旋转策略。

图3把同一个样本放到九个典型坐标。中心位置保留完整轮廓，四个角落则出现不同方向的截断，这也是后续网格热力图出现边缘退化的重要数据原因。




图 3: 同一测试样本在九个典型 (dx, dy) 位置下的外观。极端位置既改变坐标，也减少了可见区域。

图4固定位置，只改变输入角度。 $\pm 45^\circ$ 下仍能辨认主体，但轮廓方向和插值后的局部像素已经与中心训练样本明显不同。位置九宫格与角度序列分别隔离了两类扰动，为后续空间和角度分析提供参照。




图 4: 同一测试样本在七个固定旋转角度下的输入变化。旋转范围由 -45° 延伸至 45° 。

3 模型设计与改进思路

六组模型都接收 $[B, 1, 56, 56]$ 输入并输出十类 logits。模型规模控制在 CPU 可以完成多组实验的范围内，重点不是堆叠参数，而是比较不同空间归纳偏置、训练分布和 token 聚合方式。表1给出本轮配置下的可训练参数量。

表 1: 模型规模与主要结构差异

模型	参数量	位置编码	聚合方式	卷积 stem
MLP	805,642	–	–	否
CNN	1,625,866	–	–	两层卷积主体
ViT-AbsPos / ViT-Aug	75,146	Learnable	CLS	否
ViT-MeanPool	75,018	Learnable	Mean	否
HybridConv-ViT	291,402	Learnable	Mean	是

图5把六组实验的关系压缩为两条线索：E1–E3 使用相同中心训练分布比较三类基础架构；E3–E6 则沿 ViT 路线依次扩大训练分布、改变聚合方式并加入卷积 stem。后者是一条逐步改进链，而不是六个互不相关的模型。




图 5: 六组模型的对照关系与 ViT 改进路径。上方比较基础架构，下方表示从 E3 到 E6 的连续改进。

3.1 MLP：没有空间结构的参照

MLP 将 56×56 输入直接展平成 3,136 维向量，经过 256 维隐藏层、ReLU、Dropout 和十类线性分类头。展平以后，每个像素坐标对应独立的输入权重，同一轮廓平移后会激活完全不同的一组连接。它的作用不是争取最高成绩，而是提供一个几乎不具备二维局部归纳偏置的下界参照。如果连 MLP 都能适应位置变化，说明任务本身过于容易；反之，它的退化模式可以帮助判断训练分布偏置有多强。

```
1 class MLPClassifier(nn.Module):
2     def __init__(self, img_size=56, hidden_dim=256,
3                 num_classes=10, dropout=0.1):
4         super().__init__()
5         self.net = nn.Sequential(
6             nn.Flatten(),
7             nn.Linear(img_size * img_size, hidden_dim),
8             nn.ReLU(inplace=True),
9             nn.Dropout(dropout),
```

```
10         nn.Linear(hidden_dim, num_classes),
11     )
12
13     def forward(self, x):
14         return self.net(x)
```

Listing 1: MLP 基线的核心结构。输入被直接展平后完成两层线性分类。

3.2 CNN：局部连接与权值共享基线

CNN 使用两组 “ 3×3 Conv-ReLU-MaxPool”，通道数由 1 增至 32、再增至 64，之后连接 128 维全连接层和分类头。卷积核在不同坐标共享参数，因此相同局部纹理移动后仍能产生相似响应；池化也为小范围平移提供一定容忍度。不过，后端全连接层仍接收固定位置的特征图，极端平移和裁剪也会改变可见内容，所以 CNN 并不具备严格的平移不变性。它是本项目的重要强基线：ViT 的结果只有放在 CNN 旁边，才能判断全局 token 建模是否真正带来额外价值。

```
1 self.features = nn.Sequential(
2     nn.Conv2d(1, 32, 3, padding=1), nn.ReLU(),
3     nn.MaxPool2d(2),
4     nn.Conv2d(32, 64, 3, padding=1), nn.ReLU(),
5     nn.MaxPool2d(2),
6 )
7 self.classifier = nn.Sequential(
8     nn.Flatten(),
9     nn.Linear(64 * 14 * 14, 128), nn.ReLU(),
10    nn.Dropout(0.1), nn.Linear(128, 10),
11 )
12
13 def forward(self, x):
14     return self.classifier(self.features(x))
```

Listing 2: CNN 基线的特征提取与分类路径。卷积共享和池化构成其主要空间先验。

3.3 Tiny ViT：全局交互与绝对位置依赖

Tiny ViT 使用步长和核大小均为 7 的卷积完成 patch embedding，将 56×56 图像划分为 $8 \times 8 = 64$ 个 token，每个 token 维度为 64。序列经过 2 层 Transformer Encoder，每层包含 4 头自注意力和扩展比例为 2 的前馈网络。ViT-AbsPos 在序列前加入一个可学习 CLS token，并为所有 token 叠加可学习绝对位置编码，最后使用 CLS 输出进行分类。

自注意力允许任意 patch 交换信息，但 token 在进入 Encoder 前已经与固定网

格坐标绑定。可学习绝对位置编码能够帮助模型区分“上方”和“下方”，同时也可能在中心训练数据上形成强位置先验。因此，ViT-AbsPos 的实验目的不是证明绝对位置编码一定有害，而是观察它在训练位置单一时会呈现怎样的空间响应。

```

1 def forward_features(self, x):
2     # [B, 1, 56, 56] -> [B, 64, embed_dim]
3     x = self.patch_embed(x)
4     if self.cls_token is not None:
5         cls = self.cls_token.expand(x.shape[0], -1, -1)
6         x = torch.cat((cls, x), dim=1)
7
8     x = self.encoder(x + self.pos_embed)
9     x = self.norm(x)
10    if self.pooling == "cls":
11        return x[:, 0]
12    return x.mean(dim=1)
13
14 def forward(self, x):
15    return self.head(self.forward_features(x))

```

Listing 3: Tiny ViT 的 patch 序列构造、位置编码和两种聚合分支。

代码3同时服务于三个正式模型。ViT-AbsPos 使用 Center 数据和 CLS 分支；ViT-Aug 不修改网络代码，只通过 YAML 把训练模式切换为 Shift+Rotation 并打开随机擦除；ViT-MeanPool 再把 pooling 从 cls 改为 mean。这种复用避免为相近变体复制三份模型实现。

项目还实现了二维 Sin-Cos 位置编码。它把横纵坐标映射为多频率正弦和余弦分量，位置之间具有连续的解析关系，不需要为每个格点单独学习向量。Sin-Cos 仍然表达绝对坐标，本身不保证平移或旋转不变；它适合与 Learnable 版本进行位置编码消融。由于本轮六组正式实验尚未训练该配置，Sin-Cos 只保留为后续入口，不进入当前主结果，也不据此作性能结论。

3.4 第一步改进：扩大训练分布

ViT-Aug 保持 ViT-AbsPos 的模型结构不变，把训练数据从中心分布改为平移与旋转复合分布，并加入概率为 0.25 的随机擦除。这个阶段优先处理数据问题：如果训练期间从未看到边缘位置或倾斜轮廓，再复杂的结构也很难凭空获得对应鲁棒性。通过保持 75,146 个参数不变，E3 与 E4 的差异主要反映训练分布变化，但随机擦除也同时加入，因此仍不能把全部提升只归因于旋转或平移中的某一项。

旋转范围最终设置为 $[-45^\circ, 45^\circ]$ 。这一范围明显强于最初的轻微角度扰动，能够覆盖肉眼可见的朝向变化；同时没有扩展到倒置服饰，以免任务语义发生不必要改变。

3.5 第二步改进：从 CLS 到 Mean Pooling

ViT-MeanPool 删除 CLS token，对 64 个 patch token 的 Encoder 输出求平均，再送入分类头。其余 ViT 结构、位置编码和训练增强与 ViT-Aug 保持一致，因此 E4 与 E5 是六组实验中相对清晰的一组结构对照。

CLS token 是固定的全局信息汇聚点，分类结果取决于注意力层如何把各位置证据传递给它；Mean Pooling 则让每个 patch token 直接参与最终表示，更接近对整张画布上的证据平均投票。该设计不保证一定提升准确率，但可以检验聚合方式是否影响位置分布变化下的稳定性。

3.6 第三步改进：HybridConv-ViT

HybridConv-ViT 在 patch embedding 前增加两个带 padding 的 3×3 卷积层，通道数依次为 32 和 64，再将卷积特征投影成 Transformer token。后续 Encoder、可学习位置编码和 Mean Pooling 与前一阶段保持同一思路。

```
1 self.stem = nn.Sequential(  
2     nn.Conv2d(1, 32, 3, padding=1), nn.ReLU(),  
3     nn.Conv2d(32, 64, 3, padding=1), nn.ReLU(),  
4 )  
5 self.patch_embed = nn.Conv2d(  
6     64, embed_dim, kernel_size=patch_size,  
7     stride=patch_size,  
8 )  
9  
10 def forward(self, x):  
11     x = self.patch_embed(self.stem(x))  
12     x = x.flatten(2).transpose(1, 2)  
13     x = self.norm(self.encoder(x + self.pos_embed))  
14     pooled = x.mean(dim=1)  
15     return self.head(pooled)
```

Listing 4: HybridConv-ViT 的卷积 stem 与 Transformer 聚合核心。

这一步针对 FashionMNIST 的数据特点：灰度图像尺寸小，类别判断高度依赖边缘、鞋底形状、袖口和衣身轮廓。纯 ViT 需要从有限样本中同时学习局部模式和全局关系，而卷积 stem 预先提供局部连接与权值共享，再由 Transformer 组合远距离信息。Hybrid 的参数量增至 291,402，但仍明显小于两个传统基线。需要注意的是，E6 相对 E3 同时改变了增强、pooling 和 stem，因此它代表一个组合方案；卷积 stem 的独立贡献仍需更严格的控制实验确认。

4 工程实现与训练闭环

4.1 配置驱动的运行流程

项目以 `src/main.py` 作为统一入口。一次正式运行依次完成配置继承、随机种子设置、数据集构建、模型初始化、训练与验证、checkpoint 保存以及多协议测试。公共参数写在 `configs/base.yaml`，模型配置只覆盖 run name、训练模式和结构差异，减少多份 YAML 之间的隐性偏差。

每次实验写入独立目录 `outputs/<run_name>/`，其中包含 `checkpoints/`、`logs/`、`tables/` 和 `figures/`。训练和耗时较长的 49 点网格测试被拆分：第一阶段批量训练六个模型并完成基础评估，第二阶段加载各自的 `best.pt` 执行位置网格和固定角度扫描，最后由 `analyze_results.py` 从 run 目录重建跨模型表格和报告图片。训练、评估和报告生成因此可以独立重跑，不必为了修改一张图再次训练模型。




图 6: 主训练与测试流水线。耗时评估与训练解耦，但所有结果都追溯到同一最佳 checkpoint。

4.2 训练设置

六组 CPU 实验使用 batch size 64、单进程 DataLoader 和随机种子 42。优化器为 AdamW，初始学习率 3×10^{-4} ，weight decay 为 0.05；CosineAnnealing scheduler 在训练期间逐步降低学习率。损失函数采用带 0.1 label smoothing 的交叉熵，梯度范数裁剪阈值为 1.0。

每组最多训练 12 个 epoch。至少完成 5 个 epoch 后，如果验证准确率连续 3 轮没有超过当前最佳值 0.0005，则触发早停。ViT-Aug 在本轮于 epoch 7 达到其最佳验证准确率，随后三轮没有满足最小改进要求，因此在 epoch 10 停止；其余正式模型运行到 epoch 12。报告训练图只读取每个 run 最新的一段连续 epoch，旧训练日志不会再被连接到新曲线。

默认验证集采用 Center 协议。这使早停标准稳定、计算开销较低，但也带来一

个值得说明的限制：增强模型的选择依据仍偏向中心位置，而不是 Grid Accuracy 或 Shift+Rotation Accuracy。更严格的后续实验可以增加复合扰动验证集，或同时监控中心准确率和鲁棒性指标。

4.3 Checkpoint 与日志

每轮训练都保存 `last.pt`，验证准确率刷新时保存 `best.pt`。checkpoint 不只包含模型权重，还包括优化器、scheduler、当前 epoch、最佳验证准确率和完整配置。最终测试始终重新加载 `best.pt`，保证报告指标对应验证阶段选择出的同一模型状态。

日志逐轮记录 train loss、train accuracy、validation loss、validation accuracy、learning rate 和 epoch time。正式重新训练开始时，当前 run 的旧 history 会被清空，避免多次运行的数据拼接成错误曲线；smoke run 使用独立的 `_smoke` 目录，也不会写入正式汇总表。

4.4 评估协议与指标

基础评估在完整官方测试集上分别构造 Center、Small Shift、Large Shift、Rotation 和 Shift+Rotation 数据。Rotation 表示居中前景在 $[-45^\circ, 45^\circ]$ 连续随机旋转；Shift+Rotation 同时随机采样位置和角度。固定位置网格则对 49 个坐标各评估一次完整测试集，固定角度扫描对七个角度分别评估完整测试集。

除 Accuracy 外，项目定义

$$\text{Robust Drop} = \text{Center Accuracy} - \text{Large Shift Accuracy}, \quad (1)$$

$$\text{Rotation Drop} = \text{Center Accuracy} - \text{Rotation Accuracy}. \quad (2)$$

二者均以百分点表示。正值越大，说明模型从中心分布转移到扰动分布时损失越明显；小幅负值并不表示扰动提高了模型能力，而通常说明增强模型在不同条件下的性能接近，随机测试采样和训练分布差异造成了数个百分点波动。

Grid Accuracy 是 49 个位置准确率的宏平均。项目同时保留网格最小值和最大值用于分析空间平坦性，但主表仍使用平均值，以便与指导文件中的核心口径一致。逐类准确率和混淆矩阵基于 Large Shift 预测统计，逐样本结果还记录 dx 、 dy 和 $angle$ ，供错误样本与可视化脚本追溯。

4.5 可复现运行顺序

在 Windows PowerShell 中，正式流程由以下命令完成：

```
conda activate pv-vit
python src/visualize_data.py
```



```
.\scripts\run_all_experiments.ps1
.\scripts\eval_all_grid.ps1
python src/visualize_attention_comparison.py
```

其中 `eval_all_grid.ps1` 在六组网格和角度评估完成后自动执行结果汇总。报告表格不依赖手工抄录，而是由每个 run 的 `evaluation.json`、网格 CSV 和角度 CSV 重建，减少旧结果混入新报告的风险。

5 实验设计与探索过程

5.1 六组主实验

表2不是简单的模型排行榜，而是对应四个连续问题。E1–E3 先建立中心训练基线；E4 检查扩大训练分布的效果；E5 改变 token 聚合方式；E6 组合局部卷积特征与 Transformer。所有模型使用同一数据划分、优化器和评估协议。

表 2: 主实验矩阵及各实验回答的问题

编号	模型	训练分布	关键设置	主要问题
E1	MLP	Center	展平输入	缺少空间结构时位置退化有多明显？
E2	CNN	Center	局部卷积与池化	权值共享能否自然抵抗大幅平移？
E3	ViT-AbsPos	Center	Learnable Pos + CLS	全局交互是否仍会学习中心偏置？
E4	ViT-Aug	Shift+Rotation	CLS + Random Erasing	只扩大训练分布能改善多少？
E5	ViT-MeanPool	Shift+Rotation	Mean Pooling	聚合方式是否改善稳定性？
E6	HybridConv-ViT	Shift+Rotation	Conv Stem + Mean	局部归纳偏置能否继续提升？

5.2 阶段一：中心基线是否可靠

最先需要验证的不是某个改进结构，而是原始中心测试是否掩盖问题。E1–E3 的训练图像始终位于中心，测试时逐步扩大平移幅度。如果 Center Accuracy 保持较高而 Grid Accuracy 大幅下降，就能直接说明“会分类”和“能适应位置变化”是两个不同目标。

三种基线覆盖了不同空间假设：MLP 基本不保留二维结构，CNN 具有局部共享，ViT-AbsPos 允许全局 token 交互但显式编码绝对坐标。它们之间的比较用于描述失效形态，而不是仅按中心准确率确定胜负。

5.3 阶段二：先处理数据分布

在确认中心偏置后，E4 保持 ViT-AbsPos 的结构和参数量不变，将训练输入改为随机平移与 $\pm 45^\circ$ 旋转，并加入随机擦除。这一阶段检验最直接的工程假设：模型

只有在训练期看过足够广的位置和角度，才可能在测试时形成平坦响应。

由于 E4 同时包含平移、旋转和擦除，它不是严格的单因素消融。选择这种组合是为了先建立一个有效的增强方案，再根据结果决定哪些因素值得拆分。固定角度扫描是后续补充的重要环节：它避免随机 Rotation Accuracy 把极端角度的下降平均掉。

5.4 阶段三：聚合方式是否重要

E5 在 E4 基础上只把 CLS token 改为 Mean Pooling。两者模型参数量和训练增强基本一致，适合观察聚合方式带来的增量。如果 Grid Accuracy、角度平均或最差位置进一步改善，可以提出“让所有 patch 直接参与表示有助于稳定性”的解释；如果差异很小，则说明主要收益可能已经来自训练分布覆盖。

5.5 阶段四：加入局部视觉先验

E6 在 E5 前加入两层卷积 stem。该阶段关注的是小型灰度图像上的局部模式：当主体被平移、旋转或截断时，袖口、鞋底、包带等局部边缘仍可能存在。卷积权值共享可以先提取这些重复出现的局部特征，再由 Transformer 整合全局关系。

E6 是组合方案而非严格的 stem 单变量实验。因此，若 Hybrid 表现最好，合理表述是“卷积 stem、Mean Pooling 与增强的组合在当前预算下最稳定”，而不是断言提升全部由卷积产生。

5.6 评价证据链

每个研究问题由不同证据回答：

- Center、Small Shift、Large Shift 和 Robust Drop 描述从原分布到随机平移分布的总体变化；
- 49 点网格热力图揭示高准确率是否只集中在画布中央，并给出最差位置；
- Rotation、Shift+Rotation 和固定角度扇形图描述朝向变化与复合扰动；
- 逐类准确率、混淆矩阵和错误样本解释平均值背后的类别与可见性差异；
- attention rollout 用于观察响应区域是否随前景移动，但不作为模型决策的因果证明。

这种设计将“现象是否存在”“改进是否有效”和“仍然在哪里失败”分开处理，避免只用一项最高 Accuracy 概括整个项目。

6 实验结果与量化分析

本节只使用六个正式 run 的最佳 checkpoint，不包含 smoke test。表3同时列出平移、旋转和复合扰动结果。由于不同指标回答的问题不同，后续分析不以单列排序代替整体判断。

6.1 主结果：中心高分不等于位置鲁棒

表 3: 不同模型的位置鲁棒性结果

Model	Center Acc	Small Shift Acc	Large Shift Acc	Rotation Acc	Shift+Rotation Acc	Grid Acc	Robust Drop	Rotation Drop
MLP	87.48%	24.50%	13.93%	44.76%	13.27%	13.62%	73.55%	42.72%
CNN	90.79%	29.40%	13.65%	50.91%	12.10%	13.36%	77.14%	39.88%
ViT-AbsPos	86.67%	32.51%	21.24%	46.16%	18.55%	22.14%	65.43%	40.51%
ViT-Aug	60.31%	63.03%	63.89%	63.66%	63.64%	62.29%	-3.58%	-3.35%
ViT-MeanPool	63.64%	67.13%	67.83%	67.35%	67.93%	66.20%	-4.19%	-3.71%
HybridConv-ViT	81.25%	81.88%	81.62%	82.45%	81.18%	80.99%	-0.37%	-1.20%

中心训练的三种基线在 Center 上均达到 86% 以上，其中 CNN 最高，为 90.79%。一旦测试分布改为 Large Shift，MLP、CNN 和 ViT-AbsPos 分别下降至 13.93%、13.65% 和 21.24%；对应 Robust Drop 为 73.55、77.14 和 65.43 个百分点。CNN 在中心位置表现最好，却拥有六组中最大的 Robust Drop。这说明局部权值共享可以支持常规分类和小范围模式提取，但不足以抵消固定中心训练、后端固定空间布局以及极端边缘裁剪的共同影响。

ViT-AbsPos 的中心准确率低于 CNN 4.12 个百分点，但 Large Shift 和 Grid Accuracy 分别高出 7.59 和 8.78 个百分点。全局 token 交互可能扩大了可利用的空间范围，不过 65.43 个百分点的 Robust Drop 仍然很大。换言之，普通 ViT 并没有因为使用自注意力就自然获得位置不变性；中心训练分布和绝对位置编码依然留下了明显偏置。

增强模型呈现出不同的取舍。ViT-Aug 的 Center Accuracy 只有 60.31%，明显低于三个中心基线，但 Large Shift、Rotation 和 Shift+Rotation Accuracy 都约为 64%。ViT-MeanPool 的对应指标进一步提高到 63.64%、67.83%、67.35% 和 67.93%。它们的 Robust Drop 和 Rotation Drop 为小幅负值，并不表示扰动让任务更容易，而是说明模型没有把能力集中在中心位置，几个测试分布之间的差异已经缩小到随机采样和分布细节可以影响符号的程度。

HybridConv-ViT 在稳定性和绝对准确率之间取得更好的平衡：Center Accuracy 为 81.25%，Large Shift 为 81.62%，Rotation 为 82.45%，Shift+Rotation 为 81.18%。它没有超过 CNN 的中心成绩，但在四类测试条件下保持在约 81%–82%，更符合本项目对“位置可变分类器”的定义。




图 7: 中心准确率与大平移鲁棒性下降。CNN 在左图最高, 却在右图下降最多, 说明两项指标不能互相替代。

6.2 从增强到 Hybrid 的逐步变化

表 4: 模型消融实验结果

Model	Augmentation	Pooling	Conv Stem	Grid Acc	Robust Drop
MLP	center	cls	No	13.62%	73.55%
CNN	center	cls	No	13.36%	77.14%
ViT-AbsPos	center	cls	No	22.14%	65.43%
ViT-Aug	shift_rotation	cls	No	62.29%	-3.58%
ViT-MeanPool	shift_rotation	mean	No	66.20%	-4.19%
HybridConv-ViT	shift_rotation	mean	Yes	80.99%	-0.37%

表4按增强、pooling 和卷积 stem 整理六组配置。E3 到 E4 的 Grid Accuracy 从 22.14% 提升至 62.29%，增加 40.15 个百分点；两者 ViT 结构相同，最显著的变化来自训练分布覆盖。这是当前实验中幅度最大的改进，也说明在位置可变任务里，先让训练集包含目标扰动通常比单纯增大模型更直接。

E4 到 E5 只改变主要聚合策略，Grid Accuracy 从 62.29% 提升到 66.20%，固定七角度平均准确率从 61.56% 提升到 65.36%。提升幅度不如数据增强阶段大，但在位置网格和角度扫描中方向一致，支持 Mean Pooling 可能让分类表示较少依赖固定 CLS 汇聚路径这一解释。由于只有单个随机种子，这一约 4 个百分点的差距仍需重复实验验证。

E5 到 E6 加入卷积 stem 后，Grid Accuracy 增加 14.79 个百分点，七角度平均增加 15.17 个百分点。Hybrid 的提升同时出现在 Center、Large Shift、Rotation 和 Shift+Rotation，说明它并非只优化某一个特定协议。结合参数规模，291,402 参数的 Hybrid 仍小于 MLP 和 CNN，结果更可能与结构先验和训练分布匹配有关，而不只是参数数量增加。




图 8: 六组模型的 49 点 Grid Accuracy。中心训练基线与增强模型之间出现明显分层, HybridConv-ViT 取得最高网格平均。

6.3 固定角度扫描的量化结果

随机 Rotation Accuracy 对 $[-45^\circ, 45^\circ]$ 连续采样后的结果取平均, 适合概括整体水平, 却可能掩盖端点失效。七个固定角度的宏平均分别为: MLP 39.50%、CNN 45.50%、ViT-AbsPos 41.97%、ViT-Aug 61.56%、ViT-MeanPool 65.36%、HybridConv-ViT 80.53%。

三个中心训练基线都在 0° 达到各自最高值, 并随绝对角度增大迅速下降。CNN 在 $+45^\circ$ 仅为 10.30%, ViT-AbsPos 在 $+45^\circ$ 为 13.01%。相比之下, ViT-Aug 七个角度落在 52.72%–66.11%, ViT-MeanPool 落在 60.13%–69.71%, Hybrid 落在 74.18%–83.98%。增强模型不仅平均值更高, 角度间波动也明显更小。正负角度并不完全对称, 当前数据不足以确定这是类别方向、插值还是训练采样造成的, 因此报告只把它作为可重复观察的现象, 不作过度机制解释。

图9使用连续随机角度协议汇总 Rotation Accuracy, 与后文逐角度扇形图形成互补。柱形图更适合快速比较模型的总体旋转表现, 而扇形图用于检查平均值是否掩盖极端角度下降。




图 9: 六组模型在连续随机旋转协议下的 Rotation Accuracy。增强与 Hybrid 模型在旋转分布上的整体表现更高。

6.4 类别层面的困难并未消失

表 5: Large Shift 条件下的类别准确率

class	MLP	CNN	ViT-AbsPos	ViT-Aug	ViT-MeanPool	HybridConv-ViT
T-shirt/top	7.90%	12.70%	21.20%	58.30%	62.60%	72.10%
Trouser	6.90%	14.70%	18.00%	83.60%	90.00%	94.10%
Pullover	1.70%	9.60%	1.40%	40.20%	59.20%	67.90%
Dress	4.50%	4.80%	7.90%	68.50%	67.70%	80.20%
Coat	1.50%	2.00%	2.40%	50.80%	49.70%	80.20%
Sandal	49.00%	47.40%	65.20%	87.60%	86.20%	92.00%
Shirt	16.60%	6.10%	11.90%	21.70%	14.50%	49.20%
Sneaker	10.30%	7.50%	13.20%	80.90%	80.90%	91.10%
Bag	37.00%	24.40%	42.90%	69.40%	82.30%	94.70%
Ankle boot	3.90%	7.30%	28.30%	77.90%	85.20%	94.70%

Large Shift 下, HybridConv-ViT 在 Trouser、Sandal、Sneaker、Bag 和 Ankle boot 上分别达到 94.10%、92.00%、91.10%、94.70% 和 94.70%, 这些类别通常具有较明确的整体轮廓或局部特征。Shirt 只有 49.20%, 是 Hybrid 最困难的类别; Pullover 为 67.90%, T-shirt/top 为 72.10%。

增强并没有以相同幅度改善所有类别。以衬衫类为例, ViT-Aug 的准确率为 21.70%, ViT-MeanPool 反而只有 14.50%, 说明聚合策略的总体收益不能直接推广到每个类别。相似上装之间需要依赖领口、袖长和衣身等完整形状, 而边缘截断恰好会破坏这些结构。类别结果因此补充了平均指标: 位置鲁棒性不仅是模型是否跟随目标移动, 也取决于移动后还剩下多少可区分类别的信息。

6.5 对研究问题的阶段性回答

第一，位置变化会显著影响分类准确率，而且影响远大于中心模型之间几个百分点的差距。第二，普通 ViT 在网格和旋转测试中略强于另外两个中心基线，但仍存在明显中心偏置，自注意力本身不能保证位置鲁棒。第三，训练分布覆盖带来最大幅度改善，Mean Pooling 提供较小但一致的增量，卷积 stem 与增强、Mean Pooling 的组合在当前实验中表现最稳定。以上判断适用于本轮单种子、CPU 小模型配置，尚不能替代多次重复和完整全因子消融。

7 可视化与误差分析

量化表格给出平均表现，可视化则用于检查平均值是否掩盖局部失效。本节依次观察训练过程、位置响应、角度响应、类别错误和注意力分布。图中结论均与对应 CSV 或预测记录相连，不把展示样本替代总体统计。

7.1 训练曲线：增强任务更难，但中心验证并非最终目标

图10显示，中心训练的 MLP、CNN 和 ViT-AbsPos 很快达到较高验证准确率，验证损失也较低。ViT-Aug 和 ViT-MeanPool 的中心验证准确率明显较低，这是因为训练样本同时经历大范围平移和旋转，模型需要把有限容量分配给更广的输入分布，而验证集仍保持居中。

HybridConv-ViT 的中心验证曲线高于另外两个增强 ViT，且损失持续下降，说明卷积 stem 在相同增强难度下改善了特征学习。ViT-Aug 在 epoch 7 达到本轮最佳验证准确率，随后三轮没有满足最小改进阈值，于 epoch 10 触发早停；因此其曲线没有 epoch 11 和 12，这是真实训练过程而非日志缺失。




图 10: 六组模型最新一次正式训练的验证准确率与验证损失。ViT-Aug 因早停只运行 10 个 epoch。

训练曲线还提示一个重要取舍：如果只根据中心验证准确率判断，增强模型似

乎不如中心基线；但位置网格显示相反结论。训练阶段和最终评价目标不完全一致，是后续可以继续改进的工程环节。

7.2 位置网格：从中心峰值到平坦响应

图11是回答“位置变化是否影响分类”的核心证据。MLP、CNN 和 ViT-AbsPos 都在 (0,0) 附近形成显著高值区，向四周移动后迅速变浅。MLP 的 49 点准确率范围为 6.10%–87.48%，CNN 为 2.49%–90.79%，ViT-AbsPos 为 5.86%–86.67%。中心测试只取到了这些分布的最高区域，因此会严重高估模型面对任意位置时的水平。

ViT-Aug 的网格范围收缩至 58.53%–65.36%，ViT-MeanPool 为 60.62%–69.84%。两张热力图不再出现突出的中心岛，说明训练期随机位置覆盖确实改变了模型的空间响应。HybridConv-ViT 的 49 点结果进一步集中在 78.15%–82.65%，最差位置与最好位置只相差 4.50 个百分点。与单个 Grid Average 相比，这个范围更直观地说明改进不是由少数容易坐标拉高平均值。




图 11: 六组模型的 7×7 位置网格准确率。横轴和纵轴分别为 dx 、 dy ，每个单元均来自完整测试集。

边缘区域的下降包含两个来源：模型可能依赖中心位置，也可能因为前景截断而缺少类别信息。增强模型在相同裁剪条件下仍明显更平坦，说明中心偏置确实可以通过训练分布缓解；但网格实验无法把位置偏置和可见信息损失完全分离，这一限制需要在结论中保留。

7.3 角度扇形图：观察方向、幅度与平均水平

图12把 -45° 到 45° 排成扇形，每个模型占一层环带，单元格数字为该固定角度下的 Accuracy。下方柱状图单独给出七个角度的平均值，避免把平均统计塞入扇形后降低可读性。

三个中心训练基线在 0° 形成深色尖峰，越靠近 $\pm 45^\circ$ 越浅。CNN 的七角度平均虽然达到 45.50%，但这是由 0° 的 90.79% 拉高；其 $+45^\circ$ 只有 10.30%。ViT-Aug 和 ViT-MeanPool 的颜色沿角度方向更均匀，Hybrid 则在所有扇区保持较深颜色。扇形图因此同时呈现了三个信息：中心峰值有多高、极端角度下降多快，以及平均准确率是否由少数角度支撑。




图 12: 固定角度扇形热力图与七角度平均准确率。扇形由左至右对应 -45° 到 45° ，颜色和数字共同表示 Accuracy。

7.4 逐类热力图与混淆结构

图13显示 Large Shift 下十个类别并没有同步改善。鞋类、包和裤子在增强模型中形成较稳定的高值区，上装类别仍较困难。尤其是 Shirt 一行在所有模型中都明显偏浅，说明整体 Grid Accuracy 的提高没有消除细粒度类别混淆。





图 13: Large Shift 条件下的逐类准确率。行列颜色用于比较类别困难度和模型改善幅度。

HybridConv-ViT 的混淆矩阵进一步给出错误方向。数量最多的非对角项是 Shirt 被预测为 Coat (252 次)，其次是 Pullover 被预测为 Coat (167 次)、T-shirt/top 被预测为 Shirt (164 次) 以及 Shirt 被预测为 T-shirt/top (115 次)。这些错误集中在轮廓相近的上装类别，符合逐类准确率的观察。鞋类也存在方向更接近的混淆，例如 Sneaker 与 Ankle boot，但数量明显少于上装内部错误。



(a) Large Shift 混淆矩阵



(b) 典型错误样本

图 14: HybridConv-ViT 在 Large Shift 下的类别混淆与错误样本。

错误样本可以分为两类。一类主体仍较完整，但类别本身相近，例如 Coat 被预测为 Dress、Pullover 或 Shirt；另一类处在 $|dx|$ 或 $|dy|$ 较大的位置，只剩局部鞋面、裤腿或衣身，模型只能根据残留纹理判断。图中也存在 Sandal 与 Sneaker、Sneaker 与 Ankle boot 的互相混淆。这说明部分失败源于类别边界，部分失败来自可见信息减少，不能全部归结为 Transformer 结构。

7.5 Attention Rollout: 只作行为观察

Attention 对照从四个角落筛选“ViT-AbsPos 分类错误、HybridConv-ViT 分类正确”的样本。图15和图16每行依次给出输入、ViT-AbsPos rollout 和 Hybrid rollout。Hybrid 的高响应通常更集中于当前前景，例如角落中的鞋面、衣身或裤腿；ViT-AbsPos 的响应有时扩散到前景外的空白区域，或者只覆盖局部边缘。



图 15: 五个边缘位置样本上的 attention rollout 对照 (一)。左至右为输入、ViT-AbsPos 和 HybridConv-ViT。




图 16: 五个边缘位置样本上的 attention rollout 对照 (二)。样本筛选记录保存在输出表格中。

这组图经过预测差异筛选，本身具有选择性；rollout 也只是注意力权重的传播结果，不等同于特征贡献或因果解释。因此，它只能与网格准确率和错误样本一起作为定性线索，不能单独证明卷积 stem 导致了某种决策机制。

8 总结、局限与后续工作

8.1 主要结论

本项目把 FashionMNIST 中默认居中的分类任务扩展为一个可控的位置与角度鲁棒性实验。PV-FashionMNIST 不改变类别标签，而是显式控制前景的 dx 、 dy 和 angle，并通过随机协议与固定网格同时评价模型。相比只报告原始测试集 Accuracy，这套流程能够区分中心识别能力、空间响应范围和复合扰动下的稳定性。

六组实验得到三点主要结论。

第一，中心准确率会明显高估中心训练模型的位置鲁棒性。CNN 的 Center Accuracy 为 90.79%，但 Grid Accuracy 只有 13.36%；ViT-AbsPos 的 Grid Accuracy 虽提高到 22.14%，49 点热力图仍表现为明显的中心峰值。自注意力允许全局信息交互，却不会自动消除训练分布和绝对坐标带来的位置依赖。

第二，扩大训练分布是当前最直接、幅度最大的改进。从 ViT-AbsPos 到 ViT-Aug，Grid Accuracy 提升 40.15 个百分点，网格图由中心高值区转为较平坦的空间分布。加入 $\pm 45^\circ$ 旋转后，固定角度测试也显示增强模型在极端方向上的下降明显减小。数据增强的价值不仅是提高某一项平均 Accuracy，更重要的是改变模型能力在位置和角度上的分配。

第三，Mean Pooling 和卷积 stem 在增强基础上继续提供增量。ViT-MeanPool 相对 ViT-Aug 在网格和角度平均上均提高约 4 个百分点；HybridConv-ViT 最终达到 80.99% Grid Accuracy，49 点范围为 78.15%–82.65%，七角度平均为 80.53%。在本轮小模型和 CPU 预算下，局部卷积特征、全局 token 建模与广覆盖训练分布的组合最为稳定。

8.2 项目价值

项目的价值不只是一项最高成绩。数据集层面，位置和角度都可复现、可记录、可逐点扫描；模型层面，传统基线和 ViT 变体形成了有解释目的的对照；工程层面，配置、checkpoint、日志、预测和报告资产可以独立重建；分析层面，主结果表、位置网格、角度扇形图、类别混淆和 attention 观察共同组成证据链。整套流程可以迁移到其他“主体位置不固定”的小型视觉任务，而不局限于 FashionMNIST。

8.3 当前局限

1. **单随机种子**。六组正式实验只运行 seed 42，约 4 个百分点的差异尚不能视为统计稳定结论。当前结果适合提出假设，不适合给出显著性判断。
2. **消融没有完全解耦**。E4 同时加入平移、旋转和随机擦除；E6 相对基础 ViT 同时包含增强、Mean Pooling 和卷积 stem。报告只能讨论组合变化，不能把全部收益归因于单一模块。
3. **边缘裁剪构成混杂因素**。 $|dx|$ 或 $|dy| > 14$ 时前景被裁剪，Large Shift 同时改变位置与可见信息。模型在角落失败不一定意味着缺少平移能力，也可能是类别证据已经丢失。
4. **早停依据偏向中心**。验证集使用 Center 协议，可能优先选择中心准确率较好的 checkpoint，而不是网格或复合扰动最稳定的 checkpoint。
5. **训练预算较小**。CPU 配置采用 7 像素 patch、64 维 embedding、2 层 Encoder 和最多 12 个 epoch，适合课程工程闭环，但不能代表更充分训练或更大 ViT 的上限。
6. **Attention 解释有限**。rollout 样本按预测差异筛选，不能代表完整测试分布；注意力高响应也不等同于因果特征重要性。

8.4 后续实验优先级

后续工作应优先补充能够澄清当前结论的实验，而不是继续堆叠模型。第一步是在 3-5 个随机种子下重复六组实验，报告均值和标准差。第二步拆分增强链：Center、只平移、平移 + 旋转、平移 + 旋转 + 擦除依次比较，明确角度和擦除各自的作用。第三步在相同增强和 Mean Pooling 下增加“无卷积 stem”的严格对照，同时补充 Learnable、Sin-Cos 和 No-Pos 三种位置编码。

对于数据协议，可以增加“无裁剪平移”测试，只在 $[-14, 14]$ 内移动前景，再与现有 Large Shift 对照，从而区分纯位置变化和信息缺失。验证阶段也可同时监控 Center Accuracy 与扰动验证准确率，或者使用二者加权指标选择 checkpoint。最后，再考虑 GPU 配置、更小 patch 和更长训练，而不是在当前证据尚未拆清之前继续增加复杂模块。

总体而言，本项目得到的最重要认识是：分类器在标准测试集上的高准确率，并不自动意味着它适应目标位置和朝向变化。只有把扰动显式构造成数据、把鲁棒性拆成可测指标，并用对照实验和可视化追踪失效区域，才能较完整地评价一个位置可变图像分类系统。

9 成员贡献

填写提示：按 Git commit、Pull Request、实验记录和报告章节如实填写，贡献比例合计为 100%。

表 6：成员贡献记录

姓名	学号	可核验贡献	比例
[待填写：成员 1]	[待填写：学号]	[待填写：提交、实验与文档]	—
[待填写：成员 2]	[待填写：学号]	[待填写：提交、实验与文档]	—
[待填写：成员 3]	[待填写：学号]	[待填写：提交、实验与文档]	—
[待填写：成员 4]	[待填写：学号]	[待填写：提交、实验与文档]	—

参考文献

- [1] Han Xiao, Kashif Rasul, and Roland Vollgraf. Fashion-mnist: a novel image dataset for benchmarking machine learning algorithms. *arXiv preprint arXiv:1708.07747*, 2017.
- [2] Ashish Vaswani et al. Attention is all you need. In *Advances in Neural Information Processing Systems*, 2017.
- [3] Alexey Dosovitskiy et al. An image is worth 16x16 words: Transformers for image recognition at scale. In *International Conference on Learning Representations*, 2021.