

PV-FashionViT：基于 Transformer 的位置可变 FashionMNIST 图像分类

人工智能工程实践

小组成员

序号	姓名	学号
1	李怿凡	3240103379
2	李建树	3230101228
3	龙官震	3250105720
4	朱云麟	3250102363

2026 年 7 月

摘要

标准 FashionMNIST 的服饰主体大多位于图像中央，常规测试准确率因而难以反映模型面对位置变化时的稳定性。本项目将原始 28×28 灰度图像放入 56×56 画布，并施加可控平移和最大 45° 的双向旋转。构造后的数据集支持中心、小幅平移、大幅平移、 7×7 位置网格、随机旋转和固定角度扫描等评估协议；随机擦除只作为增强模型的训练设置使用。在统一的 CPU 训练预算下，项目比较了 MLP、CNN、带可学习绝对位置编码的 Tiny ViT，以及依次加入复合增强、Mean Pooling 和卷积 stem 的三种 ViT 变体。

五个随机种子下的结果显示，中心准确率不能替代位置鲁棒性评价。CNN 的 Center Accuracy 均值达到 90.93%，但 Grid Accuracy 仅为 13.09%；ViT-AbsPos 的 Grid Accuracy 为 20.68%，虽高于另外两种中心训练基线，仍保留明显的中心偏置。采用平移、旋转与随机擦除组成的增强方案后，ViT-Aug 和 ViT-MeanPool 的网格表现分别提升至 63.77% 和 65.17%。加入卷积 stem 的 HybridConv-ViT 取得 81.05% 的 Grid Accuracy，并在 Center、Large Shift、Rotation 和 Shift+Rotation 等协议下维持约 81% 的准确率；其七个固定角度的平均准确率为 80.24%。跨种子汇总与随机种子 42 的位置、角度及错误可视化共同表明：面向目标扰动的增强组合带来最大性能跃升，局部卷积特征进一步改善整体稳定性，但边缘裁剪和相似服饰类别仍构成主要困难。综合这些结果，可以认为 HybridConv-ViT 已达到本项目对位置可变分类器的初步设计要求。

关键词：位置可变性；FashionMNIST；Vision Transformer；鲁棒性评估；数据增强；可视化分析

目录

1 项目背景与问题定义 1

1.1 项目目标 1

1.2 探索路线 1

1.3 主要完成内容 2

2 PV-FashionMNIST 数据集构造 2

2.1 从中心分类到位置可变分类 2

2.2 数据划分与随机性控制 2

2.3 平移协议 3

2.4 旋转与复合增强 3

2.5 数据构造可视化 4

3 模型设计与改进思路 6

3.1 MLP 基线 7

3.2 CNN 基线 8

3.3 Tiny ViT 与绝对位置 9

3.4 扩大训练分布 10

3.5 Mean Pooling 10

3.6 HybridConv-ViT 11

4 工程实现与训练闭环 11

4.1 配置驱动的运行流程 11

4.2 从分类损失到参数更新 12

4.3 训练设置 13

4.4 检查点与日志 14

4.5 评估协议与指标 15

4.6 可复现运行顺序 16

5 实验设计与探索过程 16

5.1 六组主实验 16

5.2 三层对照逻辑 16

5.3 评价安排 17

6	实验结果与量化分析	18
6.1	中心高分不等于位置鲁棒	18
6.2	从增强到 Hybrid 的逐步变化	19
6.3	固定角度扫描的量化结果	21
6.4	类别层面的困难并未消失	22
7	可视化与误差分析	23
7.1	训练过程	23
7.2	位置响应	24
7.3	无裁剪内层与可能裁剪外圈	24
7.4	角度响应	25
7.5	逐类热力图与混淆结构	26
7.6	Attention Rollout	28
8	总结、局限与后续工作	31
8.1	对研究问题的回答	31
8.2	现有局限	31
8.3	后续可开展实验	32
9	成员贡献	32
9.1	项目仓库	33

1 项目背景与问题定义

在真实图像中，目标通常不会始终位于画面中心。衣物照片会受到构图习惯、拍摄角度和遮挡影响，同一件衣物可能出现在角落，也可能只保留部分轮廓。如果训练数据长期保持居中，模型就可能把“中心区域出现前景”当作一种稳定线索。此时，原始测试集上的高准确率既包含类别识别能力，也包含训练分布与测试分布高度一致带来的便利；仅凭这一数字，很难判断模型是否真正学到了可以随目标移动的视觉特征。

FashionMNIST包含十类 28×28 灰度服饰图像 [1]，规模适中、类别清晰，适合在有限算力下反复开展控制实验。它的主体位置相对固定，恰好为研究位置偏置提供了一个简洁起点。另一方面，Shirt、T-shirt/top、Pullover 和 Coat 等类别外形接近，当图像在边缘发生截断时，完整轮廓消失，模型会更依赖局部纹理，这使数据集同时具备可控性和一定的分析价值。

Transformer 通过自注意力在序列元素之间建立全局联系 [2]，Vision Transformer 则把图像划分为 patch 序列进行建模 [3]。全局交互并不自动等价于位置不变性：patch 仍会与位置编码结合，训练数据也会决定模型看到哪些空间分布。因此，本项目不把“ViT 是否优于 CNN”设为预定结论，而是让 MLP、CNN、普通 ViT 和逐步改进的 ViT 在同一套位置与角度协议下接受检验。

1.1 项目目标

项目的目标不是再实现一个普通的 FashionMNIST 分类器，而是把中心分类任务改写为可测量的位置鲁棒性问题。围绕这一主线，需要回答三个问题：

1. 当训练图像保持居中而测试目标发生平移或旋转时，分类性能会下降到什么程度？中心准确率能否代表真实的鲁棒性？
2. MLP、CNN 和带可学习绝对位置编码的 Tiny ViT 会呈现怎样不同的空间响应？ViT 的全局交互是否足以抵消中心训练分布带来的偏置？
3. 扩大训练期的位置和角度覆盖、改变 token 聚合方式、加入卷积 stem，能否让准确率在位置网格和角度区间上更加平坦？

1.2 探索路线

探索围绕两类变量展开：先用 MLP、CNN 和 ViT-AbsPos 比较不同空间归纳偏置，再沿 ViT 路线依次改变训练扰动、token 聚合与局部卷积先验。评估端同时采用随机平移、随机旋转、49 点位置网格和七个固定角度，避免用单个中心准确率概括全部表现。各模型原理和具体对照关系分别在第 3 节和第 5 节说明，图 1 只给出总体路线。




图 1: 项目探索主线，数据扰动、模型对照和可视化证据围绕“位置可变性”逐层展开

1.3 主要完成内容

- 实现可复现的 PV-FashionMNIST，统一记录 dx 、 dy 、angle 和 scale，并使随机参数随 epoch 更新；
- 实现 MLP、CNN、Tiny ViT 和 HybridConv-ViT，通过 YAML 继承管理 CPU 与 GPU 配置，并组织六组正式实验；
- 建立 Center、Small Shift、Large Shift、Grid、Rotation 和 Shift+Rotation 评估协议，输出 Robust Drop、Rotation Drop、逐类准确率和混淆矩阵；
- 将数据构造、训练曲线、位置网格、角度响应、错误样本和 Attention Rollout 整理为可自动重建的报告资产；
- 保存 best.pt、last.pt、完整配置、逐轮日志和逐样本预测，使训练、测试与报告汇总可以分阶段复现。

2 PV-FashionMNIST 数据集构造

2.1 从中心分类到位置可变分类

原始 FashionMNIST 样本是单通道 28×28 图像。PV-FashionMNIST 不改变类别标签，而是先对前景进行可选旋转，再把它粘贴到 56×56 的全零画布。以居中位置为原点， $dx > 0$ 表示向右移动， $dy > 0$ 表示向下移动。模型输入因此统一为 $[1, 56, 56]$ ，输出仍是十类 logits。

这个构造把类别内容与空间位置分开：对同一个原始样本，只需改变 (dx, dy) 或 angle，就能得到一组内容相同而扰动强度不同的测试输入。与直接使用随机增强相比，可记录的元数据使后续按坐标和角度聚合准确率成为可能。每次取样返回

$$(\text{image}, \text{label}, \text{meta}), \quad \text{meta} = \{dx, dy, \text{angle}, \text{scale}\}.$$

2.2 数据划分与随机性控制

FashionMNIST 官方训练集包含 60,000 张图像，项目按配置中的随机种子划分为 54,000 张训练样本和 6,000 张验证样本；官方 10,000 张测试图像只用于最终评

估。同一随机种子下，六组模型使用相同划分；随机种子 42 用于代表性可视化，第 6 节主结果则汇总五个固定随机种子。这样既能保持同一随机种子下的模型对照公平，也能观察数据划分、模型初始化和增强采样共同带来的波动。

训练期随机参数由随机种子、训练轮次和样本索引共同生成。这样做有两个目的：同一配置重新运行时可以复现；训练样本又不会在所有轮次中停留在同一位置和角度。训练循环在每轮开始时更新数据集状态，而验证集和测试集固定使用第 0 轮的数据集状态。随机性不依赖 DataLoader 的 worker 调度，因此切换单进程或多进程加载不会改变某个样本的增强参数。

2.3 平移协议

项目把位置变化划分为四种强度：

- **Center**: 固定使用 $(dx, dy) = (0, 0)$ ，对应原始中心分布；
- **Small Shift**: dx, dy 分别在 $[-8, 8]$ 内按整数均匀采样，主体仍大多完整可见；
- **Large Shift**: dx, dy 分别在 $[-18, 18]$ 内按整数均匀采样，包含明显边缘位置；
- **Grid Shift**: $dx, dy \in \{-18, -12, -6, 0, 6, 12, 18\}$ ，共形成 49 个固定位置，每个位置都评估完整测试集。

28 像素前景在 56 像素画布中无裁剪移动的上限为 14 像素。因此当 $|dx|$ 或 $|dy| > 14$ 时，部分前景会越过画布边界。项目没有把越界区域缩回画面，而是按真实粘贴结果裁剪。这使 Large Shift 同时包含位置分布变化和可见信息减少。它提高了极端条件的难度，也意味着后续不能把所有性能下降都简单归因于“缺少平移不变性”。

2.4 旋转与复合增强

在平移实验初步建立后，数据协议进一步加入旋转。Rotation 模式把前景保持在中心，在 $[-45^\circ, 45^\circ]$ 连续采样角度；Shift+Rotation 则同时在 $[-18, 18]$ 内采样平移，并在相同角度范围内旋转。旋转首先作用于原始 28×28 前景，采用双线性插值和零填充，之后再粘贴到大画布。该顺序避免围绕整张 56×56 画布旋转而产生与目标无关的大范围位移。

这一实现对应一个直接的图像坐标运算。若原像素坐标为 (u, v) ，角度为 α ，则旋转和平移可合并为

$$\begin{bmatrix} u' \\ v' \\ 1 \end{bmatrix} = \begin{bmatrix} \cos \alpha & -\sin \alpha & dx \\ \sin \alpha & \cos \alpha & dy \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} u \\ v \\ 1 \end{bmatrix}.$$

程序实际采用逆向坐标映射，避免目标图出现空洞；落在非整数坐标上的灰度由相邻四个像素双线性加权得到。因而旋转不仅改变轮廓方向，也会引入轻微插值差异，而越界裁剪还会减少类别信息。这些都是后续解释角度与边缘误差时必须保留的图像处理因素。

增强模型的训练数据采用 Shift+Rotation，并以 0.25 的概率执行随机擦除：擦除区域为边长 4-10 像素的正方形，像素填充为 0。缩放参数仍作为数据集接口保留，但本轮正式实验不额外混入缩放，以便把主要变化集中在平移和旋转。除了连续随机角度，测试阶段还固定评估

$$\{-45^\circ, -30^\circ, -15^\circ, 0^\circ, 15^\circ, 30^\circ, 45^\circ\},$$

从而得到可解释的角度响应，而不是只保留一次随机平均。

2.5 数据构造可视化

图 2 从同一批类别出发，依次展示原始图像、居中画布、随机平移、纯旋转和 Shift+Rotation。它直观呈现了项目真正改变的变量：前景类别保持不变，空间位置和朝向发生变化。




图 2: 原始 FashionMNIST 与 PV-FashionMNIST 的五种输入形式

图 3 把同一个样本放到九个典型坐标。中心位置保留完整轮廓，四个角落则出现不同方向的截断，这也是后续网格热力图出现边缘退化的重要数据原因。




图 3: 同一测试样本在九个典型 (dx, dy) 位置下的外观 (极端位置可能减少了可见区域)

图 4 固定位置, 只改变输入角度。 $\pm 45^\circ$ 下仍能辨认主体, 但轮廓方向和插值后的局部像素已经与中心训练样本明显不同。位置九宫格与角度序列分别隔离了两类扰动, 为后续空间和角度分析提供参照。




图 4: 同一测试样本在七个固定旋转角度下的输入变化, 旋转范围由 -45° 延伸至 45°

除样本外观外, 还需要确认训练扰动的覆盖范围与固定评估探针之间的关系。图 5 按照配置文件对平移和角度各进行 12,000 次蒙特卡洛采样: 左图将整数均匀平移、49 个固定网格点、Small Shift 边界和无裁剪边界叠加; 右图将连续随机角度直方图与七个固定测试角度叠加。该图用于核对配置所定义的分布, 并不是从训练日志反推的经验频数, 因此不代表模型实际见过的样本数量。




图 5: 配置定义的平移与旋转采样分布，以及确定性的网格和固定角度评估探针

3 模型设计与改进思路

六组模型都接收 $[B, 1, 56, 56]$ 输入并输出十类 logits。模型规模控制在 CPU 可以完成多组实验的范围内，重点不是把网络做大，而是看清训练分布、空间结构和 token 聚合方式分别带来什么变化。表 1 把各模型的层数、宽度和参数量放在一起，后文再解释这些结构为什么可能影响位置适应能力。

表 1: 模型规模与主要结构差异

模型	主体结构	位置 / 聚合	参数量
MLP	Flatten, 隐藏层 256, ReLU	无显式空间聚合	805,642
CNN	Conv $1 \rightarrow 32 \rightarrow 64$, 两次池化, FC 128	卷积后展平	1,625,866
ViT-AbsPos/ViT-Aug	7×7 patch, 64 tokens, $d = 64$, 2 个 Encoder, 4 heads, FFN 128	Learnable Pos / CLS	75,146
ViT-MeanPool	与上行相同	Learnable Pos / Mean	75,018
HybridConv-ViT	Conv $1 \rightarrow 32 \rightarrow 64$ stem, 随后同规格 Transformer	Learnable Pos / Mean	291,402

所有模型的 dropout 均为 0.1，分类头输出 10 个 logits。三种 Tiny ViT 共享同一套 Transformer 主体： $56/7 = 8$ ，所以每张图形成 $8 \times 8 = 64$ 个视觉 token；每层

前馈网络把 64 维特征扩展到 128 维后再压回。这样设置一方面让自注意力仍能覆盖完整画布，另一方面把模型控制在约 7.5 万参数，适合本项目的多组 CPU 对照。Hybrid 只在 token 化之前增加两层 3×3 卷积，因此它仍然是小模型，而不是通过大幅增加 Transformer 深度来换取结果。

图 6 把六组实验的关系压缩为两条线索：E1-E3 使用相同中心训练分布比较三类基础架构；E3-E6 则沿 ViT 路线依次扩大训练分布、改变聚合方式并加入卷积 stem。后者是一条逐步改进链，而不是六个互不相关的模型。




图 6: 六组模型的对照关系与 ViT 改进路径

3.1 MLP 基线

MLP 将 56×56 输入直接展平成 3,136 维向量，经过 256 维隐藏层、ReLU、Dropout 和十类线性分类头。展平以后，每个像素坐标对应独立的输入权重，同一轮廓平移后会激活完全不同的一组连接。它的作用不是争取最高成绩，而是提供一个几乎不具备二维局部归纳偏置的参照。它在位置变化下的退化程度，可以帮助判断训练分布偏置有多强。

从运算上看，每个全连接层执行 $h^{(l+1)} = \phi(W^{(l)}h^{(l)} + b^{(l)})$ ：矩阵 W 对像素特征作加权组合，偏置 b 调整激活阈值，ReLU $\phi(a) = \max(0, a)$ 使网络能够形成非线性分类边界。若移除 ReLU，多层线性映射仍可合并为一个矩阵，增加层数也无法表达更复杂的类别区域。这里的 Flatten 还使 W 的每一列固定对应某个像素坐标，正是 MLP 容易依赖中心布局的原因。

```

1 class MLPClassifier(nn.Module):
2     def __init__(self, img_size=56, hidden_dim=256,
3                   num_classes=10, dropout=0.1):
4         super().__init__()
5         self.net = nn.Sequential(
6             nn.Flatten(),
7             nn.Linear(img_size * img_size, hidden_dim),
8             nn.ReLU(inplace=True),
9             nn.Dropout(dropout),

```

```

10         nn.Linear(hidden_dim, num_classes),
11     )
12
13     def forward(self, x):
14         return self.net(x)

```

Listing 1: MLP 基线的核心结构。输入被直接展平后完成两层线性分类。

代码 1 中的 Flatten 只重排元素，却删除了显式二维邻接；两个 Linear 分别实现前述 $Wh + b$ ，ReLU 提供非线性。实现最终把图像张量映射为十类 logits，实验上重点观察缺少空间共享时的退化。

3.2 CNN 基线

CNN 使用两组 “ 3×3 Conv-ReLU-MaxPool”，通道数由 1 增至 32、再增至 64，之后连接 128 维全连接层和分类头。卷积核在不同坐标共享参数，因此相同局部纹理移动后仍能产生相似响应；池化也为小范围平移提供一定容忍度。不过，后端全连接层仍接收固定位置的特征图，极端平移和裁剪也会改变可见内容，所以 CNN 并不具备严格的平移不变性。它是本项目的重要强基线：ViT 的结果只有放在 CNN 旁边，才能判断全局 token 建模是否真正带来额外价值。

对应到数学形式，输出特征 $Y_{c,i,j}$ 是局部邻域的加权和：

$$Y_{c,i,j} = \phi \left(b_c + \sum_{c'} \sum_{m,n} K_{c,c',m,n} X_{c',i+m,j+n} \right).$$

卷积核 K 不随 (i,j) 改变，因此同一袖口或鞋底边缘移动后仍由相同参数检测；Max-Pool 再保留邻域内的最强响应。这个公式解释的是平移等变和局部容忍，而不是严格不变：边界填充、裁剪以及后端全连接层仍保留位置影响。

```

1 self.features = nn.Sequential(
2     nn.Conv2d(1, 32, 3, padding=1), nn.ReLU(),
3     nn.MaxPool2d(2),
4     nn.Conv2d(32, 64, 3, padding=1), nn.ReLU(),
5     nn.MaxPool2d(2),
6 )
7 self.classifier = nn.Sequential(
8     nn.Flatten(),
9     nn.Linear(64 * 14 * 14, 128), nn.ReLU(),
10    nn.Dropout(0.1), nn.Linear(128, 10),
11 )
12
13 def forward(self, x):
14     return self.classifier(self.features(x))

```

Listing 2: CNN 基线的特征提取与分类路径。卷积共享和池化构成其主要空间先验。

代码 2 中的 Conv2d 实现上述局部加权和与权值共享，ReLU 产生非线性特征，MaxPool2d 对每个邻域取最大响应。两次池化把空间尺寸降至 14×14 ，随后全连接层完成十类判别，也解释了该模型为何只有有限的位置容忍度。

3.3 Tiny ViT 与绝对位置

Tiny ViT 使用步长和核大小均为 7 的卷积完成 patch embedding，将 56×56 图像划分为 $8 \times 8 = 64$ 个 token，每个 token 维度为 64。序列经过 2 层 Transformer Encoder，每层包含 4 头自注意力和扩展比例为 2 的前馈网络。ViT-AbsPos 在序列前加入一个可学习 CLS token，并为所有 token 叠加可学习绝对位置编码，最后使用 CLS 输出进行分类。

在每个注意力头中，token 矩阵 Z 先投影为 $Q = ZW_Q$ 、 $K = ZW_K$ 和 $V = ZW_V$ ，再计算

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right) V.$$

QK^T 给出 64 个 patch 两两之间的相关程度，softmax 将其变为信息汇聚权重，因而角落 token 可以直接利用远处 token 的信息。但该运算本身不知道二维顺序，项目必须叠加位置编码；这也解释了全局交互为何不自动带来位置不变性。

自注意力允许任意 patch 交换信息，但 token 在进入 Encoder 前已经与固定网格坐标绑定。可学习绝对位置编码能够帮助模型区分“上方”和“下方”，同时也可能在中心训练数据上形成强位置先验。因此，ViT-AbsPos 的实验目的不是证明绝对位置编码一定有害，而是观察它在训练位置单一时会呈现怎样的空间响应。

```

1 def forward_features(self, x):
2     # [B, 1, 56, 56] -> [B, 64, embed_dim]
3     x = self.patch_embed(x)
4     if self.cls_token is not None:
5         cls = self.cls_token.expand(x.shape[0], -1, -1)
6         x = torch.cat((cls, x), dim=1)
7
8     x = self.encoder(x + self.pos_embed)
9     x = self.norm(x)
10    if self.pooling == "cls":
11        return x[:, 0]
12    return x.mean(dim=1)
13
14 def forward(self, x):
15    return self.head(self.forward_features(x))

```

Listing 3: Tiny ViT 的 patch 序列构造、位置编码和两种聚合分支。

代码 3 先把图像映射为 64 个 patch token, `x + self.pos_embed` 注入坐标信息, Encoder 内部完成多头注意力和逐 token 前馈运算。最后选择 CLS 或 token 均值, 把序列归约为十类 logits; 这里真正影响实验假设的是信息交互和聚合规则, 而不是接口形状本身。

代码 3 同时服务于三个正式模型。训练模式和聚合分支均由 YAML 配置切换, 避免为相近变体复制模型实现; 三种配置的具体差异在下面依次说明。

项目还实现了二维 Sin-Cos 位置编码。它把横纵坐标映射为多频率正弦和余弦分量, 位置之间具有连续的解析关系, 不需要为每个格点单独学习向量。Sin-Cos 仍然表达绝对坐标, 本身不保证平移或旋转不变; 它适合与 Learnable 版本进行位置编码消融。由于本轮六组正式实验尚未训练该配置, Sin-Cos 只保留为后续入口, 不进入当前主结果, 也不据此作性能结论。

3.4 扩大训练分布

ViT-Aug 保持 ViT-AbsPos 的模型结构不变, 把训练数据从中心分布改为平移与旋转复合分布, 并加入概率为 0.25 的随机擦除。这个阶段优先处理数据问题: 如果训练期间从未看到边缘位置或倾斜轮廓, 再复杂的结构也很难凭空获得对应鲁棒性。通过保持 75,146 个参数不变, E3 与 E4 的差异主要反映训练分布变化, 但随机擦除也同时加入, 因此仍不能把全部提升只归因于旋转或平移中的某一项。

旋转范围最终设置为 $[-45^\circ, 45^\circ]$ 。这一范围明显强于最初的轻微角度扰动, 能够覆盖肉眼可见的朝向变化; 同时没有扩展到倒置服饰, 以免任务语义发生不必要改变。

3.5 Mean Pooling

ViT-MeanPool 删除 CLS token, 对 64 个 patch token 的 Encoder 输出求平均, 再送入分类头。其余 ViT 结构、位置编码和训练增强与 ViT-Aug 保持一致, 因此 E4 与 E5 是六组实验中相对清晰的一组结构对照。

CLS token 是固定的全局信息汇聚点, 分类结果取决于注意力层如何把各位置证据传递给它; Mean Pooling 则让每个 patch token 直接参与最终表示, 更接近对整张画布上的证据平均投票。该设计不保证一定提升准确率, 但可以检验聚合方式是否影响位置分布变化下的稳定性。

3.6 HybridConv-ViT

HybridConv-ViT 在 patch embedding 前增加两个带 padding 的 3×3 卷积层，通道数依次为 32 和 64，再将卷积特征投影成 Transformer token。后续 Encoder、可学习位置编码和 Mean Pooling 与前一阶段保持同一思路。

```
1 self.stem = nn.Sequential(  
2     nn.Conv2d(1, 32, 3, padding=1), nn.ReLU(),  
3     nn.Conv2d(32, 64, 3, padding=1), nn.ReLU(),  
4 )  
5 self.patch_embed = nn.Conv2d(  
6     64, embed_dim, kernel_size=patch_size,  
7     stride=patch_size,  
8 )  
9  
10 def forward(self, x):  
11     x = self.patch_embed(self.stem(x))  
12     x = x.flatten(2).transpose(1, 2)  
13     x = self.norm(self.encoder(x + self.pos_embed))  
14     pooled = x.mean(dim=1)  
15     return self.head(pooled)
```

Listing 4: HybridConv-ViT 的卷积 stem 与 Transformer 聚合核心。

代码 4 先用共享卷积提取局部边缘和纹理，再把特征图投影为 token；Transformer 负责远距离关系，Mean Pooling 负责全局归约。它没有另设损失函数，而是把卷积的局部先验与注意力的全局加权组合在同一个可微分类函数中。

这一步针对 FashionMNIST 的数据特点：灰度图像尺寸小，类别判断高度依赖边缘、鞋底形状、袖口和衣身轮廓。纯 ViT 需要从有限样本中同时学习局部模式和全局关系，而卷积 stem 预先提供局部连接与权值共享，再由 Transformer 组合远距离信息。Hybrid 的参数量增至 291,402，但仍明显小于两个传统基线。需要注意的是，E6 相对 E3 同时改变了增强、pooling 和 stem，因此它代表一个组合方案；卷积 stem 的独立贡献仍需更严格的控制实验确认。

4 工程实现与训练闭环

4.1 配置驱动的运行流程

项目以 src/main.py 作为统一入口。一次正式运行依次完成配置继承、随机种子设置、数据集构建、模型初始化、训练与验证、检查点保存以及多协议测试。公共参数写在 configs/base.yaml，模型配置只覆盖 run_name、训练模式和结构差异，减少多份 YAML 之间的隐性偏差。

每次实验写入独立目录 `outputs/<run_name>/`, 其中包含 `checkpoints/`、`logs/`、`tables/` 和 `figures/`。正式流程被拆成三个阶段：首先训练六种配置在五个随机种子下的 30 个模型并完成基础评估；随后加载各自的 `best.pt`，执行耗时较长的位置网格和固定角度扫描；最后由 `analyze_results.py` 生成随机种子 42 的细节图，再由 `analyze_multiseed_results.py` 汇总五个随机种子的表格与统计图。图 7 概括了这一过程。三个阶段可以独立重跑，因此修改报告图片不需要重新训练模型。




图 7: 主训练与测试流水线，耗时评估与训练解耦，结果均追溯到对应运行的最佳检查点

4.2 从分类损失到参数更新

分类与交叉熵 对一个含 B 个样本的 batch，模型输出 logits $z_i = f_\theta(x_i) \in \mathbb{R}^{10}$ 。softmax 将任意实数映射为和为 1 的类别概率：

$$p_{i,k} = \frac{\exp(z_{i,k})}{\sum_{j=1}^{10} \exp(z_{i,j})}.$$

预测类别为 $\hat{y}_i = \arg \max_k z_{i,k}$ ；由于 softmax 保持大小顺序，对 logits 或概率取最大值结果相同。Accuracy 统计 $\hat{y}_i = y_i$ 的比例，但它是离散指标，不能直接提供平滑梯度，因此训练使用交叉熵。设 label smoothing 系数为 $\varepsilon = 0.1$ 、类别数为 $C = 10$ ，平滑目标和 batch 损失为

$$q_{i,k} = (1 - \varepsilon)\mathbf{1}[k = y_i] + \frac{\varepsilon}{C}, \quad \mathcal{L} = -\frac{1}{B} \sum_{i=1}^B \sum_{k=1}^C q_{i,k} \log p_{i,k}.$$

交叉熵对 logits 的导数具有直观形式 $\partial \mathcal{L} / \partial z_{i,k} = (p_{i,k} - q_{i,k}) / B$ ：预测概率高于目标时梯度推动对应 logit 降低，反之则推动它升高。label smoothing 不改变分类标签，而是避免模型被要求把真值概率推到绝对 1。

链式法则与反向传播 网络是多层函数复合 $z = f_L \circ \dots \circ f_1(x)$ 。链式法则把输出端误差逐层传回：

$$\delta^{(L)} = \frac{\partial \mathcal{L}}{\partial z}, \quad \delta^{(l)} = \delta^{(l+1)} \frac{\partial h^{(l+1)}}{\partial h^{(l)}}, \quad \frac{\partial \mathcal{L}}{\partial \theta_l} = \delta^{(l+1)} \frac{\partial h^{(l+1)}}{\partial \theta_l}.$$

卷积、矩阵乘法、ReLU、softmax 和 pooling 都在前向过程中记录局部运算关系，PyTorch 的自动微分据此计算向量-雅可比乘积，而不需要显式构造巨大的完整雅可比矩阵。loss.backward() 完成的正是这一反向递推。

梯度下降与小批量学习 最基本的梯度下降更新为

$$\theta_{t+1} = \theta_t - \eta \nabla_{\theta} \mathcal{L}(\theta_t),$$

其中学习率 η 控制步长。项目使用 mini-batch 梯度作为全训练集梯度的近似，使每次更新的计算量可控；AdamW 再利用梯度的一阶、二阶动量自适应各参数步长，并将 weight decay 与梯度更新分离。CosineAnnealing 随 epoch 降低学习率，梯度裁剪则在范数过大时按比例缩放，减少不稳定的大步更新。

在实现层面，训练模式启用 Dropout 等随机层；验证和测试切换到 eval() 并关闭梯度记录。二者共享同一个 f_{θ} ，区别是训练阶段更新参数，评估阶段只执行前向分类和统计指标。

```
1 model.train()
2 optimizer.zero_grad(set_to_none=True)
3 logits = model(images)           # [B, 10]
4 loss = criterion(logits, labels)  # smoothed cross entropy
5 loss.backward()                  # chain-rule gradients
6 clip_grad_norm_(model.parameters(), grad_clip)
7 optimizer.step()                 # AdamW parameter update
```

Listing 5: 一个 batch 的训练核心。代码与交叉熵、链式法则和梯度下降更新逐项对应。

代码 5 把上述数学关系压缩为一个 batch 的闭环：前向传播构造复合函数，交叉熵产生标量目标，反向传播应用链式法则，优化器沿降低损失的方向更新参数。数据增强只改变 x 的观测分布，不改变十类标签空间、损失定义或这条求导链。

4.3 训练设置

表 2 列出正式实验实际使用的训练参数。六种模型沿用同一套优化设置，结构比较时不会因为学习率或 batch size 不同而混入额外变量。

表 2: 正式实验的训练与选优参数

参数	设置	说明
运行设备	CPU, 8 个计算线程	DataLoader 使用 0 个额外 worker, 避免 Windows 多进程开销
随机种子	42、2026、3407、12345、98765	每个随机种子都重新完成数据划分、模型初始化、增强采样和随机协议测试
Batch size	训练 64, 评估 256	验证与测试不更新梯度, 可以使用更大 batch
训练轮数	最多 12 epochs	达到早停条件时可以提前结束
优化器	AdamW	初始学习率 3×10^{-4} , weight decay 0.05
学习率调度	CosineAnnealing	在最多 12 个 epoch 内逐步降低学习率
损失函数	Cross Entropy	label smoothing 0.1
梯度裁剪	范数上限 1.0	抑制偶发的过大更新
早停	最少 5 epochs, patience 3	验证准确率改进不超过 0.0005 时计为一轮未提升
选优协议	Center 验证集	保存验证准确率最高的 <code>best.pt</code>

在随机种子 42 的代表性运行中, 上述早停规则使 ViT-Aug 于第 7 轮达到最佳验证准确率, 并在第 10 轮结束训练; 其余五种配置运行到第 12 轮。因此, 训练图中 ViT-Aug 缺少第 11、12 轮并不是日志丢失。报告训练图只读取每次运行最新的一段连续日志, 避免把旧实验接到新曲线上。

验证集采用 Center 协议, 优点是简单、稳定, 也和原始 FashionMNIST 分类任务直接对应; 代价是增强模型仍按中心准确率选择检查点, 而不是按 Grid 或 Shift+Rotation 表现选优。本项目保留这一统一标准以便完成横向比较, 并把更全面的鲁棒性验证留作后续改进。

4.4 检查点与日志

每轮训练都保存 `last.pt`, 验证准确率刷新时保存 `best.pt`。检查点不只包含模型权重, 还包括优化器、学习率调度器、当前轮次、最佳验证准确率和完整配置。最终测试始终重新加载 `best.pt`, 保证报告指标对应验证阶段选择出的同一模型状态。

日志逐轮记录训练损失、训练准确率、验证损失、验证准确率、学习率和单轮耗时。正式重新训练开始时，当前运行的旧日志会被清空，避免多次运行的数据拼接成错误曲线；smoke test 使用独立的 `_smoke` 目录，也不会写入正式汇总表。

4.5 评估协议与指标

基础评估在完整官方测试集上分别构造 Center、Small Shift、Large Shift、Rotation 和 Shift+Rotation 数据。Rotation 表示居中前景在 $[-45^\circ, 45^\circ]$ 连续随机旋转；Shift+Rotation 同时随机采样位置和角度。固定位置网格则对 49 个坐标各评估一次完整测试集，固定角度扫描对七个角度分别评估完整测试集。表 3 进一步区分几种旋转指标的含义。

表 3: 旋转相关指标的采样协议与含义，连续随机指标和固定角度汇总来自不同测试构造

指标	角度与位置协议	回答的问题
Rotation Accuracy	居中位置；每个测试样本在 $[-45^\circ, 45^\circ]$ 连续采样一次角度	随机旋转分布上的总体准确率
Fixed-angle Mean	七个固定角度分别跑完整测试集，再作宏平均	各方向等权时的平均水平
Fixed-angle Worst	七个固定角度准确率的最小值	已扫描极端方向中的最弱表现
Shift+Rotation Accuracy	位置与角度同时连续随机采样	两类扰动共同出现时的总体准确率

除 Accuracy 外，项目定义

$$\text{Robust Drop} = \text{Center Accuracy} - \text{Large Shift Accuracy}, \quad (1)$$

$$\text{Rotation Drop} = \text{Center Accuracy} - \text{Rotation Accuracy}. \quad (2)$$

二者均以百分点表示。正值越大，说明模型从中心分布转移到扰动分布时损失越明显；小幅负值并不表示扰动提高了模型能力，而通常说明增强模型在不同条件下的性能接近，随机测试采样和训练分布差异造成了数个百分点波动。

Grid Accuracy 是 49 个位置准确率的宏平均。项目同时保留网格最小值和最大值用于分析空间平坦性，但主表仍使用平均值，以便与指导文件中的核心口径一致。逐类准确率和混淆矩阵基于 Large Shift 预测统计，逐样本结果还记录 dx 、 dy 和 angle ，供错误样本与可视化脚本追溯。

4.6 可复现运行顺序

在 Windows PowerShell 中，正式流程只保留多随机种子训练和评估。随机种子 42 本身已包含在五个种子中，训练曲线、位置热力图、逐类结果和 Attention 对比直接从该次运行生成，无需再训练一套内容重复的单种子模型。

```
conda activate pv-vit
python src/visualize_data.py
.\scripts\run_multiseed_experiments.ps1
.\scripts\eval_multiseed_grid.ps1
python src/visualize_attention_comparison.py
```

eval_multiseed_grid.ps1 会先为 30 个检查点完成固定位置和固定角度评估，再用随机种子 42 生成代表性细节图，最后汇总五个随机种子的主表和统计图。报告表格不依赖手工抄录，而是由每次运行的 evaluation.json、网格 CSV 和角度 CSV 重建。

5 实验设计与探索过程

5.1 六组主实验

表 4 不是简单的模型排行榜，而是按“建立基线、扩大训练分布、改变聚合方式、加入局部先验”的顺序组织实验。E1–E3 建立中心训练基线；E4 检查扩大训练分布的效果；E5 改变 token 聚合方式；E6 组合局部卷积特征与 Transformer。同一随机种子下，所有模型使用相同的数据划分、优化器和评估协议。

表 4: 主实验矩阵及各实验回答的问题

编号	模型	训练分布	关键设置	主要问题
E1	MLP	Center	展平输入	缺少空间结构时位置退化有多明显？
E2	CNN	Center	局部卷积与池化	权值共享能否自然抵抗大幅平移？
E3	ViT-AbsPos	Center	Learnable Pos + CLS	全局交互是否仍会学习中心偏置？
E4	ViT-Aug	Shift+Rotation	CLS + Random Erasing	目标扰动增强组合能改善多少？
E5	ViT-MeanPool	Shift+Rotation	Mean Pooling	聚合方式是否改善稳定性？
E6	HybridConv-ViT	Shift+Rotation	Conv Stem + Mean	局部归纳偏置能否继续提升？

5.2 三层对照逻辑

六组实验可以合并为三层对照。第一层是 E1–E3：训练分布固定为 Center，只比较 MLP、CNN 与 ViT 的空间建模方式，用来判断中心测试是否掩盖位置失效。第二层是 E3–E4：ViT 结构保持不变，训练输入扩展为平移、旋转和擦除，观察分布覆

盖带来的整体变化。第三层是 E4–E6：在相同增强方向上比较 CLS、Mean Pooling 以及卷积 stem 与 Transformer 的组合，考察聚合方式和局部视觉先验。按题目中的 A/B 记法，中心训练模型的 Center 与扰动测试分别对应 B/B 和 B/A，增强模型的 Center 与扰动测试则对应 A/B 和 A/A；项目用动态取样切换分布，不需要复制四套数据文件。

表 5：按题目 A/B 记法重排的 ViT 四设置结果（五个随机种子的均值 $\pm$ 标准差）

	测试 B: Center	测试 A: Large Shift
训练 B: Center	B/B ViT-AbsPos 86.38% $\pm$ 0.20	B/A ViT-AbsPos 20.03% $\pm$ 1.36
训练 A: Shift+Rotation	A/B ViT-Aug 62.81% $\pm$ 2.12	A/A ViT-Aug 64.60% $\pm$ 2.37

说明：A 表示目标位置发生变化。为复用六组正式实验，训练 A 对应项目中的 Shift+Rotation 与 Random Erasing 组合，而测试 A 只使用 Large Shift；因此该矩阵用于直观呈现训练/测试分布交叉，不把 B/A 到 A/A 的差异解释为纯平移增强的独立因果效应。

表 5 把主实验中结构相同的 ViT-AbsPos 与 ViT-Aug 重新排成题目建议的四设置。B/B 与 B/A 的巨大落差说明中心训练的高分不能迁移到位置变化测试；A/B 与 A/A 的接近则说明扰动训练削弱了对测试位置的依赖。由于训练 A 还包含旋转和随机擦除，这张表用于对齐题目口径和展示分布交叉，不替代后续消融表对各组件证据边界的说明。

本轮选择 7 像素 patch，使 56×56 输入恰好形成 8×8 个 token，并把计算量控制在 CPU 可接受范围。由于没有训练其他 patch 配置，本文只说明这一取值，不讨论 patch 大小的优劣。

这条链更像课程项目中的逐步试验，而不是完整的全因子消融。E4 同时加入三类增强，E6 也建立在增强和 Mean Pooling 之上，所以我们能回答“这套组合有没有用”，却不能把每一点提升精确分给单个因素。E4 与 E5 最接近单变量比较；固定位置和固定角度扫描则用来看看随机平均值有没有藏住边缘位置或极端角度的问题。

5.3 评价安排

不同结果承担不同作用：随机协议用于概括总体变化，49 点位置网格和固定角度扫描用于定位空间与方向上的薄弱区域，逐类结果、错误样本和 Attention Rollout 则用于解释平均值背后的类别差异。主结果汇总五个固定随机种子下的均值与标准差，并结合中位数、四分位数以及同一随机种子内的模型差值判断变化是否稳定。这样既保留总体结论，也不会把定性可视化误当成额外的量化证据。

6 实验结果与量化分析

本节汇总六组模型在五个随机种子下的正式结果，不包含 smoke test。每个随机种子都重新进行数据划分、模型初始化和训练增强，随机评估协议也使用相应种子；固定位置和固定角度扫描则保持统一坐标与角度。主表用均值和标准差回答“平均能做到什么程度”，三张柱形图用中位数和上下四分位数展示五次运行的大致分布。两种统计来自同一批实验：具体数值以主表为准，模型间的整体差距可直接参考柱图。作为探索性项目，分析重点是变化方向及其跨种子一致性，不对很小的差距作过度解释。

6.1 中心高分不等于位置鲁棒

表 6: 不同模型的位置鲁棒性结果（五个随机种子汇总）。Accuracy 均值采用百分比，Drop 均值采用百分点； $\pm$ Std 行均以百分点表示跨种子标准差。

Model	Stat	Center Acc	Small Shift Acc	Large Shift Acc	Rotation Acc	Shift+Rotation Acc	Grid Acc	Robust Drop (pp)	Rotation Drop (pp)
MLP	Mean	87.63%	25.06%	14.22%	44.14%	13.31%	13.58%	73.41	43.48
	$\pm$ Std	0.14	0.57	0.26	0.79	0.08	0.18	0.18	0.87
CNN	Mean	90.93%	29.49%	13.80%	50.47%	12.33%	13.09%	77.13	40.46
	$\pm$ Std	0.12	0.77	0.50	0.80	0.20	0.48	0.46	0.73
ViT-AbsPos	Mean	86.38%	30.35%	20.03%	46.18%	17.40%	20.68%	66.35	40.20
	$\pm$ Std	0.20	1.50	1.36	1.71	0.94	1.23	1.33	1.77
ViT-Aug	Mean	62.81%	64.49%	64.60%	64.86%	65.04%	63.77%	-1.80	-2.06
	$\pm$ Std	2.12	2.37	2.37	2.51	2.83	2.20	1.25	1.11
ViT-MeanPool	Mean	63.51%	66.02%	66.29%	66.20%	66.83%	65.17%	-2.78	-2.69
	$\pm$ Std	0.70	0.89	0.99	1.29	1.05	0.83	0.99	1.02
HybridConv-ViT	Mean	81.42%	81.83%	81.33%	81.86%	80.90%	81.05%	0.09	-0.44
	$\pm$ Std	0.48	0.74	0.72	0.90	0.81	0.73	0.62	0.52

先看最直观的一组结果：只在中心样本上训练时，MLP、CNN 和 ViT-AbsPos 的 Center Accuracy 都超过 86%，CNN 更达到 90.93%。但把衣物移到大范围随机位置后，三者分别只剩 14.22%、13.80% 和 20.03%。CNN 在熟悉的中心位置分得最好，在 Large Shift 下却下降最多。这个反差正好回答了项目最初的问题：标准 FashionMNIST 上的高分，并不能直接代表模型已经学会识别“出现在任何位置”的衣物。

ViT-AbsPos 的中心准确率比 CNN 低 4.55 个百分点，但 Large Shift 和 Grid Accuracy 分别高出 6.23 和 7.59 个百分点，说明全局 token 交互带来了一定帮助。不过，它的 Robust Drop 仍有 66.35 个百分点，因此“使用自注意力便自然不怕平移”并不成立。至少对当前小型 ViT 而言，训练数据覆盖哪些位置仍是决定性因素。

加入平移、旋转和擦除后，性能分布明显改变。ViT-Aug 的中心准确率降到 62.81%，但 Large Shift、Rotation 和 Shift+Rotation 都稳定在约 65%：它不再只擅长画布中央，而是用一部分中心成绩换来更均匀的表现。ViT-MeanPool 又把这些指标小幅推到约 64%–67%。五个随机种子中有四个呈现同向变化，因此 Mean Pooling 可以看作一个值得保留的小改动，但不是整条改进路线的主要贡献来源。

综合表现最好的是 HybridConv-ViT。它的 Center 和 Large Shift Accuracy 分别为 81.42% 和 81.33%，Rotation、Shift+Rotation 和 Grid Accuracy 则为 81.86%、80.90% 和 81.05%。它没有追上 CNN 的中心最高分，却几乎消除了不同协议之间的落差。这个模型只有约 29 万个参数，最多训练 12 轮，却能在位置和角度变化下维持约 81% 的准确率，已经达到本项目的核心目标。




图 8：五个随机种子汇总后的多协议结果，柱高与空心圆表示中位数，误差线范围为第一至第三四分位数

6.2 从增强到 Hybrid 的逐步变化

表 7：模型消融实验结果（五个随机种子的中位数）

Model	Augmentation	Pooling	Conv Stem	Grid Acc	Robust Drop (pp)
MLP	center	cls	No	13.59%	73.32
CNN	center	cls	No	13.16%	76.97
ViT-AbsPos	center	cls	No	20.56%	65.91
ViT-Aug	shift_rotation	cls	No	64.70%	-1.59
ViT-MeanPool	shift_rotation	mean	No	65.37%	-2.89
HybridConv-ViT	shift_rotation	mean	Yes	80.96%	-0.01

表 7 按增强、pooling 和卷积 stem 整理六组配置。

E3 到 E4 的 Grid Accuracy 中位数从 20.56% 提升到 64.70%，一次增加 44.14 个百分点。两者的 ViT 主体相同，主要区别是 E4 训练时真正见过平移、旋转和擦

除后的样本。这是整组实验中最清楚的一次跃升，也说明本项目最有效的第一步不是继续加深网络，而是先把训练数据改成任务实际会遇到的样子。由于三种增强是一起加入的，这 44.14 个百分点应理解为整套增强方案的效果。

E4 到 E5 只把 CLS 聚合换成 Mean Pooling，Grid Accuracy 中位数从 64.70% 提升到 65.37%。增幅不大，但五个随机种子中有四个方向一致。对本项目而言，这表明 Mean Pooling 是一个合理的小幅改进，但不足以单独解释整体性能提升。

E5 到 E6 加入卷积 stem 后，Grid Accuracy 中位数再增加 15.59 个百分点，七角度平均中位数增加 16.38 个百分点，而且 Center、Large Shift、Rotation 和 Shift+Rotation 都同步提高。Hybrid 只有 291,402 个参数，仍小于 MLP 和 CNN，因此这次提升至少不能简单解释为“模型更大了”。更自然的理解是：卷积先把局部轮廓整理成较稳定的特征，Transformer 再负责跨位置组合这些信息，两种结构在这个任务上配合得更好。




图 9：五个随机种子下六组模型的 49 点 Grid Accuracy，柱高与空心圆表示中位数，误差线范围为第一至第三四分位数

图 10 把三个关键比较放回同一随机种子内观察。E6 相对 E5、E4 相对 E3 的差值在五个随机种子下都为正；只有 E5 相对 E4 在随机种子 12345 下出现反向。由此看，增强和卷积 stem 带来的变化较稳定，聚合方式属于次要改进。




图 10: 同一随机种子下关键模型对的 Grid Accuracy 差值

6.3 固定角度扫描的量化结果

随机 Rotation Accuracy 对 $[-45^\circ, 45^\circ]$ 连续采样后的结果取平均, 适合概括整体水平, 却可能掩盖端点失效。五个随机种子下七个固定角度的宏平均分别为: MLP 39.93%、CNN 45.84%、ViT-AbsPos 41.75%、ViT-Aug 62.75%、ViT-MeanPool 64.02%、HybridConv-ViT 80.24%。

三个中心训练基线都在 0° 附近表现最好, 绝对角度越大, 准确率下降越快。ViT-Aug 和 ViT-MeanPool 把七角度平均提升到 60% 以上; HybridConv-ViT 达到 80.24%, 最差角度的跨种子均值也有 73.89%。这张图比单个 Rotation Accuracy 更直观地说明: 模型不只是平均准确率提高, 在 $\pm 45^\circ$ 端点也没有完全失效。正负角度仍有轻微不对称, 可能与服装轮廓、插值或有限采样有关, 本项目暂不作进一步解释。

图 11 补充展示七角度平均值和最差角度的跨种子中位数, 并与第 7 节的逐角度扇形图形成互补。前者强调整体稳定性, 后者用于检查单次代表性运行的平均值是否掩盖极端角度下降。




图 11: 五个随机种子下的固定角度鲁棒性, 柱高与空心圆表示中位数, 误差线范围为第一至第三四分位数

6.4 类别层面的困难并未消失

表 8: 随机种子 42 的代表性运行在 Large Shift 条件下的类别准确率

class	MLP	CNN	ViT-AbsPos	ViT-Aug	ViT-MeanPool	HybridConv-ViT
T-shirt/top	7.90%	12.70%	21.20%	58.30%	62.60%	72.10%
Trouser	6.90%	14.70%	18.00%	83.60%	90.00%	94.10%
Pullover	1.70%	9.60%	1.40%	40.20%	59.20%	67.90%
Dress	4.50%	4.80%	7.90%	68.50%	67.70%	80.20%
Coat	1.50%	2.00%	2.40%	50.80%	49.70%	80.20%
Sandal	49.00%	47.40%	65.20%	87.60%	86.20%	92.00%
Shirt	16.60%	6.10%	11.90%	21.70%	14.50%	49.20%
Sneaker	10.30%	7.50%	13.20%	80.90%	80.90%	91.10%
Bag	37.00%	24.40%	42.90%	69.40%	82.30%	94.70%
Ankle boot	3.90%	7.30%	28.30%	77.90%	85.20%	94.70%

表 8 和本节后续错误分析沿用随机种子 42 的代表性运行, 用于展示类别结构, 而不是再次估计跨种子均值。因此, 下面的具体百分比应与第 7 节代表性可视化互相印证, 不与表 6 中的五种子均值混用。

Large Shift 下, HybridConv-ViT 在 Trouser、Sandal、Sneaker、Bag 和 Ankle boot 上分别达到 94.10%、92.00%、91.10%、94.70% 和 94.70%, 这些类别通常具有较明确的整体轮廓或局部特征。Shirt 只有 49.20%, 是 Hybrid 最困难的类别; Pullover 为 67.90%, T-shirt/top 为 72.10%。

增强并没有以相同幅度改善所有类别。以衬衫类为例, ViT-Aug 的准确率为

21.70%，ViT-MeanPool 反而只有 14.50%，说明聚合策略的总体收益不能直接推广到每个类别。相似上装之间需要依赖领口、袖长和衣身等完整形状，而边缘截断恰好会破坏这些结构。类别结果因此补充了平均指标：位置鲁棒性不仅是模型是否跟随目标移动，也取决于移动后还剩下多少可区分类别的信息。

7 可视化与误差分析

第 6 节给出五个随机种子的总体结果，本节采用随机种子 42 的代表性运行观察训练过程、位置与角度响应、类别错误和注意力分布，用于定位总体指标背后的具体失效区域。

7.1 训练过程

图 12 显示，中心训练的 MLP、CNN 和 ViT-AbsPos 很快达到较高验证准确率，验证损失也较低。ViT-Aug 和 ViT-MeanPool 的中心验证准确率明显较低，这是因为训练样本同时经历大范围平移和旋转，模型需要把有限容量分配给更广的输入分布，而验证集仍保持居中。

在随机种子 42 的运行中，HybridConv-ViT 的中心验证曲线高于另外两个增强 ViT，且损失持续下降。ViT-Aug 在第 7 轮达到本轮最佳验证准确率，随后三轮没有满足最小改进阈值，于第 10 轮触发早停；因此其曲线没有第 11、12 轮，这是真实训练过程而非日志缺失。训练曲线用于说明优化过程，不替代五种子的最终测试结果。




图 12: 随机种子 42 的代表性运行中六组模型的验证准确率与验证损失

训练曲线还提示一个重要取舍：如果只根据中心验证准确率判断，增强模型似乎不如中心基线；但位置网格显示相反结论。训练阶段和最终评价目标不完全一致，是后续可以继续改进的工程环节。

7.2 位置响应

图 13 是回答“位置变化是否影响分类”的核心证据。MLP、CNN 和 ViT-AbsPos 都在 (0, 0) 附近形成显著高值区，向四周移动后迅速变浅。中心测试只取到了这些分布的最高区域，因此会严重高估模型面对任意位置时的水平；精确的均值、极值和下降幅度已在第 6 节给出。

随机种子 42 下，ViT-Aug 和 ViT-MeanPool 的热力图不再出现突出的中心岛，说明训练期随机位置覆盖改变了模型的空间响应。HybridConv-ViT 的 49 点结果进一步收紧，最差位置与最好位置只相差 4.50 个百分点。该局部形态与图 9 的跨种子总体排序一致；与单个 Grid Accuracy 相比，热力图还能说明代表性运行的改进不是由少数容易坐标拉高平均值。




图 13: 随机种子 42 的 7×7 位置网格准确率，横轴和纵轴分别为 dx 、 dy ，每个单元均来自完整测试集

7.3 无裁剪内层与可能裁剪外圈

为了进一步检查边缘下降，表 9 和图 14 把同一份 7×7 网格拆成两组。内层 5×5 使用 $\{-12, -6, 0, 6, 12\}$ ，28 像素前景在 56 像素画布中保持完整；外圈 24 个点至少有一个坐标为 ± 18 ，因而会在对应方向损失 4 像素。这个拆分不需要重新训练或重新选择样本，每个坐标仍评估完整测试集。

表 9: 随机种子 42 的无裁剪内层与可能裁剪外圈对照。内层为 $|dx|, |dy| \leq 12$ 的 25 个点，外圈为至少一个坐标等于 ± 18 的 24 个点。

Model	Inner 5×5 Acc	Outer Ring Acc	Inner-Outer (pp)
MLP	16.97%	10.13%	6.84
CNN	16.47%	10.12%	6.35
ViT-AbsPos	26.76%	17.32%	9.44
ViT-Aug	63.12%	61.42%	1.70
ViT-MeanPool	66.72%	65.67%	1.05
HybridConv-ViT	81.57%	80.39%	1.18




图 14: 随机种子 42 的无裁剪内层 5×5 与可能裁剪外圈 Accuracy 对比，柱顶数字为准确率，gap 为两组百分点差

三个中心训练基线的内外圈差距为 6.35–9.44 个百分点，其中 ViT-AbsPos 最大；ViT-Aug、ViT-MeanPool 和 HybridConv-ViT 的差距只有 1.05–1.70 个百分点。换言之，增强模型不仅热力图更平坦，在前景部分越界的外圈也没有出现额外的大幅崩溃。不过，外圈同时比内层离中心更远，因此这项拆分只能量化“边缘位置加上裁剪”的联合惩罚，不能把差值全部解释为可见信息损失的纯因果效应。

7.4 角度响应

图 15 把随机种子 42 在 -45° 到 45° 下的结果排成扇形，每个模型占一层环带，单元格数字为该固定角度下的 Accuracy。下方柱状图单独给出七个角度的平均值，避免把平均统计塞入扇形后降低可读性；跨种子的角度总体水平则以图 11 为准。

三个中心训练基线在 0° 形成深色尖峰，越靠近 $\pm 45^\circ$ 越浅；其中 CNN 的平均值明显受到中心高点拉动。ViT-Aug 和 ViT-MeanPool 的颜色沿角度方向更均匀，Hybrid 则在所有扇区保持较深颜色。扇形图因此同时呈现了三个信息：中心峰值有多高、极端角度下降多快，以及平均准确率是否由少数角度支撑。正负角度的局部不对称只是观察现象，当前实验无法区分类别朝向、插值误差和随机波动的影响。




图 15: 随机种子 42 的固定角度扇形热力图与七角度平均准确率，扇形由左至右对应 -45° 到 45°

7.5 逐类热力图与混淆结构

图 16 显示 Large Shift 下十个类别并没有同步改善。鞋类、包和裤子在增强模型中形成较稳定的高值区，上装类别仍较困难。尤其是 Shirt 一行在所有模型中都明显偏浅，说明整体 Grid Accuracy 的提高没有消除细粒度类别混淆。





图 16: 随机种子 42 的代表性运行在 Large Shift 条件下的逐类准确率

图 17 中的混淆矩阵进一步给出错误方向。数量最多的非对角项是 Shirt 被预测为 Coat (252 次)，其次是 Pullover 被预测为 Coat (167 次)、T-shirt/top 被预测为 Shirt (164 次) 以及 Shirt 被预测为 T-shirt/top (115 次)。这些错误集中在轮廓相近的上装类别，符合逐类准确率的观察。鞋类也存在外形接近的混淆，例如 Sneaker 与 Ankle boot，但数量明显少于上装内部错误。



(a) Large Shift 混淆矩阵



(b) 典型错误样本

图 17: 随机种子 42 的 HybridConv-ViT 在 Large Shift 下的类别混淆与错误样本

错误样本大致可以分为两类。一类主体仍较完整，但类别本身相近，例如 Coat 被预测为 Dress、Pullover 或 Shirt；另一类处在 $|dx|$ 或 $|dy|$ 较大的位置，只剩局部鞋面、裤腿或衣身，模型只能根据残留纹理判断。图中也存在 Sandal 与 Sneaker、Sneaker 与 Ankle boot 的互相混淆。这说明部分失败源于类别边界，部分失败来自可见信息减少，不能全部归结为 Transformer 结构。

7.6 Attention Rollout

Attention 对照使用随机种子 42。图 18 和图 19 每行依次给出输入、ViT-AbsPos rollout 和 Hybrid rollout。Hybrid 的高响应通常更集中于当前前景，例如角落中的鞋面、衣身或裤腿；ViT-AbsPos 的响应有时扩散到前景外的空白区域，或者只覆盖局部边缘。



图 18: 随机种子 42 中五个边缘位置样本的 Attention Rollout 对照 (一), 左至右为输入、ViT-AbsPos 和 HybridConv-ViT




图 19: 随机种子 42 中五个边缘位置样本的 Attention Rollout 对照 (二)

rollout 是注意力权重的传播结果，不等同于特征贡献或因果解释。因此，它只

能与网格准确率和错误样本一起作为定性线索，不能单独证明卷积 stem 导致了某种决策机制。

8 总结、局限与后续工作

8.1 对研究问题的回答

第一，位置变化会不会明显影响分类？会，而且影响远大于中心测试给人的印象。中心训练的 MLP、CNN 和 ViT-AbsPos 在 Center 上都有 86% 以上准确率，CNN 达到 90.93%；换成 Large Shift 后，三者只剩 14.22%、13.80% 和 20.03%。这说明原任务中的高准确率很大一部分建立在“衣物总在画布中央”这一稳定条件上。一旦位置变化并伴随边缘裁剪，模型原有的分类能力不能直接迁移过去。

第二，使用绝对位置编码的 Tiny ViT 能否自然适应位移？不能。ViT-AbsPos 在 Large Shift 和位置网格上比中心训练的 MLP、CNN 略好，但 Grid Accuracy 仍只有约 21%，Robust Drop 达到 66.35 个百分点。自注意力让远距离 patch 可以交换信息，却没有替代合适的训练分布；可学习绝对位置编码也仍会把 token 与固定画布坐标联系起来。

第三，数据增强、Mean Pooling 和卷积 stem 是否有效？三者的作用大小不同。加入平移、旋转和随机擦除后，ViT 的 Grid Accuracy 从约 21% 提升到约 65%，这是最主要的变化；Mean Pooling 又带来约 1 个百分点的小幅改善；加入卷积 stem 后，HybridConv-ViT 的 Center、Large Shift、Rotation、Shift+Rotation 和 Grid Accuracy 都达到约 81%。它没有取得最高的中心准确率，但位置改变、角度改变或二者同时出现时，成绩几乎不再下降。

因此，可以认为 HybridConv-ViT 已经达到本项目对“位置可变 FashionMNIST 分类器”的初步设计要求：它在保留较好分类准确率的同时，明显减弱了模型对中心位置和固定朝向的依赖，并且这一结果在五个随机种子下保持一致。它还不是一个完全解决问题的模型，例如 Shirt 等相似上装仍较难分类，极端位置的前景裁剪也没有消失；但相较于三个中心训练基线，它已经从“中心图像分类器”推进成了能够实际处理位置与角度变化的分类器。

8.2 现有局限

1. **增强没有逐项拆开。**E4 同时加入平移、旋转和随机擦除；E6 又建立在增强与 Mean Pooling 之上。当前报告能确认组合方案有效，但还不知道每个组件单独贡献多少。
2. **边缘裁剪仍构成混杂因素。**第 7 节已把无裁剪内层与可能裁剪外圈分开汇总，量化了边缘区域的额外下降；但外圈也比内层离中心更远，所以该对照仍不能

把位置偏置和可见信息损失作纯因果分解。

3. **早停依据偏向中心**。验证集使用 Center 协议，可能优先选择中心准确率较好的检查点，而不是网格或复合扰动最稳定的检查点。
4. **训练预算有限**。CPU 配置采用 7 像素 patch、64 维 embedding、2 层 Encoder 和最多 12 个 epoch，足够完成课程项目的比较，但没有探索更大 ViT 或更长训练的上限。
5. **Attention 解释有限**。rollout 样本按预测差异筛选，不能代表完整测试分布；注意力高响应也不等同于因果特征重要性。
6. **效率证据不完整**。当前只可靠记录参数量和单次训练的 epoch time，尚未在统一硬件与 batch size 下重复测量推理延迟、峰值内存和吞吐量，也未统计 FLOPs。因此报告可以比较模型规模，但不宣称 Hybrid 已取得最佳计算效率。

8.3 后续可开展实验

如果继续推进，优先补充几个能把现有现象讲得更清楚的实验：依次比较 Center、只平移、平移 + 旋转、平移 + 旋转 + 擦除；在相同增强下单独切换 CLS 与 Mean Pooling；再比较有无卷积 stem。这样可以更直接地判断每一步为何有效。位置编码也可以补充 Learnable、Sin-Cos 和 No-Pos 三种设置。

对于数据协议，后续可以设计可见像素比例受控的配对样本：在保持位移距离相近的情况下分别保留完整前景和模拟裁剪，从而比当前内外圈拆分更严格地区分纯位置变化与信息缺失。验证阶段也可同时监控 Center Accuracy 与扰动验证准确率，或者使用二者加权指标选择检查点。完成这些对照后，再考虑 GPU 配置、更小 patch 和更长训练。

9 成员贡献

贡献比例按小组协商结果分配，共计 100%。

表 10: 成员贡献记录

姓名	学号	主要分工	贡献比例
李恽凡	3240103379	实验流程搭建; 算法优化、可视化与报告撰写	27%
李建树	3230101228	项目框架搭建、基础算法编写	26%
龙官震	3250105720	实验多种子流程优化更新	26%
朱云麟	3250102363	优化报告	21%

9.1 项目仓库

项目代码、配置文件、运行脚本与报告源文件统一保存在以下仓库:

GitHub Repository

github.com/GuChL9/PV-FashionViT

参考文献

- [1] Han Xiao, Kashif Rasul, and Roland Vollgraf. Fashion-MNIST: a Novel Image Dataset for Benchmarking Machine Learning Algorithms. *arXiv preprint arXiv:1708.07747*, 2017.
- [2] Ashish Vaswani et al. Attention Is All You Need. In *Advances in Neural Information Processing Systems*, 2017.
- [3] Alexey Dosovitskiy et al. An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale. In *International Conference on Learning Representations*, 2021.