

PV-FashionViT：基于 Transformer 的位置可变 FashionMNIST 图像分类

[待填写：课程名称]

[待填写：学院/专业]

姓名	学号	GitHub 用户名	主要贡献
[待填写：成员 1]	[待填写：学号]	[待填写：用户名]	[待填写：贡献]
[待填写：成员 2]	[待填写：学号]	[待填写：用户名]	[待填写：贡献]
[待填写：成员 3]	[待填写：学号]	[待填写：用户名]	[待填写：贡献]
[待填写：成员 4]	[待填写：学号]	[待填写：用户名]	[待填写：贡献]

[待填写：提交日期]

摘要

本项目尝试把 FashionMNIST 上默认居中的分类任务改写为一个位置可控的鲁棒性问题。我们将 28×28 的灰度服饰前景放置到 56×56 画布的不同坐标, 构造 PV-FashionMNIST, 并比较 MLP、CNN、带绝对位置编码的 Tiny ViT, 以及加入仿射增强、Mean Pooling 和卷积 stem 的 ViT 变体。除中心、随机小平移和随机大平移外, 项目还在 7×7 固定位置网格上逐点测试, 以观察准确率的空间分布。实验中, 中心训练的 MLP、CNN 与 ViT-AbsPos 在大平移下均出现明显下降; 加入增强后的 ViT 变体在网格上的表现更均匀。HybridConv-ViT 在本次配置下取得 85.43% 的 Grid Accuracy, Center 与 Large Shift 的差为 0.27 个百分点。结果提示: 在这一小型数据集与单次训练预算下, 位置鲁棒性不能只由中心准确率判断, 训练数据中的位置分布与轻量局部归纳偏置都值得继续考察。项目同时保留了混淆矩阵、错误样本和 attention rollout, 用于辅助梳理模型在边缘位置的行为。

关键词: 位置鲁棒性; FashionMNIST; Vision Transformer; 数据增强; 可视化分析

目录

1	项目背景与研究问题	1
1.1	研究问题	1
1.2	主要工作	1
2	任务定义与数据集构造	2
2.1	任务定义	2
2.2	数据划分与复现	2
2.3	位置与复合扰动	2
3	模型设计	4
3.1	MLP 与 CNN 基线	4
3.2	Tiny ViT 与位置编码	4
3.3	增强、Mean Pooling 与 HybridConv-ViT	4
4	训练与评估流程	5
4.1	训练设置	5
4.2	Checkpoint、日志与复现	5
4.3	评估指标	5
5	实验设计	5
5.1	主实验矩阵	5
5.2	分析原则	6
6	实验结果	6
6.1	主结果	6
6.2	消融视角	7
6.3	类别准确率	8
7	可视化与错误分析	9
7.1	训练过程	9
7.2	位置网格	9
7.3	混淆与边缘错误	10
7.4	Attention Rollout 作为辅助观察	11

8 总结与展望	14
9 成员贡献	14

1 项目背景与研究问题

标准图像分类数据常把主体放在画面中央,这使得模型在中心测试集上获得较高准确率,却未必说明它能够适应位置改变。在实际拍摄或简单的家庭衣物整理场景中,衣物可能落在画面边缘,也可能因为构图而只显示部分轮廓。我们以 FashionMNIST 为起点,不追求把任务扩展为复杂的真实服饰识别,而是用一个可控的小型数据构造来观察:当图像内容相同、只改变其在画布上的位置时,模型会发生什么变化。

FashionMNIST 是由十类灰度服饰图像组成的公开基准数据集 [1]。它足够轻量,便于在 CPU 上完成多组对照;同时,类别间存在 Shirt、Pullover、Coat 等外形相近的情形,能够暴露边缘裁剪和局部纹理依赖带来的困难。Transformer 的全局 token 交互机制来源于自注意力结构 [2], Vision Transformer 将其用于图像 patch 序列 [3]。本项目并不预设 ViT 一定优于卷积网络,而是把 CNN、普通 ViT 和改进 ViT 放到相同的位置扰动协议下进行探索。

1.1 研究问题

围绕位置可变性,实验尝试回答以下三个问题:

1. 当训练和测试位置不一致时,中心准确率会以多大程度转化为大平移和网格位置上的性能?
2. 带可学习绝对位置编码、使用 CLS token 的 Tiny ViT 是否会呈现更明显的位置偏置?
3. 随机仿射增强、Mean Pooling 与卷积 stem 这三类工程选择,能否使网格上的预测更均匀?

1.2 主要工作

本项目完成的工作包括:

- 构造可复现的 PV-FashionMNIST; 每个样本记录 dx 、 dy 、旋转角度和缩放比例;
- 实现 MLP、CNN、Tiny ViT 与 HybridConv-ViT, 并以 YAML 配置管理六组主实验;
- 使用 Center、Small Shift、Large Shift 与 7×7 Grid 的组合协议, 记录 Robust Drop、逐类准确率和混淆矩阵;
- 将训练曲线、位置热力图、错误样本和 attention rollout 整理为可追溯的图表资产。attention 图仅用于观察模型关注区域, 不作为因果解释。

2 任务定义与数据集构造

2.1 任务定义

原始 FashionMNIST 样本为单通道 28×28 图像，标签属于十个服饰类别。PV-FashionMNIST 将前景粘贴到全零的 56×56 画布。以画布中心为基准， $dx > 0$ 表示向右移动， $dy > 0$ 表示向下移动；模型仍输出同一十类标签。这样，类别本身不变，而位置成为一个可独立操控的变量。

2.2 数据划分与复现

官方训练集的 60,000 张图像按固定随机种子 42 划分为 54,000 张训练样本和 6,000 张验证样本；官方 10,000 张测试样本只用于最终评估。训练时的随机位置由“seed + epoch + sample index”决定，因此同一配置在单进程或多进程加载下均可复现。训练集每个 epoch 更新位置，而验证与测试使用固定协议。

2.3 位置与复合扰动

本项目使用如下几类位置模式：Center 为 $(0, 0)$ ；Small Shift 在 $[-8, 8]$ 内均匀采样；Large Shift 在 $[-18, 18]$ 内均匀采样；Grid Shift 使用 $\{-18, -12, -6, 0, 6, 12, 18\}^2$ 的 49 个固定坐标。对于 Affine 训练模式，图像先在原始 28×28 前景上做 $\pm 10^\circ$ 旋转和 $[0.9, 1.1]$ 缩放，再以随机位置粘贴到画布，并以概率 0.25 施加随机擦除。由于无裁剪粘贴的最大位移只有 14 像素， $|dx|$ 或 $|dy| = 18$ 会使前景在画布边缘部分截断；这被保留为 Large Shift 难度的一部分，而不是数据错误。

图1展示原始样本与五种构造模式。图2进一步把同一张图置于九个典型坐标，直观说明本任务既包含纯平移，也在极端位置包含可见区域缩小的情况。




图 1: 原始 FashionMNIST 与 PV-FashionMNIST 的样本预览。随机平移、网格位置与 Affine 模式共享相同的类别标签，但改变了前景在 56×56 画布中的位置。




图 2: 同一测试样本在九个典型 (dx, dy) 位置下的外观。角落位置可出现边缘截断。

3 模型设计

所有模型接收 $[B, 1, 56, 56]$ 张量并输出十类 logits。模型规模有意保持较小，以便将实验重点放在位置协议和结构差异，而非预训练或大规模算力。

3.1 MLP 与 CNN 基线

MLP 将图像展平为 3,136 维向量，经 “Linear(256)–ReLU–Dropout–Linear(10)” 完成分类。它不显式保留二维邻域，因此作为对位置变化较敏感的下界对照。

CNN 使用两层 “Conv(3×3)–ReLU–MaxPool”，通道数依次为 32 和 64，随后连接 128 维全连接分类头。卷积核的局部连接与权重共享提供了平移相关的归纳偏置，因此 CNN 是检验 ViT 是否真正带来位置收益的必要对照，而不只是一个更高的中心准确率参照。

3.2 Tiny ViT 与位置编码

Tiny ViT 先用大小为 7×7 的卷积 patch embedding 将图像划分为 $8 \times 8 = 64$ 个 token，token 维度为 64；随后叠加可学习绝对位置编码，输入 2 层、4 头的 Transformer encoder，并用 CLS token 表示全局分类特征。绝对位置编码可帮助模型区分空间坐标，但也可能让模型在中心训练分布中学习到位置先验，这正是 ViT-AbsPos 的观察对象。

工程中另保留了 Sin-Cos 位置编码配置，作为后续位置编码消融入口；本报告的六组主实验仍以可学习绝对位置编码为主，以避免额外训练配置混入主对照。

3.3 增强、Mean Pooling 与 HybridConv-ViT

ViT-Aug 在 ViT-AbsPos 的基础上使用随机位置、旋转、缩放与随机擦除。ViT-MeanPool 进一步将 CLS token 改为所有 patch token 的均值。该改动的动机不是假定平均池化必然更好，而是尝试减少分类头对固定全局 token 的依赖。

HybridConv-ViT 在 patch embedding 前增加两层卷积 stem ($1 \rightarrow 32 \rightarrow 64$ ，均为 3×3 卷积和 ReLU)，再接相同规模的 Transformer 与 Mean Pooling。它把局部边缘/纹理提取和 token 级全局建模串联起来。由于后续实验同时改变了训练增强、pooling 和 stem，Hybrid 的结果应理解为一个组合方案的表现，而不能分解成某一个模块的严格独立贡献。

4 训练与评估流程

4.1 训练设置

六组主实验均在 CPU 上运行，batch size 为 64，DataLoader 使用单进程，随机种子为 42。优化器采用 AdamW，初始学习率 3×10^{-4} ，权重衰减为 0.05；学习率以 cosine scheduler 逐步衰减。交叉熵损失使用 0.1 的 label smoothing，并对梯度范数裁剪到 1.0。每组至多训练 12 个 epoch；在至少训练 5 个 epoch 后，若验证准确率连续 3 个 epoch 未达到最小改进阈值 0.0005，则触发早停。

该设置是一次面向普通 CPU 的工程取舍，并非充分调参后的最优训练方案。不同模型每个 epoch 的耗时差异明显，特别是 HybridConv-ViT 的卷积 stem 与 Transformer 组合更慢；因此本报告更关注同一预算下的趋势，而不把单次成绩视为稳定排名。

4.2 Checkpoint、日志与复现

每轮训练保存包含模型参数、优化器、scheduler、epoch、最佳验证准确率和完整配置的 checkpoint。每个 run 目录还记录 train loss、train accuracy、validation loss、validation accuracy、学习率和 epoch 耗时。最终评估始终加载验证集表现最好的 best.pt，避免使用最后一轮参数替代最佳模型。

4.3 评估指标

Center、Small Shift 与 Large Shift Accuracy 分别在对应固定协议的完整测试集上计算。Grid Accuracy 是 49 个固定坐标准确率的宏平均；这比只报告一次随机平移更能显示空间上的局部失效区域。Robust Drop 定义为

$$\text{Robust Drop} = \text{Center Accuracy} - \text{Large Shift Accuracy}, \quad (1)$$

其单位为百分点。除此之外，项目记录 Large Shift 下的逐类准确率、混淆矩阵以及逐样本预测，以免总体平均掩盖少数类别的失败模式。

5 实验设计

5.1 主实验矩阵

表1给出六组主实验。E1-E3 在中心位置训练，用于先观察不同基本架构受到位置分布变化时的敏感程度；E4-E6 使用 Affine 训练模式，逐步引入 Mean Pooling 与卷积 stem。所有模型都接受相同的四类最终测试协议，从而保证位置评估口径一致。

表 1: 主实验设置

编号	模型	训练数据	主要考察点
E1	MLP	PV-Center	无空间结构基线
E2	CNN	PV-Center	局部卷积归纳偏置
E3	ViT-AbsPos	PV-Center	绝对位置编码与 CLS token
E4	ViT-Aug	PV-Affine	训练期位置与外观增强
E5	ViT-MeanPool	PV-Affine	token 聚合方式
E6	HybridConv-ViT	PV-Affine	卷积 stem 与 Mean Pooling

5.2 分析原则

本实验矩阵不是严格的全因子设计：E4-E6 在结构改变之外共享增强训练，Hybrid 还同时使用了 Mean Pooling。因此，表3中的比较用于提出下一步值得验证的假设，而不把所有差值解释为某个单独模块的因果效应。比较时重点查看三条线索：中心与大平移的差距、49 点热力图是否平坦，以及类别层面是否仍存在集中失败。

6 实验结果

本节只使用各 run 的正式 checkpoint 与完整网格评估结果，不包含 smoke test。表2汇总四种位置协议，表3从增强、pooling 与卷积 stem 的组合角度整理结果。

6.1 主结果

表 2: 不同模型的位置鲁棒性结果

Model	Center Acc	Small Shift Acc	Large Shift Acc	Grid Acc	Robust Drop
MLP	87.48%	24.50%	13.93%	13.62%	73.55%
CNN	90.79%	29.40%	13.65%	13.36%	77.14%
ViT-AbsPos	86.45%	31.33%	20.76%	22.06%	65.69%
ViT-Aug	71.00%	72.25%	72.87%	71.52%	-1.87%
ViT-MeanPool	71.71%	72.67%	72.92%	71.58%	-1.21%
HybridConv-ViT	86.05%	86.38%	85.78%	85.43%	0.27%

中心训练的三种基线在 Center 上都达到 86% 以上，其中 CNN 为 90.79%；但它们在 Large Shift 上分别降至 13.93%、13.65% 和 20.76%。对应 Robust Drop 分别为 73.55、77.14 和 65.69 个百分点。这个现象并不说明 CNN 或 ViT “无效”，而是说明中心测试难以暴露训练位置与测试位置不一致的问题。

引入 Affine 训练后, ViT-Aug 与 ViT-MeanPool 的 Grid Accuracy 分别为 71.52% 与 71.58%, 两者的 Center-Large Shift 差接近 0。HybridConv-ViT 的 Grid Accuracy 进一步达到 85.43%, Large Shift Accuracy 为 85.78%。在本次配置中, Hybrid 的中心准确率没有超过 CNN, 但其不同位置之间的波动最小; 这正是本任务比单点准确率更关心的现象。




图 3: 中心准确率与位置鲁棒性下降的对比。两图的排序不同, 提示仅用中心准确率选择模型会遗漏位置敏感性。

6.2 消融视角

表 3: 模型消融实验结果

Model	Augmentation	Pooling	Conv Stem	Grid Acc	Robust Drop
MLP	center	cls	No	13.62%	73.55%
CNN	center	cls	No	13.36%	77.14%
ViT-AbsPos	center	cls	No	22.06%	65.69%
ViT-Aug	affine	cls	No	71.52%	-1.87%
ViT-MeanPool	affine	mean	No	71.58%	-1.21%
HybridConv-ViT	affine	mean	Yes	85.43%	0.27%

从 E3 到 E4, 训练分布由 Center 改为 Affine 后, 网格平均从 22.06% 提升到 71.52%; 这首先提示训练期位置覆盖可能是最直接的因素。E4 与 E5 的 Grid Accuracy 几乎相同, Mean Pooling 在本次预算下没有带来明显的网格均值提升, 但 Large Shift Accuracy 略高。E6 的组合方案在所有位置指标上进一步上升。由于模型之间并非只改动一个变量, 这些现象更适合形成后续消融的优先级: 先分离增强效应, 再单独重复 pooling 与 stem 的比较。

6.3 类别准确率

表 4: Large Shift 条件下的类别准确率

class	MLP	CNN	ViT-AbsPos	ViT-Aug	ViT-MeanPool	HybridConv-ViT
T-shirt/top	7.90%	12.70%	18.00%	68.10%	65.60%	81.20%
Trouser	6.90%	14.70%	14.00%	93.30%	94.90%	96.70%
Pullover	1.70%	9.60%	3.40%	66.00%	68.10%	83.30%
Dress	4.50%	4.80%	4.10%	76.80%	68.50%	81.00%
Coat	1.50%	2.00%	2.80%	56.40%	67.20%	75.50%
Sandal	49.00%	47.40%	67.80%	87.10%	88.40%	94.10%
Shirt	16.60%	6.10%	10.10%	19.10%	15.10%	58.70%
Sneaker	10.30%	7.50%	14.10%	87.00%	85.10%	96.60%
Bag	37.00%	24.40%	52.90%	88.60%	87.60%	97.80%
Ankle boot	3.90%	7.30%	20.40%	86.30%	88.70%	92.90%

Large Shift 下, Shirt 是最稳定的困难类别之一: ViT-Aug 与 ViT-MeanPool 的准确率仍只有 19.10% 和 15.10%; HybridConv-ViT 虽提升至 58.70%, 但仍低于其余多数类别。相比之下, Trouser、Sneaker、Bag 和 Ankle boot 在增强模型中更容易保持较高准确率。这种类别差异提示, 位置鲁棒性与类别轮廓、局部纹理以及边缘裁剪的可见比例有关, 不能只由平均准确率概括。




图 4: Large Shift 条件下的逐类准确率。浅色到深色表示从低到高的准确率; Shirt 在多种模型中仍较难。

7 可视化与错误分析

7.1 训练过程

图5汇总六组验证曲线。中心训练的 MLP、CNN 与 ViT-AbsPos 在较早阶段即可达到较高验证准确率；使用 Affine 训练的模型在中心验证上的起点更低，但后续位置测试更稳定。该差异符合一个直观猜测：训练分布更广时，模型未必把能力集中在中心位置。由于每组只运行一次固定种子，曲线仅反映本次训练轨迹，不用于判断统计显著性。




图 5: 六组模型的验证准确率与验证损失曲线。不同模型的单 epoch 耗时不同，横轴只表示训练轮数。

7.2 位置网格

图6是本项目最直接的空间证据。MLP、CNN 和 ViT-AbsPos 在 (0,0) 附近形成明显高值区，离开中心后大面积接近随机猜测水平。ViT-AbsPos 的高值区相对更宽，但仍随边缘位置迅速下降。相反，ViT-Aug 与 ViT-MeanPool 的热力图在 0.7 左右较为平坦；HybridConv-ViT 在全部 49 个位置上约为 0.83–0.87。这里的平坦性比单一 Grid 平均值更有信息量：它显示该模型并非只在少数偏移坐标上偶然表现良好。





图 6: 六组模型的 7×7 位置网格准确率。横纵轴为前景相对中心的像素平移。

7.3 混淆与边缘错误

图7给出 HybridConv-ViT 在 Large Shift 下的混淆矩阵和部分错误样本。尽管 Hybrid 的总体准确率较高, Shirt 仍容易与形状相近的上装类别混淆。错误样本中还可看到部分主体被截断, 模型只能利用局部边缘或纹理判断类别。因而, 极端坐标上的失败不能完全被解释为“模型没有学会平移不变性”; 可见信息减少同样改变了任务难度。



(a) Large Shift 混淆矩阵



(b) 部分错误样本

图 7: HybridConv-ViT 在 Large Shift 下的类别混淆与典型错误。

7.4 Attention Rollout 作为辅助观察

为避免只展示容易分类的样本，我们从四个角落选择了 ViT-AbsPos 未正确分类而 HybridConv-ViT 正确分类的十个样本，并按不同类别和坐标分布到图8与图9。图中左列为输入，中列与右列分别为两个模型的 rollout 叠加结果。可以观察到，HybridConv 的高响应通常与当前前景所在角落更一致；ViT-AbsPos 的响应有时扩散到前景之外。不过该图是按预测差异筛选的展示样本，存在选择性，且 attention 权重本身不等同于因果归因。因此它只支持对模型行为的定性讨论，不替代表2和图6中的量化结论。




图 8: 五个边缘位置样本上的 attention rollout 对照 (一)。左至右为输入、ViT-AbsPos 与 HybridConv-ViT。




图 9: 五个边缘位置样本上的 attention rollout 对照 (二)。样本的完整筛选记录保存在项目输出目录。

8 总结与展望

本项目以可控方式把 FashionMNIST 的中心分类问题扩展为位置可变条件下的分类实验。六组结果共同提示：中心准确率不足以代表位置鲁棒性。中心训练的 MLP、CNN 与 ViT-AbsPos 都在 Large Shift 和完整网格上发生大幅下降；将随机位置、旋转、缩放和擦除纳入训练后，热力图明显变平。加入卷积 stem 与 Mean Pooling 的 HybridConv-ViT 在本次配置中取得最小的 Robust Drop 和最高的 Grid Accuracy。

这些结果更像一个值得继续追踪的探索方向，而不是对模型优劣的最终验证。当前六组实验使用单个随机种子、统一但有限的 CPU 预算，且 E4-E6 的增强、pooling 与 stem 并未完全解耦。未来可以在多个种子下重复训练，补充仅随机平移、仅 Mean Pooling、仅卷积 stem 的控制实验；也可以比较 No-Pos 与 Sin-Cos 位置编码，并将真实拍摄的衣物图像作为不参与训练的外部测试集。对于边缘裁剪，还可将纯平移与显式遮挡分开标注，以更清楚地区分位置变化和信息缺失带来的影响。

9 成员贡献

填写提示：按 Git commit、Pull Request、实验记录和报告章节如实填写，贡献比例合计为 100%。

表 5: 成员贡献记录

姓名	学号	可核验贡献	比例
[待填写: 成员 1]	[待填写: 学号]	[待填写: 提交、实验与文档]	—
[待填写: 成员 2]	[待填写: 学号]	[待填写: 提交、实验与文档]	—
[待填写: 成员 3]	[待填写: 学号]	[待填写: 提交、实验与文档]	—
[待填写: 成员 4]	[待填写: 学号]	[待填写: 提交、实验与文档]	—

参考文献

- [1] Han Xiao, Kashif Rasul, and Roland Vollgraf. Fashion-mnist: a novel image dataset for benchmarking machine learning algorithms. *arXiv preprint arXiv:1708.07747*, 2017.
- [2] Ashish Vaswani et al. Attention is all you need. In *Advances in Neural Information Processing Systems*, 2017.
- [3] Alexey Dosovitskiy et al. An image is worth 16x16 words: Transformers for image recognition at scale. In *International Conference on Learning Representations*, 2021.